Машинне навчання

Метод дерева прийняття рішень (decision tree)

Лабораторна робота 1

Студентка Пороскун Олена. Група ПМ.м-21

Task 1

Постановка задачі

1. Розділити всю вибірку на навчальну та тестову
2. Побудувати алгоритм навчання на навчальній вибірці з використанням вбудованого алгоритму DecisionTreeClassifier() з бібліотеки sklearn
3. Перевірити результати роботи на тестовій вибірці.
4. Вивести на екран дерево.
5. Оформити результати у вигляді звіту.

Розглянемо перший датасет

- Імпортуємо необхідні бібліотеки

```
In [1]: import numpy as np
        import pandas as pd
        from matplotlib import pyplot as plt
```

```
In [2]: from sklearn import tree
        from sklearn.tree import DecisionTreeClassifier
        from sklearn.model_selection import train_test_split

        # Імпорт модуля метрик scikit-learn для розрахунку точності
        from sklearn import metrics

        from sklearn.tree import export_graphviz
        from io import StringIO

        from IPython.display import Image
        import graphviz
        import pydotplus
```

```
In [3]: !pip install graphviz
        !pip install pydotplus

Requirement already satisfied: graphviz in c:\users\admin\anaconda3\lib\site-packages (0.20.1)
Requirement already satisfied: pydotplus in c:\users\admin\anaconda3\lib\site-packages (2.0.2)
Requirement already satisfied: pyparsing>=2.0.1 in c:\users\admin\anaconda3\lib\site-packages (from pydotplus) (3.0.9)
```

```
In [4]: #conda install graphviz
```

- Будемо розглядати датасет **creditcard.csv**. Виведемо його у формі датафрейму.

```
In [5]: data = pd.read_csv('creditcard.csv')
```

```
In [6]: data.head()
```

Out[6]:

	Time	V1	V2	V3	V4	V5	V6	V7	V8	V9	...	V21	V22	V23	V24	V25	V26	V27	V28	Amount	Class
0	0.0	-1.359807	-0.072781	2.536347	1.378155	-0.338321	0.462388	0.239599	0.098698	0.363787	...	-0.018307	0.277838	-0.110474	0.066928	0.128539	-0.189115	0.133558	-0.021053	149.62	0
1	0.0	1.191857	0.266151	0.166480	0.448154	0.060018	-0.082361	-0.078803	0.085102	-0.255425	...	-0.225775	-0.638672	0.101288	-0.339846	0.167170	0.125895	-0.008983	0.014724	2.69	0
2	1.0	-1.358354	-1.340163	1.773209	0.379780	-0.503198	1.800499	0.791461	0.247676	-1.514654	...	0.247998	0.771679	0.909412	-0.689281	-0.327642	-0.139097	-0.055353	-0.059752	378.66	0
3	1.0	-0.966272	-0.185226	1.792993	-0.863291	-0.010309	1.247203	0.237609	0.377436	-1.387024	...	-0.108300	0.005274	-0.190321	-1.175575	0.647376	-0.221929	0.062723	0.061458	123.50	0
4	2.0	-1.158233	0.877737	1.548718	0.403034	-0.407193	0.095921	0.592941	-0.270533	0.817739	...	-0.009431	0.798278	-0.137458	0.141267	-0.206010	0.502292	0.219422	0.215153	69.99	0

5 rows × 31 columns

```
In [7]: #data.info()
```

- Далі визначаємо ознаки та цільову змінну. Ділимо вибірку на навчальну і тестову. Виведемо їх розмірності.

```
In [8]: X = data.drop(columns='Class', axis=1)
        y = data['Class']
```

```
In [9]: data['Class'].value_counts()

Out[9]: 0    284315
        1       492
        Name: Class, dtype: int64
```

```
In [10]: X_train, X_test, y_train, y_test = \
                         train_test_split(X, y, test_size = 0.25, random_state = 1) # 75% training and 25% test
         print(X_train.shape, X_test.shape)
         print(y_train.shape, y_test.shape)

(213605, 30) (71202, 30)
(213605,) (71202,)
```

- Створюємо об'єкт класифікатора дерева рішень. За замовчуванням у класифікатора стоїть критерій *gini* (default="gini"), тому можна не вказувати його. Максимальна глибина дерева буде 3.
- Створюємо класифікатор дерева прийняття рішень для тренувань.
- Робимо прогноз на тестовому наборі даних.

```
In [11]: clf = DecisionTreeClassifier(random_state=0, max_depth=3)
         clf = clf.fit(X_train, y_train)
         y_pred = clf.predict(X_test)
```

- Перевіряємо результати роботи на тестовій вибірці за допомогою точності моделі (як часто класифікатор є правильним):

```
In [12]: y_pred = clf.predict(X_test)
         print("Оцінка тестового набору даних: ", metrics.accuracy_score(y_test, y_pred))

Оцінка тестового набору даних:  0.9991713715906857
```

- Виводимо на екран дерево прийняття рішень:

```
In [13]: plt.figure(figsize=(15,10))
         tree.plot_tree(clf.fit(X_train, y_train))

Out[13]: [Text(0.5, 0.875, 'X[17] <= -2.789\ngini = 0.004\nsamples = 213605\nvalue = [213224, 381]'),
          Text(0.25, 0.625, 'X[10] <= -2.129\ngini = 0.348\nsamples = 348\nvalue = [78, 270]'),
          Text(0.125, 0.375, 'X[26] <= -0.225\ngini = 0.256\nsamples = 305\nvalue = [46, 259]'),
          Text(0.0625, 0.125, 'gini = 0.442\nsamples = 103\nvalue = [34, 69]'),
          Text(0.1875, 0.125, 'gini = 0.112\nsamples = 202\nvalue = [12, 190]'),
          Text(0.375, 0.375, 'X[21] <= 0.304\ngini = 0.381\nsamples = 43\nvalue = [32, 11]'),
          Text(0.3125, 0.125, 'gini = 0.124\nsamples = 30\nvalue = [28, 2]'),
          Text(0.4375, 0.125, 'gini = 0.426\nsamples = 13\nvalue = [4, 9]'),
          Text(0.75, 0.625, 'X[14] <= -8.092\ngini = 0.001\nsamples = 213257\nvalue = [213146, 111]'),
          Text(0.625, 0.375, 'X[15] <= 1.423\ngini = 0.198\nsamples = 27\nvalue = [3, 24]'),
          Text(0.5625, 0.125, 'gini = 0.0\nsamples = 24\nvalue = [0, 24]'),
          Text(0.6875, 0.125, 'gini = 0.0\nsamples = 3\nvalue = [3, 0]'),
          Text(0.875, 0.375, 'X[14] <= -4.661\ngini = 0.001\nsamples = 213230\nvalue = [213143, 87]'),
          Text(0.8125, 0.125, 'gini = 0.265\nsamples = 197\nvalue = [166, 31]'),
          Text(0.9375, 0.125, 'gini = 0.001\nsamples = 213033\nvalue = [212977, 56]')]
```

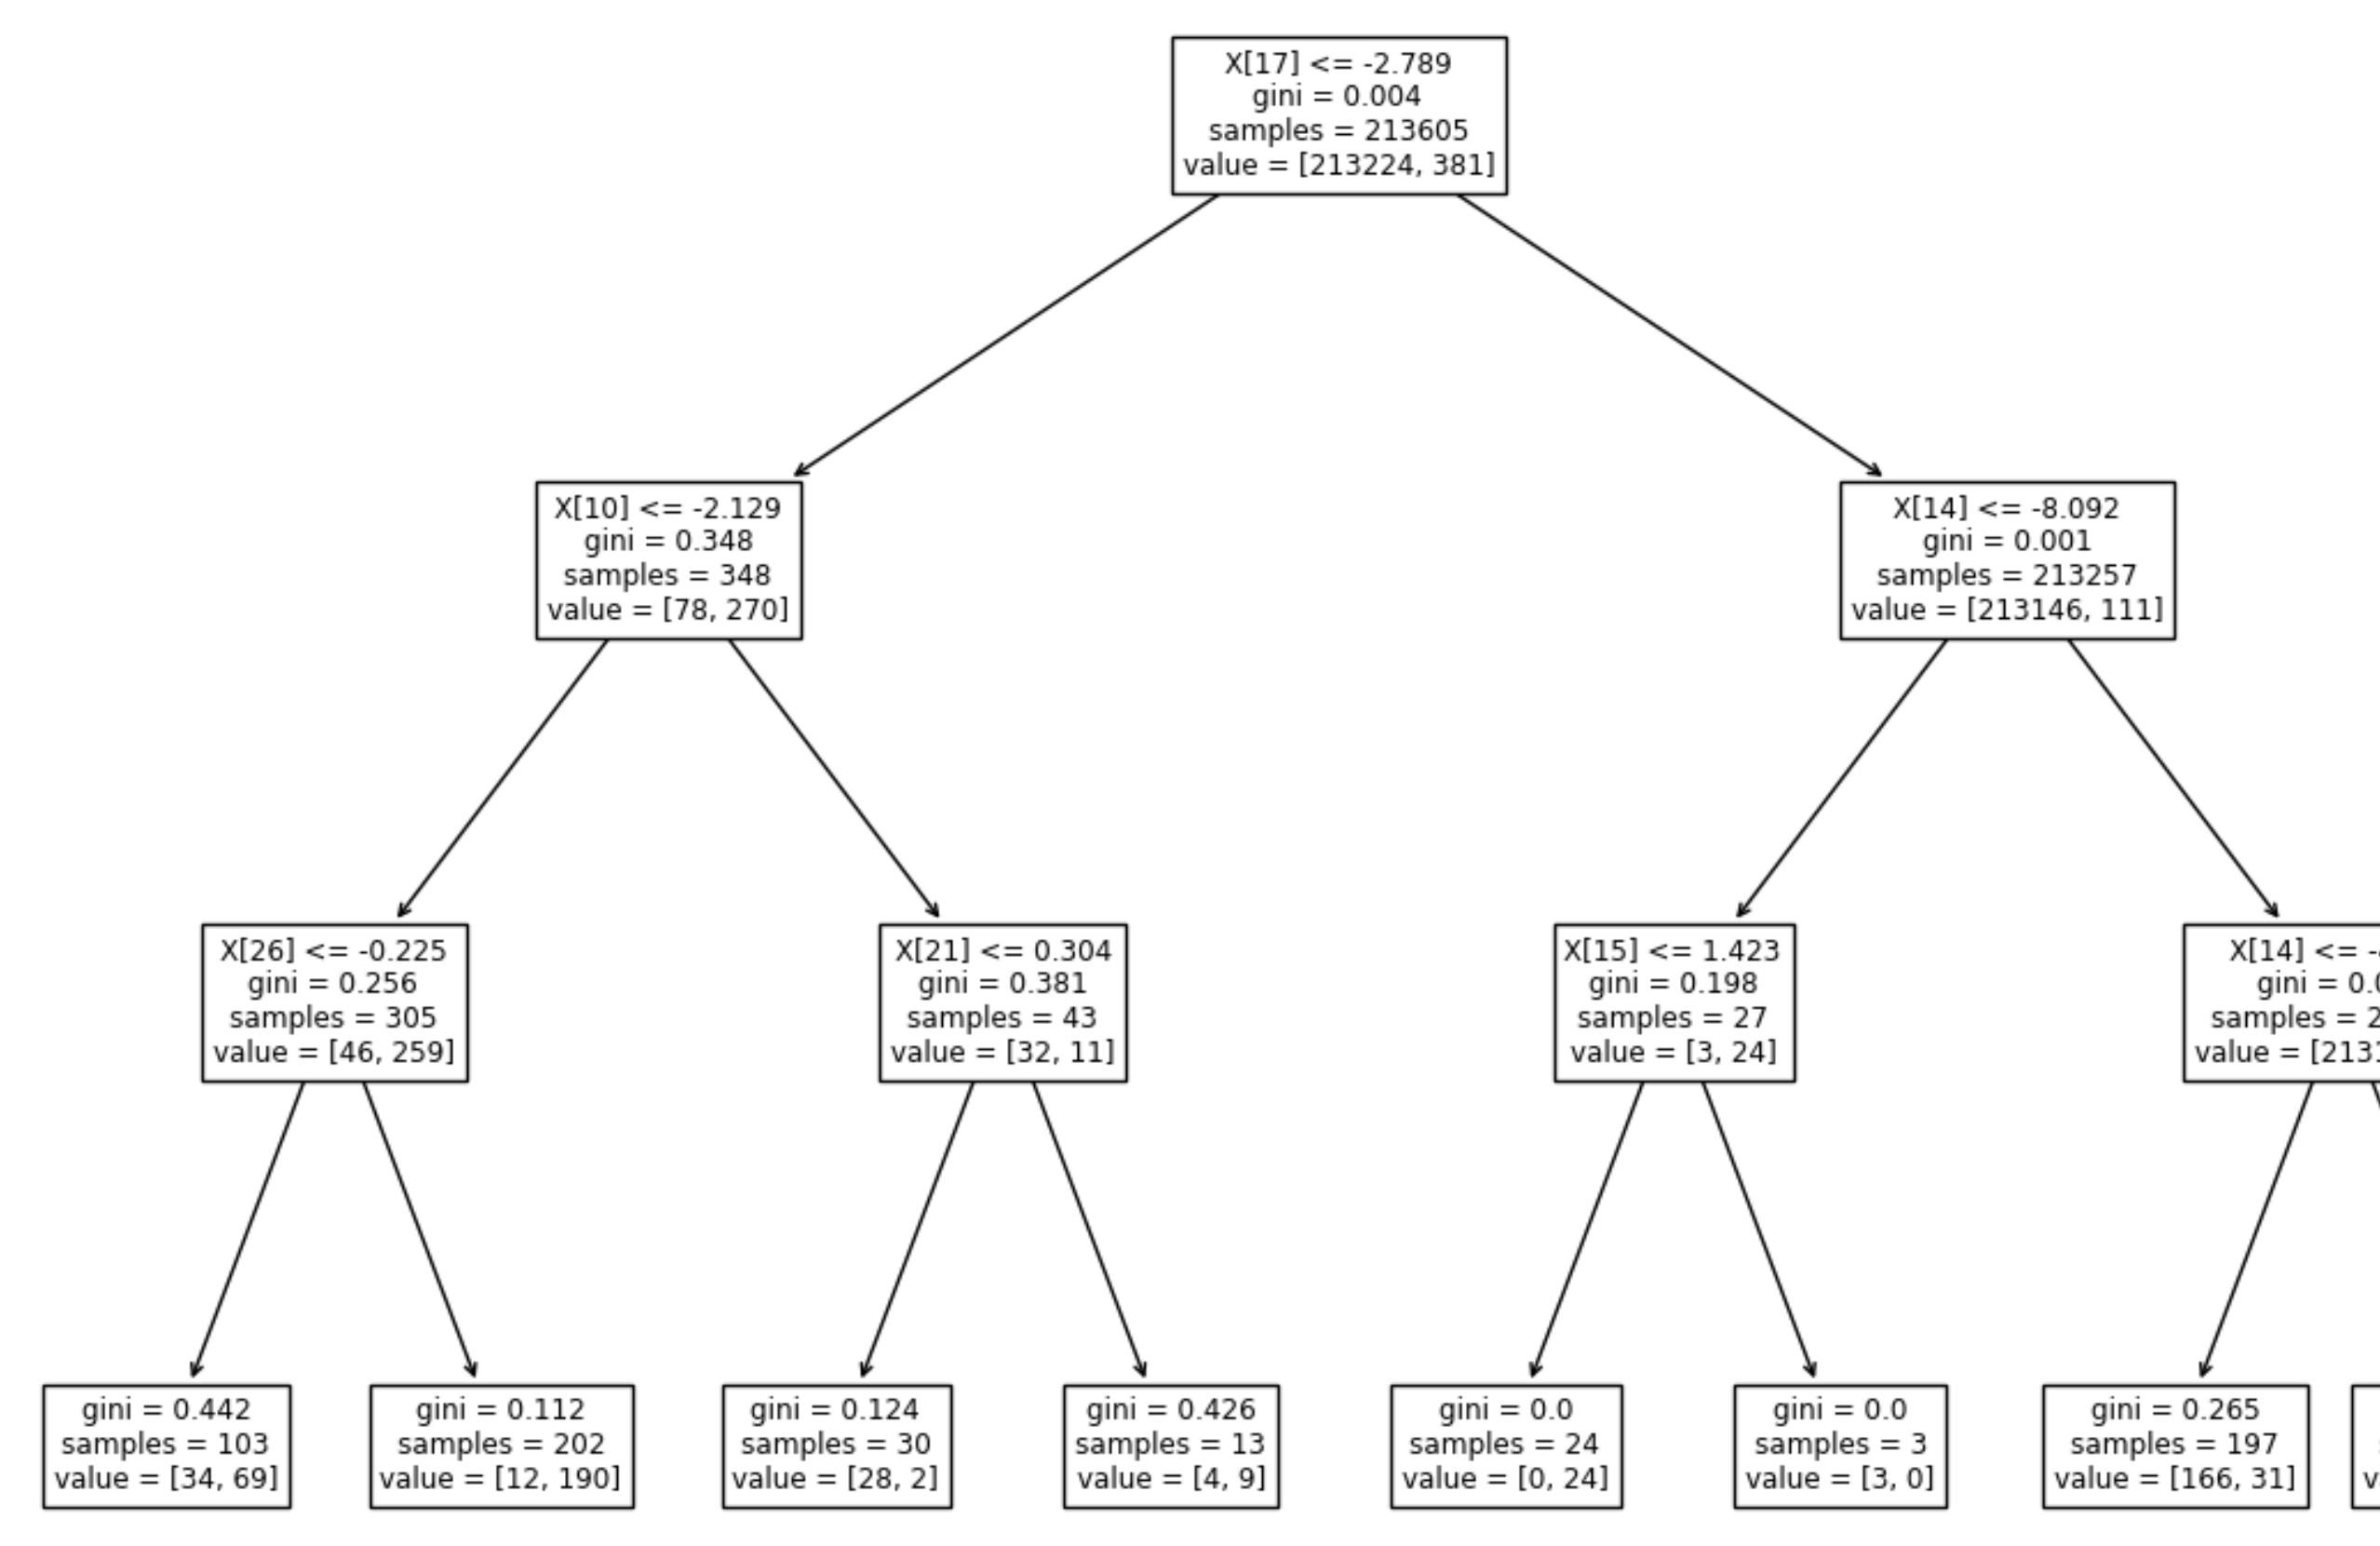
X[17] <= -2.789
gini = 0.004
samples = 213605
value = [213224, 381]
X[10] <= -2.129
gini = 0.348
samples = 348
value = [78, 270]
X[14] <= -8.092
gini = 0.001
samples = 213257
value = [213146, 111]
X[26] <= -0.225
gini = 0.256
samples = 305
value = [46, 259]
X[21] <= 0.304
gini = 0.381
samples = 43
value = [32, 11]
X[15] <= 1.423
gini = 0.198
samples = 27
value = [3, 24]
X[14] <= -4.661
gini = 0.001
samples = 213230
value = [213143, 87]
gini = 0.442
samples = 103
value = [34, 69]
gini = 0.112
samples = 202
value = [12, 190]
gini = 0.124
samples = 30
value = [28, 2]
gini = 0.426
samples = 13
value = [4, 9]
gini = 0.0
samples = 24
value = [0, 24]
gini = 0.0
samples = 3
value = [3, 0]
gini = 0.265
samples = 197
value = [166, 31]
gini = 0.001
samples = 213033
value = [212977, 56]

- Візуалізуємо дерево більш детально

```
In [14]: feature_cols_credit = [i for i in X.columns]

         dot_data_credit = StringIO()
         export_graphviz(clf, out_file = dot_data_credit,
                         feature_names = feature_cols_credit,
                         class_names = ["0", "1"],
                         filled = True, rounded = True,
                         special_characters = True)

         graph_credit = pydotplus.graph_from_dot_data(dot_data_credit.getvalue())
         graph_credit.write_png('lab1_credit.png')
         Image(graph_credit.create_png())
```

Out[14]:

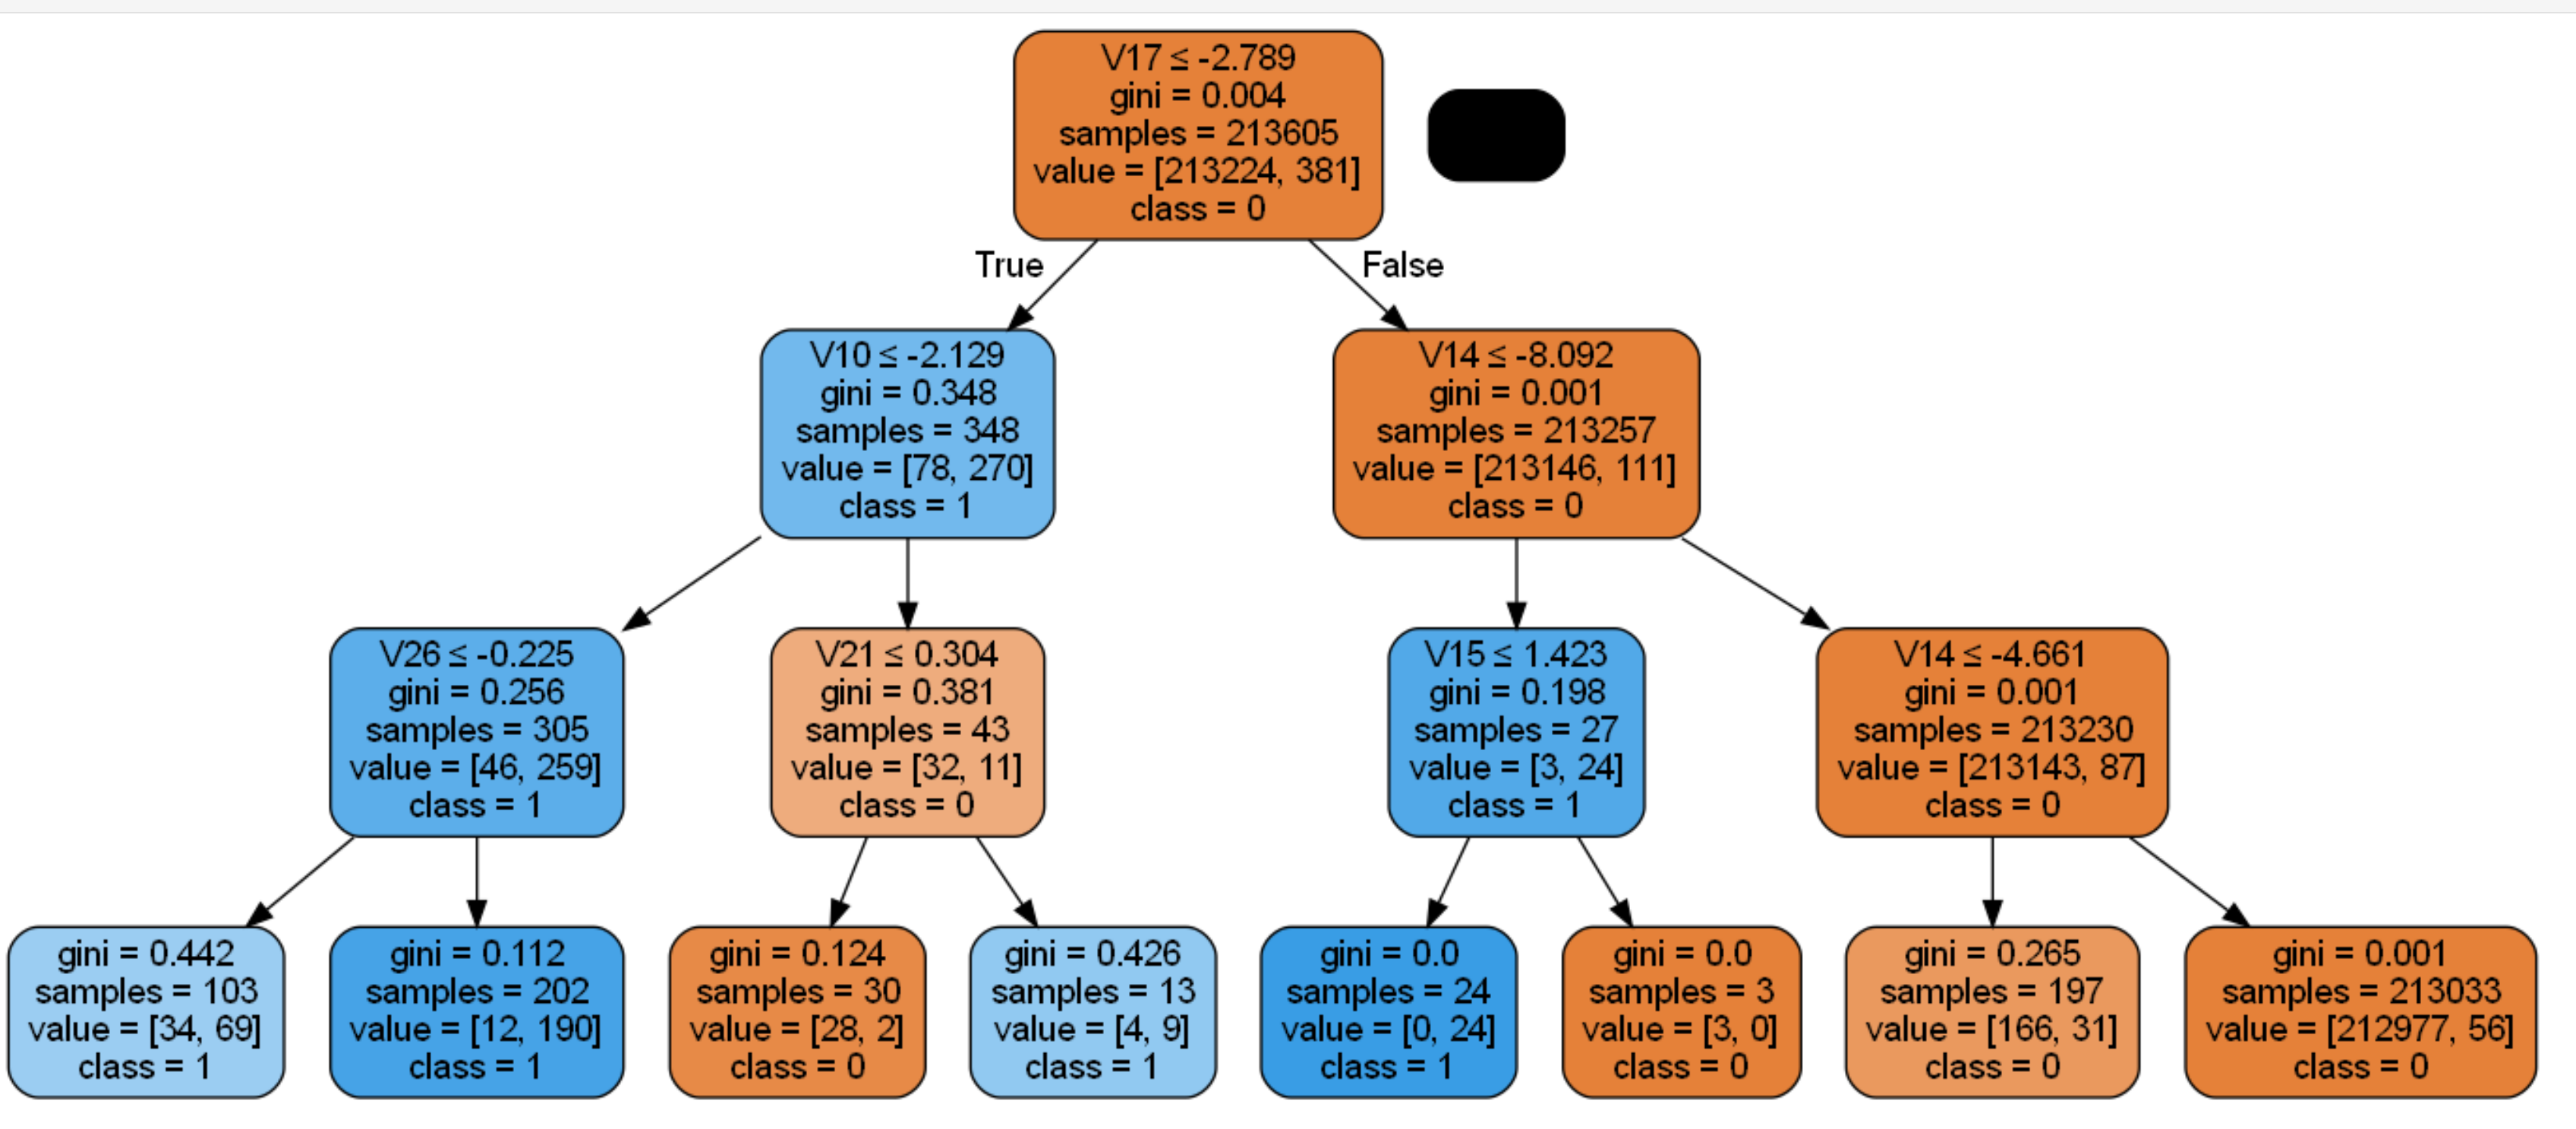
V17 ≤ -2.789
gini = 0.004
samples = 213605
value = [213224, 381]
class = 0
True
False
V10 ≤ -2.129
gini = 0.348
samples = 348
value = [78, 270]
class = 1
V14 ≤ -8.092
gini = 0.001
samples = 213257
value = [213146, 111]
class = 0
V26 ≤ -0.225
gini = 0.256
samples = 305
value = [46, 259]
class = 1
V21 ≤ 0.304
gini = 0.381
samples = 43
value = [32, 11]
class = 0
V15 ≤ 1.423
gini = 0.198
samples = 27
value = [3, 24]
class = 1
V14 ≤ -4.661
gini = 0.001
samples = 213230
value = [213143, 87]
class = 0
gini = 0.442
samples = 103
value = [34, 69]
class = 1
gini = 0.112
samples = 202
value = [12, 190]
class = 1
gini = 0.124
samples = 30
value = [28, 2]
class = 0
gini = 0.426
samples = 13
value = [4, 9]
class = 1
gini = 0.0
samples = 24
value = [0, 24]
class = 1
gini = 0.0
samples = 3
value = [3, 0]
class = 0
gini = 0.265
samples = 197
value = [166, 31]
class = 0
gini = 0.001
samples = 213033
value = [212977, 56]
class = 0

[redacted]

''' %matplotlib inline feature_cols_credit = [i for i in X.columns] dot_data_credit = tree.export_graphviz(clf, out_file = None, feature_names = feature_cols_credit, class_names = ["0", "1"], filled = True, rounded = True, special_characters = True) graph_credit = graphviz.Source(dot_data_credit) graph_credit.save('lab1_credit.png') graph_credit '''

Розглянемо тепер інший датасет

- Імпортуємо необхідні бібліотеки

```
In [15]: from sklearn.datasets import load_iris
         from sklearn.tree import DecisionTreeClassifier
         from sklearn.tree import export_text
```

- Будемо розглядати датасет **iris**. Далі визначаємо ознаки та цільову змінну. Виведемо датасет у формі датафрейму

```
In [16]: iris = load_iris()
```

```
In [17]: X2, y2 = iris.data, iris.target
```

```
In [18]: # dfIris = pd.DataFrame(data = np.c_[iris['data'], iris['target']], columns = iris['feature_names'] + ['target'])
         dfIris = pd.DataFrame(data = np.c_[X2, y2], columns = iris['feature_names'] + ['target'])
         dfIris
```

Out[18]:

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	target
0	5.1	3.5	1.4	0.2	0.0
1	4.9	3.0	1.4	0.2	0.0
2	4.7	3.2	1.3	0.2	0.0
3	4.6	3.1	1.5	0.2	0.0
4	5.0	3.6	1.4	0.2	0.0
...	...	...	...	...	...
145	6.7	3.0	5.2	2.3	2.0
146	6.3	2.5	5.0	1.9	2.0
147	6.5	3.0	5.2	2.0	2.0
148	6.2	3.4	5.4	2.3	2.0
149	5.9	3.0	5.1	1.8	2.0

150 rows × 5 columns

Класи розглянутих об'єктів:

```
In [19]: print(iris['target_names'])

['setosa' 'versicolor' 'virginica']
```

```
In [20]: print(dfIris['target'].unique())

[0. 1. 2.]
```

- Ділимо вибірку на навчальну і тестову. Виведемо їх розмірності.

```
In [21]: X2_train, X2_test, y2_train, y2_test = \
                         train_test_split(X2, y2, test_size = 0.25, random_state = 1) # 75% training and 25% test
         print(X2_train.shape, X2_test.shape)
         print(y2_train.shape, y2_test.shape)

(112, 4) (38, 4)
(112,) (38,)
```

- Створюємо об'єкт класифікатора дерева рішень. За замовчуванням у класифікатора стоїть критерій *gini* (default="gini"), тому можна не вказувати його. Максимальна глибина дерева буде 3.
- Створюємо класифікатор дерева прийняття рішень для тренувань.
- Робимо прогноз на тестовому наборі даних.

```
In [22]: clf2 = DecisionTreeClassifier(random_state=0, max_depth=3)
         clf2 = clf2.fit(X2_train, y2_train)
         y2_pred = clf2.predict(X2_test)
```

- Перевіряємо результати роботи на тестовій вибірці за допомогою точності моделі (як часто класифікатор є правильним):

```
In [23]: y2_pred = clf2.predict(X2_test)
         print("Оцінка тестового набору даних: ", metrics.accuracy_score(y2_test, y2_pred))

Оцінка тестового набору даних:  0.9736842105263158
```

- Виводимо на екран дерево прийняття рішень:

```
In [24]: #plt.figure(figsize=(10,9))
         #tree.plot_tree(clf2.fit(X2_train, y2_train))
         #plt.title("Дерево прийняття рішень (decision tree)")
```

```
In [25]: decision_tree_iris = clf2
         tx = export_text(decision_tree_iris, feature_names=iris['feature_names'])
         print(tx)

|--- petal width (cm) <= 0.80
|   |--- class: 0
|--- petal width (cm) >  0.80
|   |--- petal width (cm) <= 1.65
|   |   |--- petal length (cm) <= 4.95
|   |   |   |--- class: 1
|   |   |--- petal length (cm) >  4.95
|   |   |   |--- class: 2
|   |--- petal width (cm) >  1.65
|   |   |--- petal length (cm) <= 4.85
|   |   |   |--- class: 2
|   |   |--- petal length (cm) >  4.85
|   |   |   |--- class: 2
```

```
In [26]: dot_data = tree.export_graphviz(clf2, out_file = None,
                             feature_names = iris.feature_names,
                             class_names = ["0", "1", "2"],
                             filled = True, rounded = True,
                             special_characters = True)
         graph = graphviz.Source(dot_data)
         #graph.save('lab1_iris.png')
         graph.render("lab1_iris")
         graph
```

Out[26]:

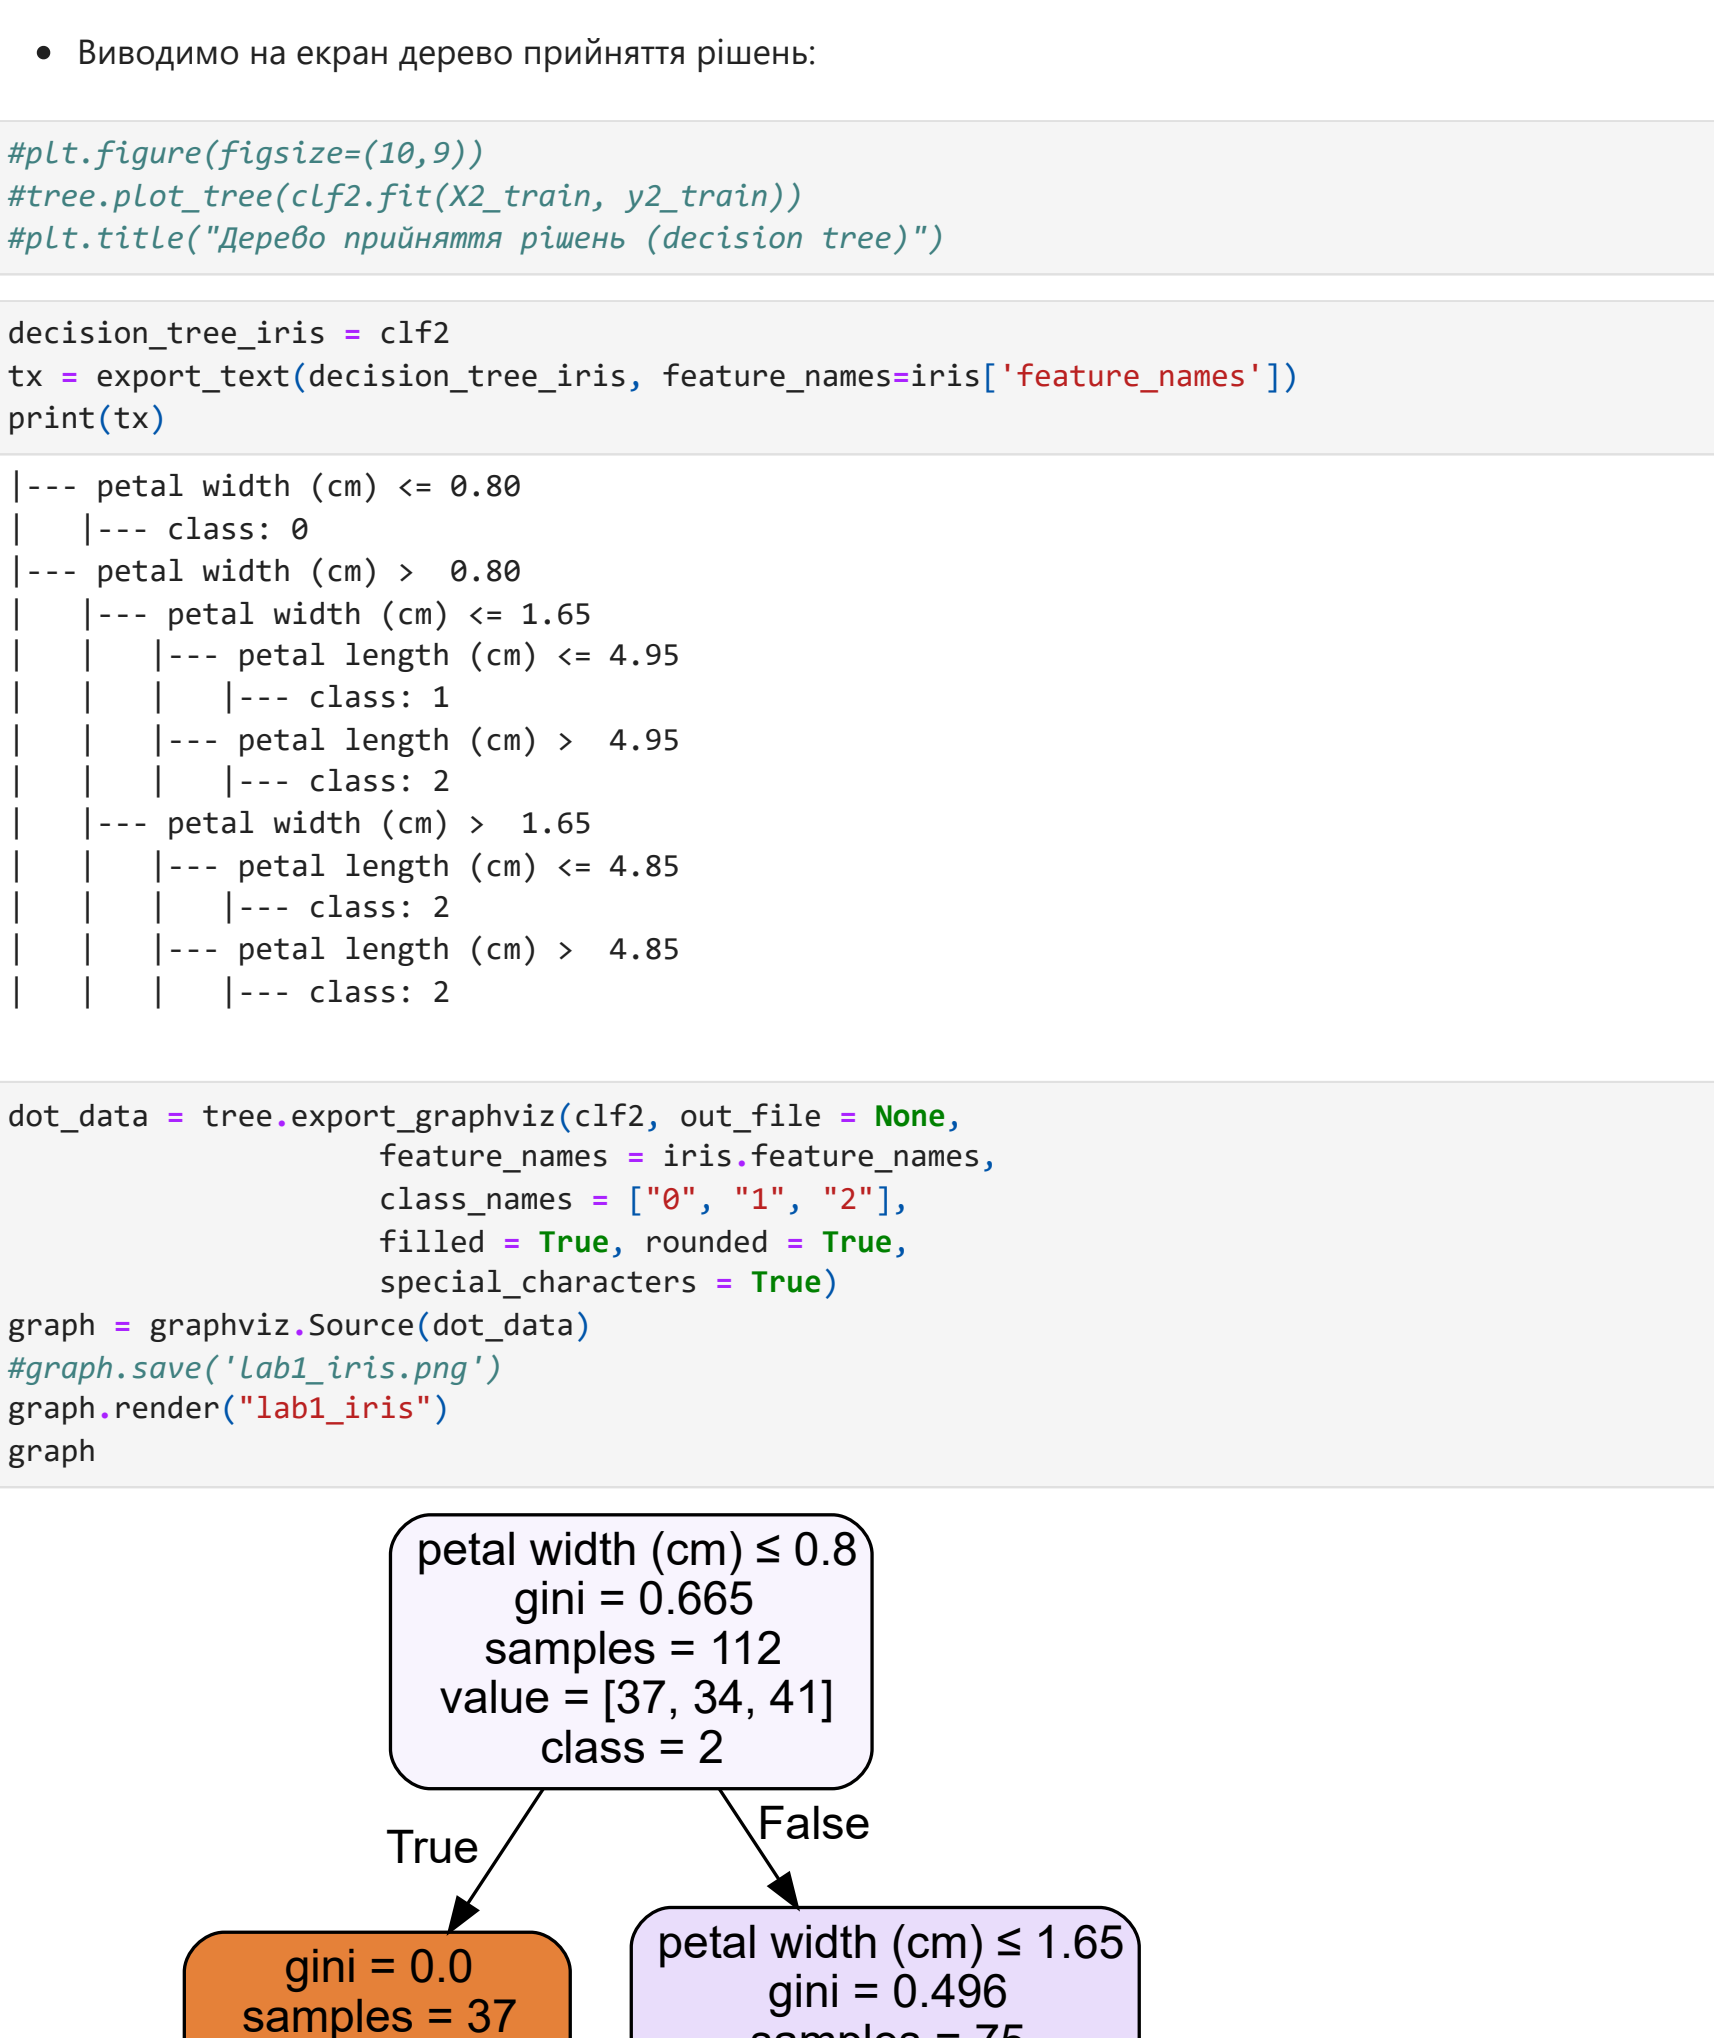
petal width (cm) ≤ 0.8
gini = 0.665
samples = 112
value = [37, 34, 41]
class = 2
True
False
gini = 0.0
samples = 37
value = [37, 0, 0]
class = 0
petal width (cm) ≤ 1.65
gini = 0.496
samples = 75
value = [0, 34, 41]
class = 2
petal length (cm) ≤ 4.95
gini = 0.193
samples = 37
value = [0, 33, 4]
class = 1
petal length (cm) ≤ 4.85
gini = 0.051
samples = 38
value = [0, 1, 37]
class = 2
gini = 0.0
samples = 32
value = [0, 32, 0]
class = 1
gini = 0.32
samples = 5
value = [0, 1, 4]
class = 2
gini = 0.375
samples = 4
value = [0, 1, 3]
class = 2
gini = 0.0
samples = 34
value = [0, 0, 34]
class = 2

- Наступний варіант з назвами класів ірисів.

```
In [27]: dot_data2 = tree.export_graphviz(clf2, out_file = None,
                             feature_names = iris.feature_names,
                             class_names = iris.target_names,
                             filled = True, rounded = True,
                             special_characters = True)
         graph2 = graphviz.Source(dot_data2)
         #graph2.save('lab1_iris_classColors.jpg')
         graph2.render("lab1_iris_classColors")
         graph2
```

Out[27]:

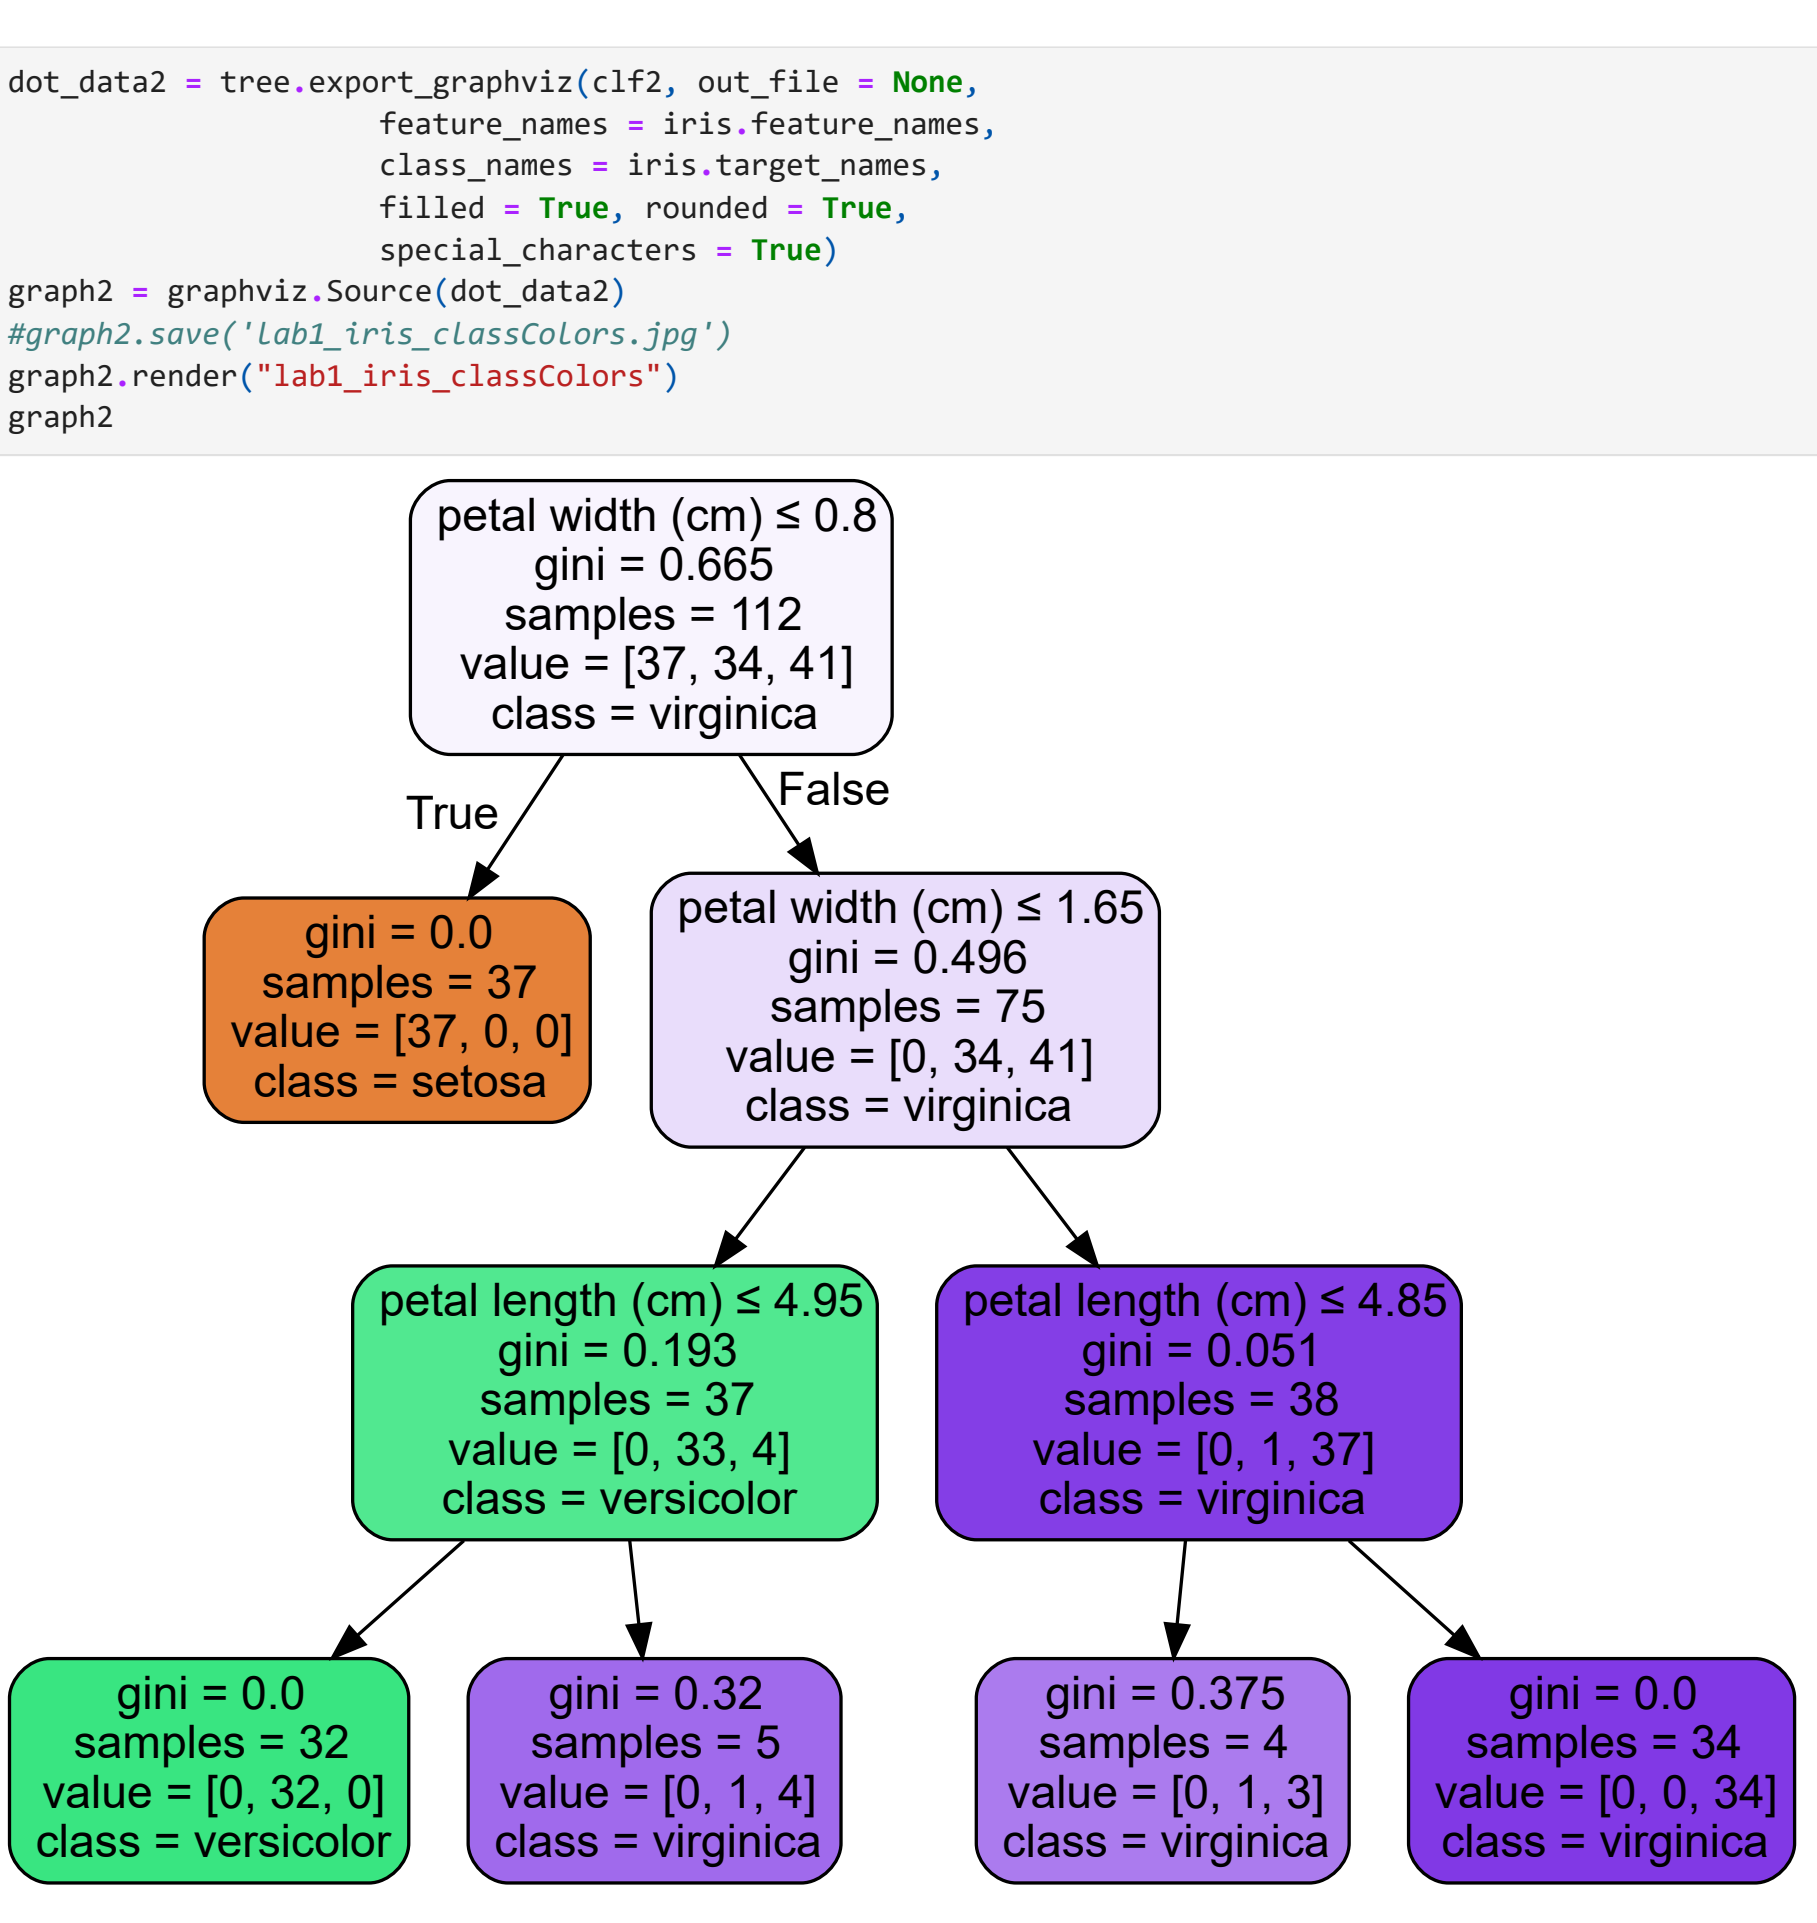
petal width (cm) ≤ 0.8
gini = 0.665
samples = 112
value = [37, 34, 41]
class = virginica
True
False
gini = 0.0
samples = 37
value = [37, 0, 0]
class = setosa
petal width (cm) ≤ 1.65
gini = 0.496
samples = 75
value = [0, 34, 41]
class = virginica
petal length (cm) ≤ 4.95
gini = 0.193
samples = 37
value = [0, 33, 4]
class = versicolor
petal length (cm) ≤ 4.85
gini = 0.051
samples = 38
value = [0, 1, 37]
class = virginica
gini = 0.0
samples = 32
value = [0, 32, 0]
class = versicolor
gini = 0.32
samples = 5
value = [0, 1, 4]
class = virginica
gini = 0.375
samples = 4
value = [0, 1, 3]
class = virginica
gini = 0.0
samples = 34
value = [0, 0, 34]
class = virginica

''' dot_data = StringIO() export_graphviz(clf2, out_file = None, feature_names = iris.feature_names, class_names = ["0", "1", "2"], filled = True, rounded = True, special_characters = True) graph = pydotplus.graph_from_dot_data(dot_data.getvalue()) graph.write_png('lab1_iris.png') Image(graph.create_png()) '''

```
In [ ]:
```

Машинне навчання

Метод дерева прийняття рішень (decision tree)

Лабораторна робота 2

Студентка Пороскун Олена. Група ПМ.м-21

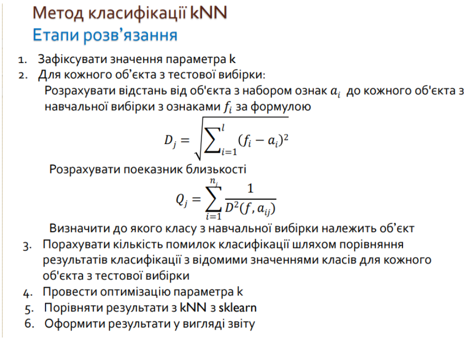

Метод класифікації kNN

Етапи розв’язання

1. Зафіксувати значення параметра k
2. Для кожного об’єкта з тестової вибірки:

   Розрахувати відстань від об'єкта з набором ознак a_i до кожного об'єкта з навчальної вибірки з ознаками f_i за формулою

   $$D_j = \sqrt{\sum_{i=1}^{l} (f_i - a_i)^2}$$

   Розрахувати поеказник близькості

   $$Q_j = \sum_{i=1}^{n_j} \frac{1}{D^2(f, a_{ij})}$$

   Визначити до якого класу з навчальної вибірки належить об’єкт
3. Порахувати кількість помилок класифікації шляхом порівняння результатів класифікації з відомими значеннями класів для кожного об'єкта з тестової вибірки
4. Провести оптимізацію параметра k
5. Порівняти результати з kNN з sklearn
6. Оформити результати у вигляді звіту

1.1.5 Численний приклад

Розглянемо простий численний приклад роботи алгоритму KNN, проілюстрований на рисунку 2.2. Нехай є набір даних про позичальників банку частина з яких допустили прострочення платежу (таблиця). Ознаками є вік та середньомісячний дохід. Мітками класу в полі “Прострочено” будуть “Так” та “Ні”.

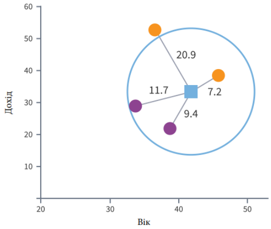

X_1 – вік	X_2 – дохід	Прострочено
46	40	Ні
36	54	Ні
34	29	Так
38	23	Так

Робота алгоритму KNN

На рисунку помаранчевими кружками представлені об’єкти класу “Ні”, а фіолетовими класу “Так”. Синім квадратом відображається об’єкт, що класифікується (новий позичальник).

Завдання полягає в тому, щоб виконати класифікацію нового позичальника для якого $a_1 = 42$ і $a_2 = 34$ з метою оцінити можливість прострочення ним платежів.

1. Задамо значення параметра $k = 3$
2. Розрахуємо відстань між вектором ознак об’єкта, що класифікується, і векторами навчальних прикладів за формулою (1.1) та встановимо для кожного прикладу його ранг.

X_1 – вік	X_2 – дохід	Відстань	Ранг	Сусід	Прострочено
46	40	7.2	1	Так	Ні
36	54	20.9	4	Ні	Ні
34	29	9.4	2	Так	Так
38	23	11.7	3	Так	Так

3. Виключимо з розгляду приклад, який при $k = 3$ не є сусідом

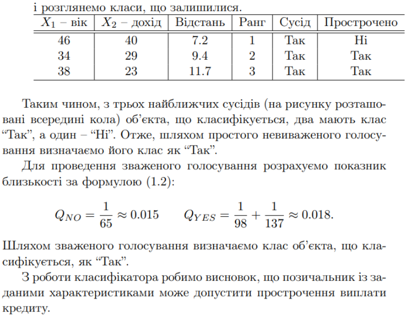

і розглянемо класи, що залишилися.

X_1 – вік	X_2 – дохід	Відстань	Ранг	Сусід	Прострочено
46	40	7.2	1	Так	Ні
34	29	9.4	2	Так	Так
38	23	11.7	3	Так	Так

Таким чином, з трьох найближчих сусідів (на рисунку розташовані всередині кола) об'єкта, що класифікується, два мають клас "Так", а один – "Ні". Отже, шляхом простого невиваженого голосування визначаємо його клас як "Так".

Для проведення зваженого голосування розрахуємо показник близькості за формулою (1.2):

$$Q_{NO} = \frac{1}{65} \approx 0.015 \qquad Q_{YES} = \frac{1}{98} + \frac{1}{137} \approx 0.018.$$

Шляхом зваженого голосування визначаємо клас об'єкта, що класифікується, як "Так".

З роботи класифікатора робимо висновок, що позичальник із заданими характеристиками може допустити прострочення виплати кредиту.

- Імпортуємо потрібні бібліотеки

In [1]:
```
# import warnings filter
from warnings import simplefilter
# ignore all future warnings
simplefilter(action='ignore', category=FutureWarning)
```

In [2]:
```
import numpy as np
import pandas as pd
import seaborn as sns
from matplotlib import pyplot as plt
```

In [3]:
```
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
```

- Розглянемо датасет з ірисами. Створимо датафрейм з нього.

In [4]:
```
iris = load_iris()
X, y = iris.data, iris.target
```

In [5]:
```
# dfIris = pd.DataFrame(data = np.c_[iris['data'], iris['target']], columns = iris['feature_names'] + ['target'])
dfIris = pd.DataFrame(data = np.c_[X, y], columns = iris['feature_names'] + ['target'])
dfIris
```

Out[5]:

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	target
0	5.1	3.5	1.4	0.2	0.0
1	4.9	3.0	1.4	0.2	0.0
2	4.7	3.2	1.3	0.2	0.0
3	4.6	3.1	1.5	0.2	0.0
4	5.0	3.6	1.4	0.2	0.0
...	...	...	...	...	...
145	6.7	3.0	5.2	2.3	2.0
146	6.3	2.5	5.0	1.9	2.0
147	6.5	3.0	5.2	2.0	2.0
148	6.2	3.4	5.4	2.3	2.0
149	5.9	3.0	5.1	1.8	2.0

150 rows × 5 columns

In [6]:
```
print(iris['target_names'])
```
```
['setosa' 'versicolor' 'virginica']
```

In [7]:
```
print(dfIris['target'].unique())
```
```
[0. 1. 2.]
```

- Покажемо на графіках пари відповідних параметрів і значення цільовох функції.

In [8]:
```
sns.scatterplot(x = dfIris['sepal length (cm)'], y = dfIris['sepal width (cm)'], hue = dfIris['target'])
#plt.legend(bbox_to_anchor=(1,1), loc="upper left")
```

Out[8]:
```
<AxesSubplot:xlabel='sepal length (cm)', ylabel='sepal width (cm)'>
```

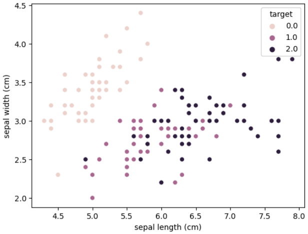

In [9]:
```
sns.scatterplot(x = dfIris['petal length (cm)'], y = dfIris['petal width (cm)'], hue = dfIris['target'])
```

Out[9]:
```
<AxesSubplot:xlabel='petal length (cm)', ylabel='petal width (cm)'>
```

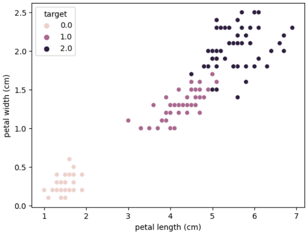

- Розділимо вибірку на навчальну і тестову.

```
In [10]: X_train, X_test, y_train, y_test = \
                         train_test_split(X, y, test_size = 0.25, random_state = 1) # 75% training and 25% test
         #print(X_train.shape, X_test.shape)
         #print(y_train.shape, y_test.shape)
```

- Далі потрібно знайти відстані за відповідними формулами. Також створимо ще навчальний і тестовий датафрейм.

```
In [11]: # знаходимо відстані між одним тестовим об'ктом (j) і всіма навчальними (0,...,len(X_train))
         def fun_distance(X_train, X_test, j):
             n_train = len(X_train)
             distances = [np.linalg.norm(X_train[i] - X_test[j]) for i in range(n_train)]
             return distances
```

```
In [12]: def fun_df(X_train, X_test, y_train, y_test):
             print('df_test(наприклад, перший):')
             df_test = pd.DataFrame(data = np.c_[X_test, y_test], columns = ['x1','x2','x3','x4',] + ['y'])
             display(df_test.head(1))

             print('\ndf_train(перші 5 рядків):')
             df_train = pd.DataFrame(data = np.c_[X_train, y_train], columns = ['x1','x2','x3','x4',] + ['y'])
             display(df_train.head())

             return df_test, df_train

         df_test, df_train = fun_df(X_train, X_test, y_train, y_test)
```

```
df_test(наприклад, перший):
```

	x1	x2	x3	x4	y
0	5.8	4.0	1.2	0.2	0.0

```
df_train(перші 5 рядків):
```

	x1	x2	x3	x4	y
0	6.5	2.8	4.6	1.5	1.0
1	6.7	2.5	5.8	1.8	2.0
2	6.8	3.0	5.5	2.1	2.0
3	5.1	3.5	1.4	0.3	0.0
4	6.0	2.2	5.0	1.5	2.0

- Для проведення зваженого голосування розрахуємо показник близькості **Q**.

```
In [13]: def fun_Q(df_sort, clas):
             y = df_sort.query('`y` == @clas')

             if y.shape[0] == 0:
                 Q = 0
             else:
                 y['distances^2'] = (y['distances'])**2
                 Q = 1 / y['distances^2']
                 Q = Q.sum()

             #print('Q_{0:.0f} = {1}'.format(clas, Q))
             return clas, Q
```

- Тепер визначимо клас конкретного тестового об'єкта.

```
In [14]: def fun_Class(distances, df_train, k):
             # df_test = pd.DataFrame(data = np.c_[X_test, y_test], columns = ['x1','x2','x3','x4',] + ['y'])

             # df_train = pd.DataFrame(data = np.c_[X_train, y_train], columns = ['x1','x2','x3','x4',] + ['y'])
             df_train['distances'] = distances
             display(df_train.head())

             # df_sort
             df_sort = df_train.sort_values(by=['distances'])
             display(df_sort.head())

             print('\nk сусідів =',k)
             df_sort = df_sort.head(k)
             display(df_sort.head())

             classes = df_train['y'].unique()
             classes.sort()
             #print('classes =', classes)

             Q, Class = [], []
             for i in classes:
                 cl, q = fun_Q(df_sort, clas=i)
                 Q.append(q)
                 Class.append(cl)

             df_new = pd.DataFrame(data = np.c_[Class, Q], columns = ['class', 'Q'])
             display(df_new)

             answer = df_new[ df_new['Q'] == df_new['Q'].max() ]
             answer = answer['class'].values
             answer = int(answer[0])

             namees_class = iris['target_names']
             print('class prediction: ', answer, '-', namees_class[answer])

             return answer
```

- **Виконаємо всі дії за алгоритмом для кожного тестового об'єкта по черзі і продемонструємо їх.**

In [15]:

```python
k_neighbours = 3
y_pred = []
for j_test in range(len(X_test)):
    print("----", j_test+1, " тестовий об`єкт ----")
    distances = fun_distance(X_train, X_test, j=j_test)
    y_pr = fun_Class(distances, df_train, k=k_neighbours)
    y_pred.append(y_pr)
    print("y_test =", y_test[j_test], '\n\n')
```

```
---- 1  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	3.896152
1	6.7	2.5	5.8	1.8	2.0	5.174940
2	6.8	3.0	5.5	2.1	2.0	4.909175
3	5.1	3.5	1.4	0.3	0.0	0.888819
4	6.0	2.2	5.0	1.5	2.0	4.405678

	x1	x2	x3	x4	y	distances
62	5.7	4.4	1.5	0.4	0.0	0.547723
8	5.7	3.8	1.7	0.3	0.0	0.556776
42	5.4	3.7	1.5	0.2	0.0	0.583095
13	5.5	3.5	1.3	0.2	0.0	0.591608
44	5.2	4.1	1.5	0.1	0.0	0.685565

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
62	5.7	4.4	1.5	0.4	0.0	0.547723
8	5.7	3.8	1.7	0.3	0.0	0.556776
42	5.4	3.7	1.5	0.2	0.0	0.583095

	class	Q
0	0.0	9.500316
1	1.0	0.000000
2	2.0	0.000000

```
class prediction:  0 - setosa
y_test = 0


---- 2  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	2.184033
1	6.7	2.5	5.8	1.8	2.0	3.300000
2	6.8	3.0	5.5	2.1	2.0	3.223352
3	5.1	3.5	1.4	0.3	0.0	2.049390
4	6.0	2.2	5.0	1.5	2.0	2.249444

	x1	x2	x3	x4	y	distances
91	4.9	2.4	3.3	1.0	1.0	0.387298
39	5.0	2.3	3.3	1.0	1.0	0.387298
88	5.0	2.0	3.5	1.0	1.0	0.721110
106	5.7	2.6	3.5	1.0	1.0	0.793725
87	5.5	2.4	3.7	1.0	1.0	0.818535

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
91	4.9	2.4	3.3	1.0	1.0	0.387298
39	5.0	2.3	3.3	1.0	1.0	0.387298
88	5.0	2.0	3.5	1.0	1.0	0.721110

	class	Q
0	0.0	0.00000
1	1.0	15.25641
2	2.0	0.00000

```
class prediction:  1 - versicolor
y_test = 1


---- 3  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	0.316228
1	6.7	2.5	5.8	1.8	2.0	1.542725
2	6.8	3.0	5.5	2.1	2.0	1.319091
3	5.1	3.5	1.4	0.3	0.0	3.565109
4	6.0	2.2	5.0	1.5	2.0	1.170470

	x1	x2	x3	x4	y	distances
31	6.7	3.1	4.4	1.4	1.0	0.141421
6	6.6	2.9	4.6	1.3	1.0	0.244949
37	6.4	2.9	4.3	1.3	1.0	0.264575
0	6.5	2.8	4.6	1.5	1.0	0.316228
96	6.7	3.1	4.7	1.5	1.0	0.346410

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
31	6.7	3.1	4.4	1.4	1.0	0.141421
6	6.6	2.9	4.6	1.3	1.0	0.244949
37	6.4	2.9	4.3	1.3	1.0	0.264575

	class	Q
0	0.0	0.000000
1	1.0	80.952381
2	2.0	0.000000

```
class prediction:  1 - versicolor
y_test = 1


---- 4  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	3.810512
1	6.7	2.5	5.8	1.8	2.0	5.085273

2	6.8	3.0	5.5	2.1	2.0	4.827007
3	5.1	3.5	1.4	0.3	0.0	0.519615
4	6.0	2.2	5.0	1.5	2.0	4.260282

	x1	x2	x3	x4	y	distances
42	5.4	3.7	1.5	0.2	0.0	0.346410
75	5.1	3.7	1.5	0.4	0.0	0.412311
13	5.5	3.5	1.3	0.2	0.0	0.458258
44	5.2	4.1	1.5	0.1	0.0	0.458258
35	5.1	3.8	1.6	0.2	0.0	0.479583

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
42	5.4	3.7	1.5	0.2	0.0	0.346410
75	5.1	3.7	1.5	0.4	0.0	0.412311
13	5.5	3.5	1.3	0.2	0.0	0.458258

	class	Q
0	0.0	18.977591
1	1.0	0.000000
2	2.0	0.000000

```
class prediction:  0 - setosa
y_test = 0


---- 5  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	2.539685
1	6.7	2.5	5.8	1.8	2.0	1.878829
2	6.8	3.0	5.5	2.1	2.0	1.634013
3	5.1	3.5	1.4	0.3	0.0	5.984981
4	6.0	2.2	5.0	1.5	2.0	2.894823

	x1	x2	x3	x4	y	distances
14	7.7	3.8	6.7	2.2	2.0	0.412311
56	7.6	3.0	6.6	2.1	2.0	0.883176
60	7.2	3.6	6.1	2.5	2.0	0.932738
20	7.7	2.8	6.7	2.0	2.0	1.063015
16	7.3	2.9	6.3	1.8	2.0	1.104536

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
14	7.7	3.8	6.7	2.2	2.0	0.412311
56	7.6	3.0	6.6	2.1	2.0	0.883176
60	7.2	3.6	6.1	2.5	2.0	0.932738

	class	Q
0	0.0	0.00000
1	1.0	0.00000
2	2.0	8.31383

```
class prediction:  2 - virginica
y_test = 2


---- 6  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	0.556776
1	6.7	2.5	5.8	1.8	2.0	1.431782
2	6.8	3.0	5.5	2.1	2.0	1.109054
3	5.1	3.5	1.4	0.3	0.0	3.749667
4	6.0	2.2	5.0	1.5	2.0	1.183216

	x1	x2	x3	x4	y	distances
19	6.0	3.4	4.5	1.6	1.0	0.374166
29	6.1	3.0	4.9	1.8	2.0	0.458258
96	6.7	3.1	4.7	1.5	1.0	0.458258
76	5.9	3.2	4.8	1.8	1.0	0.469042
34	6.0	3.0	4.8	1.8	2.0	0.479583

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
19	6.0	3.4	4.5	1.6	1.0	0.374166
29	6.1	3.0	4.9	1.8	2.0	0.458258
96	6.7	3.1	4.7	1.5	1.0	0.458258

```
C:\Users\Admin\AppData\Local\Temp\ipykernel_9888\151950262.py:7: SettingWithCopyWarning: 
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
  y['distances^2'] = (y['distances'])**2
C:\Users\Admin\AppData\Local\Temp\ipykernel_9888\151950262.py:7: SettingWithCopyWarning: 
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
  y['distances^2'] = (y['distances'])**2
```

	class	Q
0	0.0	0.000000
1	1.0	11.904762
2	2.0	4.761905

```
class prediction:  1 - versicolor
y_test = 1


---- 7  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	1.067708
1	6.7	2.5	5.8	1.8	2.0	1.067708
2	6.8	3.0	5.5	2.1	2.0	0.469042
3	5.1	3.5	1.4	0.3	0.0	4.592385

4	6.0	2.2	5.0	1.5	2.0	1.506652

	x1	x2	x3	x4	y	distances
57	6.7	3.0	5.2	2.3	2.0	0.244949
15	6.9	3.1	5.4	2.1	2.0	0.360555
2	6.8	3.0	5.5	2.1	2.0	0.469042
30	6.5	3.2	5.1	2.0	2.0	0.509902
80	6.5	3.0	5.2	2.0	2.0	0.519615

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
57	6.7	3.0	5.2	2.3	2.0	0.244949
15	6.9	3.1	5.4	2.1	2.0	0.360555
2	6.8	3.0	5.5	2.1	2.0	0.469042

	class	Q
0	0.0	0.000000
1	1.0	0.000000
2	2.0	28.904429

```
class prediction:  2 - virginica
y_test = 2


---- 8  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	3.385262
1	6.7	2.5	5.8	1.8	2.0	4.628175
2	6.8	3.0	5.5	2.1	2.0	4.402272
3	5.1	3.5	1.4	0.3	0.0	0.591608
4	6.0	2.2	5.0	1.5	2.0	3.766962

	x1	x2	x3	x4	y	distances
35	5.1	3.8	1.6	0.2	0.0	0.360555
75	5.1	3.7	1.5	0.4	0.0	0.412311
69	5.0	3.5	1.6	0.6	0.0	0.479583
67	5.0	3.4	1.6	0.4	0.0	0.509902
70	4.8	3.4	1.9	0.2	0.0	0.538516

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
35	5.1	3.8	1.6	0.2	0.0	0.360555
75	5.1	3.7	1.5	0.4	0.0	0.412311
69	5.0	3.5	1.6	0.6	0.0	0.479583

	class	Q
0	0.0	17.922487
1	1.0	0.000000
2	2.0	0.000000

```
class prediction:  0 - setosa
y_test = 0


---- 9  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	3.753665
1	6.7	2.5	5.8	1.8	2.0	4.968903
2	6.8	3.0	5.5	2.1	2.0	4.823899
3	5.1	3.5	1.4	0.3	0.0	0.547723
4	6.0	2.2	5.0	1.5	2.0	3.992493

	x1	x2	x3	x4	y	distances
79	4.8	3.1	1.6	0.2	0.0	0.141421
77	4.6	3.1	1.5	0.2	0.0	0.173205
22	4.8	3.4	1.6	0.2	0.0	0.223607
82	4.6	3.2	1.4	0.2	0.0	0.223607
43	4.9	3.1	1.5	0.2	0.0	0.244949

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
79	4.8	3.1	1.6	0.2	0.0	0.141421
77	4.6	3.1	1.5	0.2	0.0	0.173205
22	4.8	3.4	1.6	0.2	0.0	0.223607

	class	Q
0	0.0	103.333333
1	1.0	0.000000
2	2.0	0.000000

```
class prediction:  0 - setosa
y_test = 0


---- 10  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	1.473092
1	6.7	2.5	5.8	1.8	2.0	0.888819
2	6.8	3.0	5.5	2.1	2.0	0.360555
3	5.1	3.5	1.4	0.3	0.0	5.081338
4	6.0	2.2	5.0	1.5	2.0	1.714643

	x1	x2	x3	x4	y	distances
73	6.8	3.2	5.9	2.3	2.0	0.223607
110	6.7	3.1	5.6	2.4	2.0	0.264575
45	6.7	3.3	5.7	2.1	2.0	0.300000
33	6.7	3.3	5.7	2.5	2.0	0.300000
2	6.8	3.0	5.5	2.1	2.0	0.360555

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances

73	6.8	3.2	5.9	2.3	2.0	0.223607
110	6.7	3.1	5.6	2.4	2.0	0.264575
45	6.7	3.3	5.7	2.1	2.0	0.300000

	class	Q
0	0.0	0.000000
1	1.0	0.000000
2	2.0	45.396825

```
class prediction:  2 - virginica
y_test = 2


---- 11  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	1.009950
1	6.7	2.5	5.8	1.8	2.0	2.014944
2	6.8	3.0	5.5	2.1	2.0	1.964688
3	5.1	3.5	1.4	0.3	0.0	3.119295
4	6.0	2.2	5.0	1.5	2.0	1.044031

	x1	x2	x3	x4	y	distances
97	5.7	2.9	4.2	1.3	1.0	0.223607
41	5.5	2.5	4.0	1.3	1.0	0.300000
85	5.6	3.0	4.1	1.3	1.0	0.316228
32	5.7	2.8	4.5	1.3	1.0	0.331662
21	5.7	3.0	4.2	1.2	1.0	0.331662

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
97	5.7	2.9	4.2	1.3	1.0	0.223607
41	5.5	2.5	4.0	1.3	1.0	0.300000
85	5.6	3.0	4.1	1.3	1.0	0.316228

	class	Q
0	0.0	0.000000
1	1.0	41.111111
2	2.0	0.000000

```
class prediction:  1 - versicolor
y_test = 1


---- 12  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	3.469870
1	6.7	2.5	5.8	1.8	2.0	4.734976
2	6.8	3.0	5.5	2.1	2.0	4.483302
3	5.1	3.5	1.4	0.3	0.0	0.591608
4	6.0	2.2	5.0	1.5	2.0	3.917908

	x1	x2	x3	x4	y	distances
8	5.7	3.8	1.7	0.3	0.0	0.331662
42	5.4	3.7	1.5	0.2	0.0	0.346410
35	5.1	3.8	1.6	0.2	0.0	0.387298
75	5.1	3.7	1.5	0.4	0.0	0.412311
44	5.2	4.1	1.5	0.1	0.0	0.458258

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
8	5.7	3.8	1.7	0.3	0.0	0.331662
42	5.4	3.7	1.5	0.2	0.0	0.346410
35	5.1	3.8	1.6	0.2	0.0	0.387298

	class	Q
0	0.0	24.090909
1	1.0	0.000000
2	2.0	0.000000

```
class prediction:  0 - setosa
y_test = 0


---- 13  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	1.565248
1	6.7	2.5	5.8	1.8	2.0	0.714143
2	6.8	3.0	5.5	2.1	2.0	0.500000
3	5.1	3.5	1.4	0.3	0.0	5.266878
4	6.0	2.2	5.0	1.5	2.0	1.737815

	x1	x2	x3	x4	y	distances
73	6.8	3.2	5.9	2.3	2.0	0.412311
54	7.4	2.8	6.1	1.9	2.0	0.458258
2	6.8	3.0	5.5	2.1	2.0	0.500000
105	7.2	3.0	5.8	1.6	2.0	0.519615
45	6.7	3.3	5.7	2.1	2.0	0.538516

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
73	6.8	3.2	5.9	2.3	2.0	0.412311
54	7.4	2.8	6.1	1.9	2.0	0.458258
2	6.8	3.0	5.5	2.1	2.0	0.500000

	class	Q
0	0.0	0.000000
1	1.0	0.000000
2	2.0	14.644258

```
class prediction:  2 - virginica
y_test = 2
```

```
---- 14  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	0.424264
1	6.7	2.5	5.8	1.8	2.0	1.536229
2	6.8	3.0	5.5	2.1	2.0	1.249000
3	5.1	3.5	1.4	0.3	0.0	3.581899
4	6.0	2.2	5.0	1.5	2.0	1.187434

	x1	x2	x3	x4	y	distances
31	6.7	3.1	4.4	1.4	1.0	0.346410
96	6.7	3.1	4.7	1.5	1.0	0.374166
37	6.4	2.9	4.3	1.3	1.0	0.412311
6	6.6	2.9	4.6	1.3	1.0	0.424264
0	6.5	2.8	4.6	1.5	1.0	0.424264

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
31	6.7	3.1	4.4	1.4	1.0	0.346410
96	6.7	3.1	4.7	1.5	1.0	0.374166
37	6.4	2.9	4.3	1.3	1.0	0.412311

	class	Q
0	0.0	0.000000
1	1.0	21.358543
2	2.0	0.000000

```
class prediction:  1 - versicolor
y_test = 1


---- 15  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	0.519615
1	6.7	2.5	5.8	1.8	2.0	1.558846
2	6.8	3.0	5.5	2.1	2.0	1.417745
3	5.1	3.5	1.4	0.3	0.0	3.495712
4	6.0	2.2	5.0	1.5	2.0	0.860233

	x1	x2	x3	x4	y	distances
94	6.1	2.9	4.7	1.4	1.0	0.244949
93	5.9	3.0	4.2	1.5	1.0	0.331662
55	6.2	2.9	4.3	1.3	1.0	0.346410
32	5.7	2.8	4.5	1.3	1.0	0.374166
34	6.0	3.0	4.8	1.8	2.0	0.435890

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
94	6.1	2.9	4.7	1.4	1.0	0.244949
93	5.9	3.0	4.2	1.5	1.0	0.331662
55	6.2	2.9	4.3	1.3	1.0	0.346410

	class	Q
0	0.0	0.000000
1	1.0	34.090909
2	2.0	0.000000

```
class prediction:  1 - versicolor
y_test = 1


---- 16  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	4.141256
1	6.7	2.5	5.8	1.8	2.0	5.346962
2	6.8	3.0	5.5	2.1	2.0	5.200961
3	5.1	3.5	1.4	0.3	0.0	0.774597
4	6.0	2.2	5.0	1.5	2.0	4.352011

	x1	x2	x3	x4	y	distances
46	4.4	3.0	1.3	0.2	0.0	0.200000
82	4.6	3.2	1.4	0.2	0.0	0.223607
77	4.6	3.1	1.5	0.2	0.0	0.300000
26	4.7	3.2	1.3	0.2	0.0	0.300000
28	4.6	3.4	1.4	0.3	0.0	0.316228

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
46	4.4	3.0	1.3	0.2	0.0	0.200000
82	4.6	3.2	1.4	0.2	0.0	0.223607
77	4.6	3.1	1.5	0.2	0.0	0.300000

	class	Q
0	0.0	56.111111
1	1.0	0.000000
2	2.0	0.000000

```
class prediction:  0 - setosa
y_test = 0


---- 17  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	0.989949
1	6.7	2.5	5.8	1.8	2.0	2.102380
2	6.8	3.0	5.5	2.1	2.0	2.054264
3	5.1	3.5	1.4	0.3	0.0	2.978255
4	6.0	2.2	5.0	1.5	2.0	1.135782

	x1	x2	x3	x4	y	distances
63	5.8	2.7	3.9	1.2	1.0	0.141421

52	5.8	2.7	4.1	1.0	1.0	0.244949
41	5.5	2.5	4.0	1.3	1.0	0.331662
104	6.1	2.8	4.0	1.3	1.0	0.374166
97	5.7	2.9	4.2	1.3	1.0	0.387298

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
63	5.8	2.7	3.9	1.2	1.0	0.141421
52	5.8	2.7	4.1	1.0	1.0	0.244949
41	5.5	2.5	4.0	1.3	1.0	0.331662

	class	Q
0	0.0	0.000000
1	1.0	75.757576
2	2.0	0.000000

```
class prediction:  1 - versicolor
y_test = 1


---- 18  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	0.927362
1	6.7	2.5	5.8	1.8	2.0	1.800000
2	6.8	3.0	5.5	2.1	2.0	1.673320
3	5.1	3.5	1.4	0.3	0.0	3.398529
4	6.0	2.2	5.0	1.5	2.0	1.024695

	x1	x2	x3	x4	y	distances
32	5.7	2.8	4.5	1.3	1.0	0.300000
97	5.7	2.9	4.2	1.3	1.0	0.387298
93	5.9	3.0	4.2	1.5	1.0	0.424264
21	5.7	3.0	4.2	1.2	1.0	0.435890
85	5.6	3.0	4.1	1.3	1.0	0.447214

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
32	5.7	2.8	4.5	1.3	1.0	0.300000
97	5.7	2.9	4.2	1.3	1.0	0.387298
93	5.9	3.0	4.2	1.5	1.0	0.424264

	class	Q
0	0.0	0.000000
1	1.0	23.333333
2	2.0	0.000000

```
class prediction:  1 - versicolor
y_test = 1


---- 19  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	3.519943
1	6.7	2.5	5.8	1.8	2.0	4.790616
2	6.8	3.0	5.5	2.1	2.0	4.583667
3	5.1	3.5	1.4	0.3	0.0	0.346410
4	6.0	2.2	5.0	1.5	2.0	3.906405

	x1	x2	x3	x4	y	distances
101	5.4	3.4	1.7	0.2	0.0	0.282843
50	5.2	3.5	1.5	0.2	0.0	0.300000
13	5.5	3.5	1.3	0.2	0.0	0.316228
3	5.1	3.5	1.4	0.3	0.0	0.346410
42	5.4	3.7	1.5	0.2	0.0	0.360555

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
101	5.4	3.4	1.7	0.2	0.0	0.282843
50	5.2	3.5	1.5	0.2	0.0	0.300000
13	5.5	3.5	1.3	0.2	0.0	0.316228

	class	Q
0	0.0	33.611111
1	1.0	0.000000
2	2.0	0.000000

```
class prediction:  0 - setosa
y_test = 0


---- 20  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	3.957272
1	6.7	2.5	5.8	1.8	2.0	5.205766
2	6.8	3.0	5.5	2.1	2.0	5.037857
3	5.1	3.5	1.4	0.3	0.0	0.387298
4	6.0	2.2	5.0	1.5	2.0	4.257934

	x1	x2	x3	x4	y	distances
74	5.0	3.3	1.4	0.2	0.0	0.223607
90	4.9	3.0	1.4	0.2	0.0	0.300000
26	4.7	3.2	1.3	0.2	0.0	0.316228
43	4.9	3.1	1.5	0.2	0.0	0.331662
53	4.9	3.1	1.5	0.1	0.0	0.346410

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
74	5.0	3.3	1.4	0.2	0.0	0.223607
90	4.9	3.0	1.4	0.2	0.0	0.300000
26	4.7	3.2	1.3	0.2	0.0	0.316228

	class	Q
0	0.0	41.111111
1	1.0	0.000000
2	2.0	0.000000

```
class prediction:  0 - setosa
y_test = 0


---- 21  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	1.081665
1	6.7	2.5	5.8	1.8	2.0	1.941649
2	6.8	3.0	5.5	2.1	2.0	1.967232
3	5.1	3.5	1.4	0.3	0.0	3.283291
4	6.0	2.2	5.0	1.5	2.0	0.927362

	x1	x2	x3	x4	y	distances
32	5.7	2.8	4.5	1.3	1.0	0.316228
97	5.7	2.9	4.2	1.3	1.0	0.424264
41	5.5	2.5	4.0	1.3	1.0	0.424264
52	5.8	2.7	4.1	1.0	1.0	0.479583
21	5.7	3.0	4.2	1.2	1.0	0.489898

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
32	5.7	2.8	4.5	1.3	1.0	0.316228
97	5.7	2.9	4.2	1.3	1.0	0.424264
41	5.5	2.5	4.0	1.3	1.0	0.424264

	class	Q
0	0.0	0.000000
1	1.0	21.111111
2	2.0	0.000000

```
class prediction:  1 - versicolor
y_test = 1


---- 22  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	1.122497
1	6.7	2.5	5.8	1.8	2.0	1.928730
2	6.8	3.0	5.5	2.1	2.0	1.822087
3	5.1	3.5	1.4	0.3	0.0	3.374907
4	6.0	2.2	5.0	1.5	2.0	1.118034

	x1	x2	x3	x4	y	distances
32	5.7	2.8	4.5	1.3	1.0	0.412311
97	5.7	2.9	4.2	1.3	1.0	0.479583
85	5.6	3.0	4.1	1.3	1.0	0.489898
21	5.7	3.0	4.2	1.2	1.0	0.519615
93	5.9	3.0	4.2	1.5	1.0	0.583095

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
32	5.7	2.8	4.5	1.3	1.0	0.412311
97	5.7	2.9	4.2	1.3	1.0	0.479583
85	5.6	3.0	4.1	1.3	1.0	0.489898

	class	Q
0	0.0	0.000000
1	1.0	14.396846
2	2.0	0.000000

```
class prediction:  1 - versicolor
y_test = 1


---- 23  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	0.529150
1	6.7	2.5	5.8	1.8	2.0	0.948683
2	6.8	3.0	5.5	2.1	2.0	0.648074
3	5.1	3.5	1.4	0.3	0.0	4.210701
4	6.0	2.2	5.0	1.5	2.0	1.081665

	x1	x2	x3	x4	y	distances
66	6.9	3.1	4.9	1.5	1.0	0.316228
96	6.7	3.1	4.7	1.5	1.0	0.374166
80	6.5	3.0	5.2	2.0	2.0	0.412311
68	6.8	2.8	4.8	1.4	1.0	0.424264
30	6.5	3.2	5.1	2.0	2.0	0.424264

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
66	6.9	3.1	4.9	1.5	1.0	0.316228
96	6.7	3.1	4.7	1.5	1.0	0.374166
80	6.5	3.0	5.2	2.0	2.0	0.412311

```
C:\Users\Admin\AppData\Local\Temp\ipykernel_9888\151950262.py:7: SettingWithCopyWarning: 
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
  y['distances^2'] = (y['distances'])**2
C:\Users\Admin\AppData\Local\Temp\ipykernel_9888\151950262.py:7: SettingWithCopyWarning: 
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
  y['distances^2'] = (y['distances'])**2
```

	class	Q

0	0.0	0.000000
1	1.0	17.142857
2	2.0	5.882353

```
class prediction:  1 - versicolor
y_test = 1


---- 24  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	3.882010
1	6.7	2.5	5.8	1.8	2.0	5.137120
2	6.8	3.0	5.5	2.1	2.0	4.936598
3	5.1	3.5	1.4	0.3	0.0	0.141421
4	6.0	2.2	5.0	1.5	2.0	4.221374

	x1	x2	x3	x4	y	distances
3	5.1	3.5	1.4	0.3	0.0	0.141421
89	5.1	3.5	1.4	0.2	0.0	0.173205
9	5.0	3.6	1.4	0.2	0.0	0.173205
95	5.0	3.4	1.5	0.2	0.0	0.244949
74	5.0	3.3	1.4	0.2	0.0	0.244949

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
3	5.1	3.5	1.4	0.3	0.0	0.141421
89	5.1	3.5	1.4	0.2	0.0	0.173205
9	5.0	3.6	1.4	0.2	0.0	0.173205

	class	Q
0	0.0	116.666667
1	1.0	0.000000
2	2.0	0.000000

```
class prediction:  0 - setosa
y_test = 0


---- 25  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	1.643168
1	6.7	2.5	5.8	1.8	2.0	0.883176
2	6.8	3.0	5.5	2.1	2.0	0.734847
3	5.1	3.5	1.4	0.3	0.0	5.282992
4	6.0	2.2	5.0	1.5	2.0	1.878829

	x1	x2	x3	x4	y	distances
105	7.2	3.0	5.8	1.6	2.0	0.346410
16	7.3	2.9	6.3	1.8	2.0	0.435890
54	7.4	2.8	6.1	1.9	2.0	0.469042
73	6.8	3.2	5.9	2.3	2.0	0.648074
45	6.7	3.3	5.7	2.1	2.0	0.663325

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
105	7.2	3.0	5.8	1.6	2.0	0.346410
16	7.3	2.9	6.3	1.8	2.0	0.435890
54	7.4	2.8	6.1	1.9	2.0	0.469042

	class	Q
0	0.0	0.000000
1	1.0	0.000000
2	2.0	18.141946

```
class prediction:  2 - virginica
y_test = 2


---- 26  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	0.964365
1	6.7	2.5	5.8	1.8	2.0	2.056696
2	6.8	3.0	5.5	2.1	2.0	1.962142
3	5.1	3.5	1.4	0.3	0.0	3.023243
4	6.0	2.2	5.0	1.5	2.0	1.140175

	x1	x2	x3	x4	y	distances
97	5.7	2.9	4.2	1.3	1.0	0.141421
85	5.6	3.0	4.1	1.3	1.0	0.223607
21	5.7	3.0	4.2	1.2	1.0	0.244949
63	5.8	2.7	3.9	1.2	1.0	0.264575
52	5.8	2.7	4.1	1.0	1.0	0.331662

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
97	5.7	2.9	4.2	1.3	1.0	0.141421
85	5.6	3.0	4.1	1.3	1.0	0.223607
21	5.7	3.0	4.2	1.2	1.0	0.244949

	class	Q
0	0.0	0.000000
1	1.0	86.666667
2	2.0	0.000000

```
class prediction:  1 - versicolor
y_test = 1


---- 27  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	3.858756
1	6.7	2.5	5.8	1.8	2.0	5.123475

2	6.8	3.0	5.5	2.1	2.0	4.852834
3	5.1	3.5	1.4	0.3	0.0	0.812404
4	6.0	2.2	5.0	1.5	2.0	4.347413

	x1	x2	x3	x4	y	distances
44	5.2	4.1	1.5	0.1	0.0	0.346410
62	5.7	4.4	1.5	0.4	0.0	0.360555
42	5.4	3.7	1.5	0.2	0.0	0.519615
8	5.7	3.8	1.7	0.3	0.0	0.547723
35	5.1	3.8	1.6	0.2	0.0	0.600000

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
44	5.2	4.1	1.5	0.1	0.0	0.346410
62	5.7	4.4	1.5	0.4	0.0	0.360555
42	5.4	3.7	1.5	0.2	0.0	0.519615

	class	Q
0	0.0	19.729345
1	1.0	0.000000
2	2.0	0.000000

```
class prediction:  0 - setosa
y_test = 0


---- 28  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	3.742993
1	6.7	2.5	5.8	1.8	2.0	4.999000
2	6.8	3.0	5.5	2.1	2.0	4.771792
3	5.1	3.5	1.4	0.3	0.0	0.316228
4	6.0	2.2	5.0	1.5	2.0	4.130375

	x1	x2	x3	x4	y	distances
75	5.1	3.7	1.5	0.4	0.0	0.141421
35	5.1	3.8	1.6	0.2	0.0	0.141421
9	5.0	3.6	1.4	0.2	0.0	0.264575
3	5.1	3.5	1.4	0.3	0.0	0.316228
89	5.1	3.5	1.4	0.2	0.0	0.331662

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
75	5.1	3.7	1.5	0.4	0.0	0.141421
35	5.1	3.8	1.6	0.2	0.0	0.141421
9	5.0	3.6	1.4	0.2	0.0	0.264575

	class	Q
0	0.0	114.285714
1	1.0	0.000000
2	2.0	0.000000

```
class prediction:  0 - setosa
y_test = 0


---- 29  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	0.509902
1	6.7	2.5	5.8	1.8	2.0	1.421267
2	6.8	3.0	5.5	2.1	2.0	1.407125
3	5.1	3.5	1.4	0.3	0.0	3.631804
4	6.0	2.2	5.0	1.5	2.0	0.741620

	x1	x2	x3	x4	y	distances
94	6.1	2.9	4.7	1.4	1.0	0.223607
55	6.2	2.9	4.3	1.3	1.0	0.435890
32	5.7	2.8	4.5	1.3	1.0	0.458258
109	6.3	2.5	4.9	1.5	1.0	0.509902
0	6.5	2.8	4.6	1.5	1.0	0.509902

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
94	6.1	2.9	4.7	1.4	1.0	0.223607
55	6.2	2.9	4.3	1.3	1.0	0.435890
32	5.7	2.8	4.5	1.3	1.0	0.458258

	class	Q
0	0.0	0.000000
1	1.0	30.025063
2	2.0	0.000000

```
class prediction:  1 - versicolor
y_test = 1


---- 30  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	0.670820
1	6.7	2.5	5.8	1.8	2.0	0.900000
2	6.8	3.0	5.5	2.1	2.0	0.888819
3	5.1	3.5	1.4	0.3	0.0	4.237924
4	6.0	2.2	5.0	1.5	2.0	0.583095

	x1	x2	x3	x4	y	distances
24	6.3	2.7	4.9	1.8	2.0	0.244949
48	6.4	2.7	5.3	1.9	2.0	0.374166
18	6.2	2.8	4.8	1.8	2.0	0.387298
109	6.3	2.5	4.9	1.5	1.0	0.412311
47	6.0	2.7	5.1	1.6	1.0	0.479583

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
24	6.3	2.7	4.9	1.8	2.0	0.244949
48	6.4	2.7	5.3	1.9	2.0	0.374166
18	6.2	2.8	4.8	1.8	2.0	0.387298

	class	Q
0	0.0	0.00000
1	1.0	0.00000
2	2.0	30.47619

```
class prediction:  2 - virginica
y_test = 2


---- 31  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	0.458258
1	6.7	2.5	5.8	1.8	2.0	1.486607
2	6.8	3.0	5.5	2.1	2.0	1.337909
3	5.1	3.5	1.4	0.3	0.0	3.563706
4	6.0	2.2	5.0	1.5	2.0	0.905539

	x1	x2	x3	x4	y	distances
94	6.1	2.9	4.7	1.4	1.0	0.141421
55	6.2	2.9	4.3	1.3	1.0	0.346410
37	6.4	2.9	4.3	1.3	1.0	0.447214
93	5.9	3.0	4.2	1.5	1.0	0.458258
34	6.0	3.0	4.8	1.8	2.0	0.458258

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
94	6.1	2.9	4.7	1.4	1.0	0.141421
55	6.2	2.9	4.3	1.3	1.0	0.346410
37	6.4	2.9	4.3	1.3	1.0	0.447214

	class	Q
0	0.0	0.000000
1	1.0	63.333333
2	2.0	0.000000

```
class prediction:  1 - versicolor
y_test = 1


---- 32  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	2.090454
1	6.7	2.5	5.8	1.8	2.0	1.260952
2	6.8	3.0	5.5	2.1	2.0	1.100000
3	5.1	3.5	1.4	0.3	0.0	5.753260
4	6.0	2.2	5.0	1.5	2.0	2.319483

	x1	x2	x3	x4	y	distances
54	7.4	2.8	6.1	1.9	2.0	0.538516
56	7.6	3.0	6.6	2.1	2.0	0.547723
16	7.3	2.9	6.3	1.8	2.0	0.678233
20	7.7	2.8	6.7	2.0	2.0	0.700000
60	7.2	3.6	6.1	2.5	2.0	0.806226

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
54	7.4	2.8	6.1	1.9	2.0	0.538516
56	7.6	3.0	6.6	2.1	2.0	0.547723
16	7.3	2.9	6.3	1.8	2.0	0.678233

	class	Q
0	0.0	0.000000
1	1.0	0.000000
2	2.0	8.955522

```
class prediction:  2 - virginica
y_test = 2


---- 33  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	1.244990
1	6.7	2.5	5.8	1.8	2.0	2.304344
2	6.8	3.0	5.5	2.1	2.0	2.291288
3	5.1	3.5	1.4	0.3	0.0	2.853069
4	6.0	2.2	5.0	1.5	2.0	1.272792

	x1	x2	x3	x4	y	distances
65	5.5	2.4	3.8	1.1	1.0	0.173205
41	5.5	2.5	4.0	1.3	1.0	0.244949
87	5.5	2.4	3.7	1.0	1.0	0.264575
63	5.8	2.7	3.9	1.2	1.0	0.300000
52	5.8	2.7	4.1	1.0	1.0	0.360555

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
65	5.5	2.4	3.8	1.1	1.0	0.173205
41	5.5	2.5	4.0	1.3	1.0	0.244949
87	5.5	2.4	3.7	1.0	1.0	0.264575

	class	Q
0	0.0	0.000000
1	1.0	64.285714
2	2.0	0.000000

```
class prediction:  1 - versicolor
y_test = 1


---- 34  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	1.170470
1	6.7	2.5	5.8	1.8	2.0	0.556776
2	6.8	3.0	5.5	2.1	2.0	0.458258
3	5.1	3.5	1.4	0.3	0.0	4.802083
4	6.0	2.2	5.0	1.5	2.0	1.113553

	x1	x2	x3	x4	y	distances
17	6.4	2.8	5.6	2.2	2.0	0.100000
27	6.5	3.0	5.8	2.2	2.0	0.316228
5	6.3	2.9	5.6	1.8	2.0	0.331662
48	6.4	2.7	5.3	1.9	2.0	0.374166
38	6.5	3.0	5.5	1.8	2.0	0.387298

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
17	6.4	2.8	5.6	2.2	2.0	0.100000
27	6.5	3.0	5.8	2.2	2.0	0.316228
5	6.3	2.9	5.6	1.8	2.0	0.331662

	class	Q
0	0.0	0.000000
1	1.0	0.000000
2	2.0	119.090909

```
class prediction:  2 - virginica
y_test = 2


---- 35  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	1.244990
1	6.7	2.5	5.8	1.8	2.0	1.322876
2	6.8	3.0	5.5	2.1	2.0	1.135782
3	5.1	3.5	1.4	0.3	0.0	4.368066
4	6.0	2.2	5.0	1.5	2.0	1.104536

	x1	x2	x3	x4	y	distances
72	5.6	2.8	4.9	2.0	2.0	0.489898
78	5.8	2.7	5.1	1.9	2.0	0.509902
100	5.8	2.7	5.1	1.9	2.0	0.509902
23	5.7	2.5	5.0	2.0	2.0	0.519615
49	5.9	3.0	5.1	1.8	2.0	0.640312

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
72	5.6	2.8	4.9	2.0	2.0	0.489898
78	5.8	2.7	5.1	1.9	2.0	0.509902
100	5.8	2.7	5.1	1.9	2.0	0.509902

	class	Q
0	0.0	0.000000
1	1.0	0.000000
2	2.0	11.858974

```
class prediction:  2 - virginica
y_test = 2


---- 36  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	3.681032
1	6.7	2.5	5.8	1.8	2.0	4.944694
2	6.8	3.0	5.5	2.1	2.0	4.727579
3	5.1	3.5	1.4	0.3	0.0	0.316228
4	6.0	2.2	5.0	1.5	2.0	4.084116

	x1	x2	x3	x4	y	distances
42	5.4	3.7	1.5	0.2	0.0	0.100000
50	5.2	3.5	1.5	0.2	0.0	0.223607
35	5.1	3.8	1.6	0.2	0.0	0.244949
75	5.1	3.7	1.5	0.4	0.0	0.282843
89	5.1	3.5	1.4	0.2	0.0	0.300000

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
42	5.4	3.7	1.5	0.2	0.0	0.100000
50	5.2	3.5	1.5	0.2	0.0	0.223607
35	5.1	3.8	1.6	0.2	0.0	0.244949

	class	Q
0	0.0	136.666667
1	1.0	0.000000
2	2.0	0.000000

```
class prediction:  0 - setosa
y_test = 0


---- 37  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	1.284523
1	6.7	2.5	5.8	1.8	2.0	2.229350
2	6.8	3.0	5.5	2.1	2.0	2.251666
3	5.1	3.5	1.4	0.3	0.0	3.059412
4	6.0	2.2	5.0	1.5	2.0	1.140175

	x1	x2	x3	x4	y	distances
41	5.5	2.5	4.0	1.3	1.0	0.200000
65	5.5	2.4	3.8	1.1	1.0	0.300000
87	5.5	2.4	3.7	1.0	1.0	0.435890
11	5.2	2.7	3.9	1.4	1.0	0.519615
63	5.8	2.7	3.9	1.2	1.0	0.519615

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
41	5.5	2.5	4.0	1.3	1.0	0.20000
65	5.5	2.4	3.8	1.1	1.0	0.30000
87	5.5	2.4	3.7	1.0	1.0	0.43589

	class	Q
0	0.0	0.000000
1	1.0	41.374269
2	2.0	0.000000

```
class prediction:  1 - versicolor
y_test = 1


---- 38  тестовий об`єкт ----
```

	x1	x2	x3	x4	y	distances
0	6.5	2.8	4.6	1.5	1.0	3.738984
1	6.7	2.5	5.8	1.8	2.0	4.998000
2	6.8	3.0	5.5	2.1	2.0	4.810405
3	5.1	3.5	1.4	0.3	0.0	0.173205
4	6.0	2.2	5.0	1.5	2.0	4.090232

	x1	x2	x3	x4	y	distances
50	5.2	3.5	1.5	0.2	0.0	0.141421
89	5.1	3.5	1.4	0.2	0.0	0.141421
12	5.1	3.4	1.5	0.2	0.0	0.141421
3	5.1	3.5	1.4	0.3	0.0	0.173205
95	5.0	3.4	1.5	0.2	0.0	0.223607

```
k сусідів = 3
```

	x1	x2	x3	x4	y	distances
50	5.2	3.5	1.5	0.2	0.0	0.141421
89	5.1	3.5	1.4	0.2	0.0	0.141421
12	5.1	3.4	1.5	0.2	0.0	0.141421

	class	Q
0	0.0	150.0
1	1.0	0.0
2	2.0	0.0

```
class prediction:  0 - setosa
y_test = 0
```

- ***Знайдемо точність - відповідність прогнозованих та реальних даних.***

In [16]:

```
accuracy = accuracy_score(y_test, y_pred)
print("Accuracy (точність):", accuracy)
```

```
Accuracy (точність): 1.0
```

З використанням вбудованого алгоритму kNN з бібліотеки *sklearn* провести класифікацію об'єктів. Визначити кількість помилок.

In [17]:

```
# Масштабування функцій за допомогою StandardScaler
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)
```

In [18]:

```
knn = KNeighborsClassifier(n_neighbors=3)
knn.fit(X_train, y_train)
```

Out[18]:

```
KNeighborsClassifier(n_neighbors=3)
```

In [19]:

```
y_pred = knn.predict(X_test)
y_pred
```

Out[19]:

```
array([0, 1, 1, 0, 2, 1, 2, 0, 0, 2, 1, 0, 2, 1, 1, 0, 1, 1, 0, 0, 1, 1,
       1, 0, 2, 1, 0, 0, 1, 2, 1, 2, 1, 2, 2, 0, 1, 0])
```

In [20]:

```
accuracy = accuracy_score(y_test, y_pred)
print("Accuracy (точність):", accuracy)
```

```
Accuracy (точність): 1.0
```

Машинне навчання

Метод опорних векторів (SVM)

Лабораторна робота 3

Студентка Пороскун Олена. Група ПМ.м-21

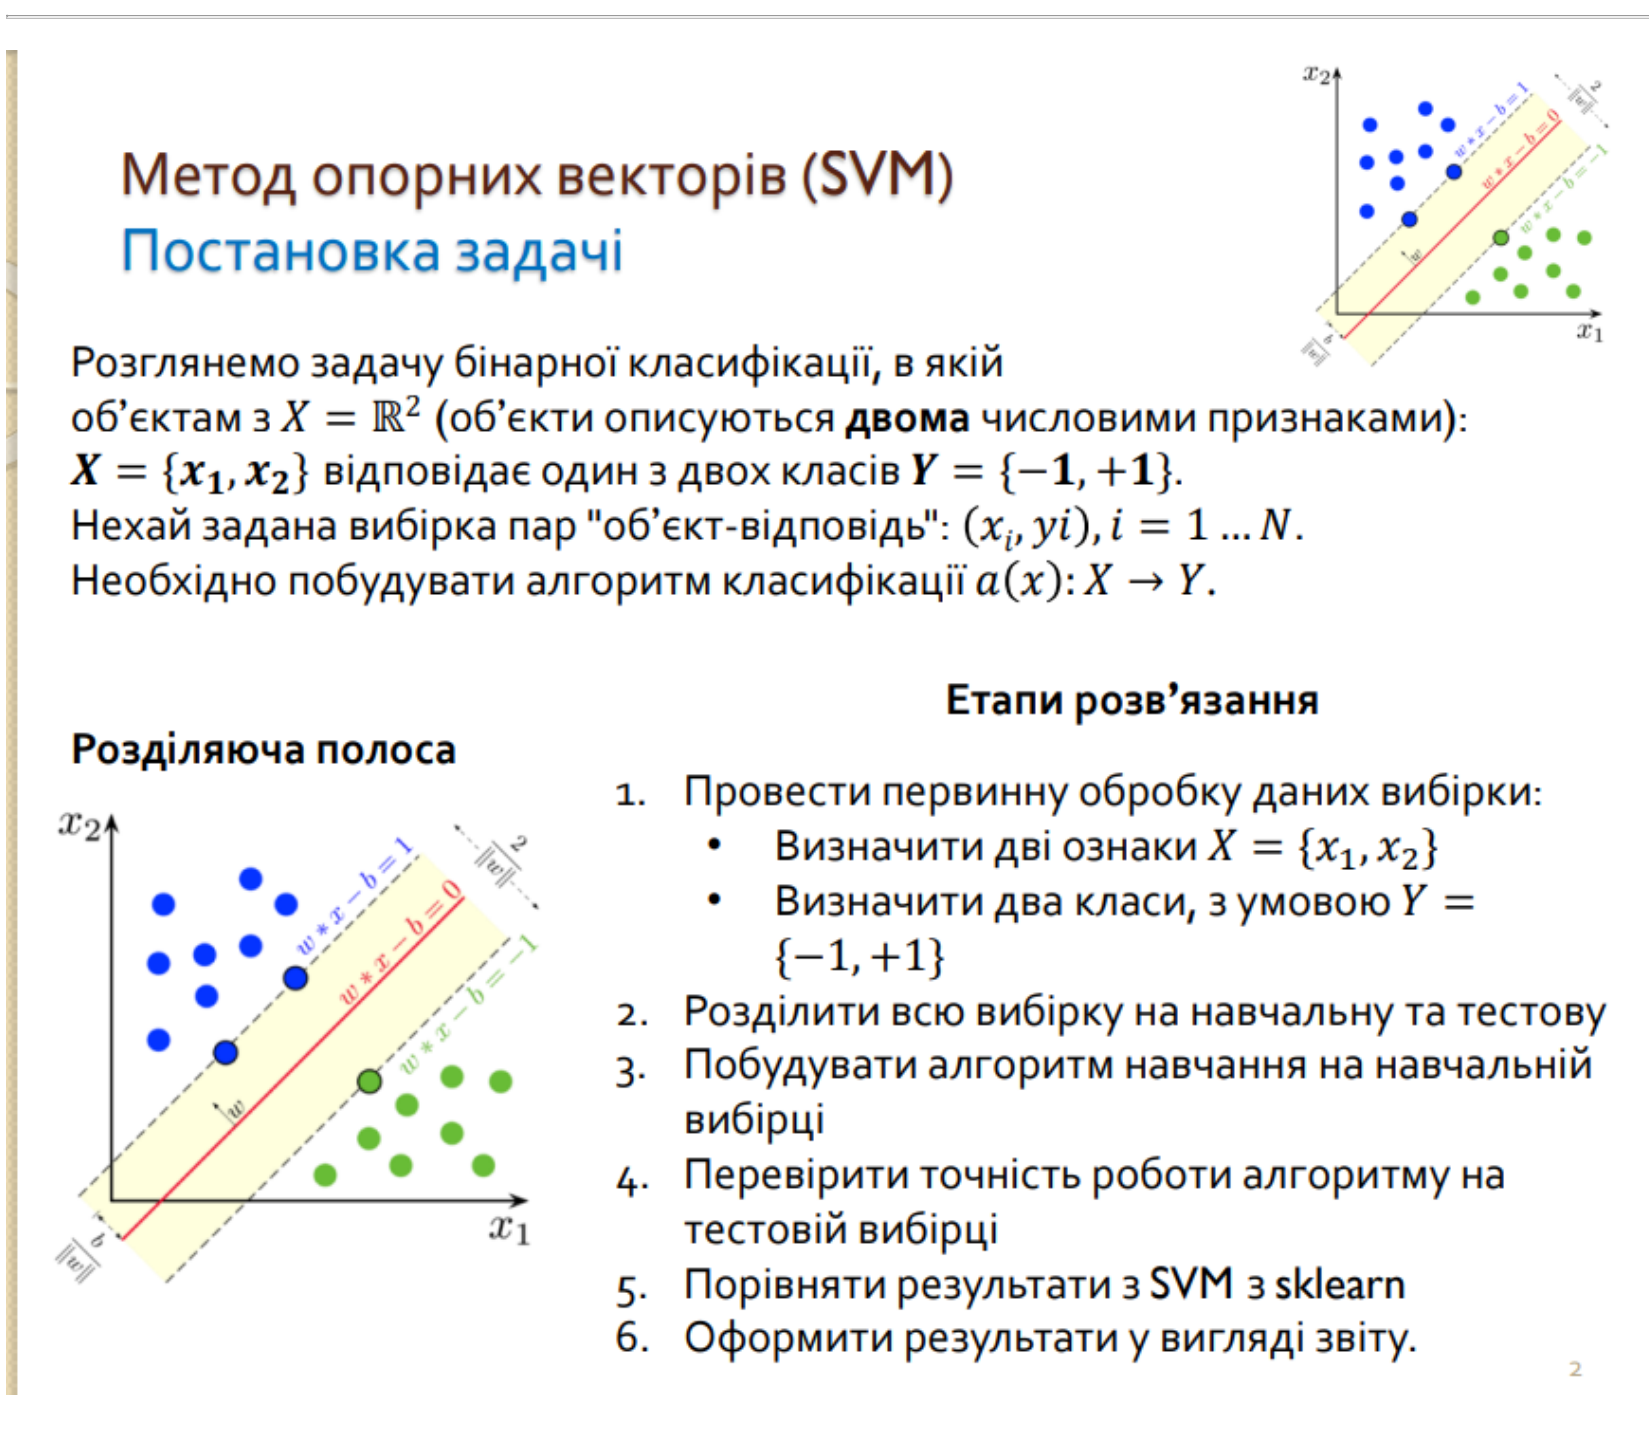

Метод опорних векторів (SVM)
Постановка задачі

Розглянемо задачу бінарної класифікації, в якій об'єктам з $X = \mathbb{R}^2$ (об'єкти описуються **двома** числовими признаками): $\boldsymbol{X} = \{\boldsymbol{x_1}, \boldsymbol{x_2}\}$ відповідає один з двох класів $\boldsymbol{Y} = \{\boldsymbol{-1}, \boldsymbol{+1}\}$.
Нехай задана вибірка пар "об'єкт-відповідь": $(x_i, yi), i = 1 \dots N$.
Необхідно побудувати алгоритм класифікації $a(x): X \to Y$.

Розділяюча полоса

Етапи розв'язання

1. Провести первинну обробку даних вибірки:
   - Визначити дві ознаки $X = \{x_1, x_2\}$
   - Визначити два класи, з умовою $Y = \{-1, +1\}$
2. Розділити всю вибірку на навчальну та тестову
3. Побудувати алгоритм навчання на навчальній вибірці
4. Перевірити точність роботи алгоритму на тестовій вибірці
5. Порівняти результати з SVM з sklearn
6. Оформити результати у вигляді звіту.

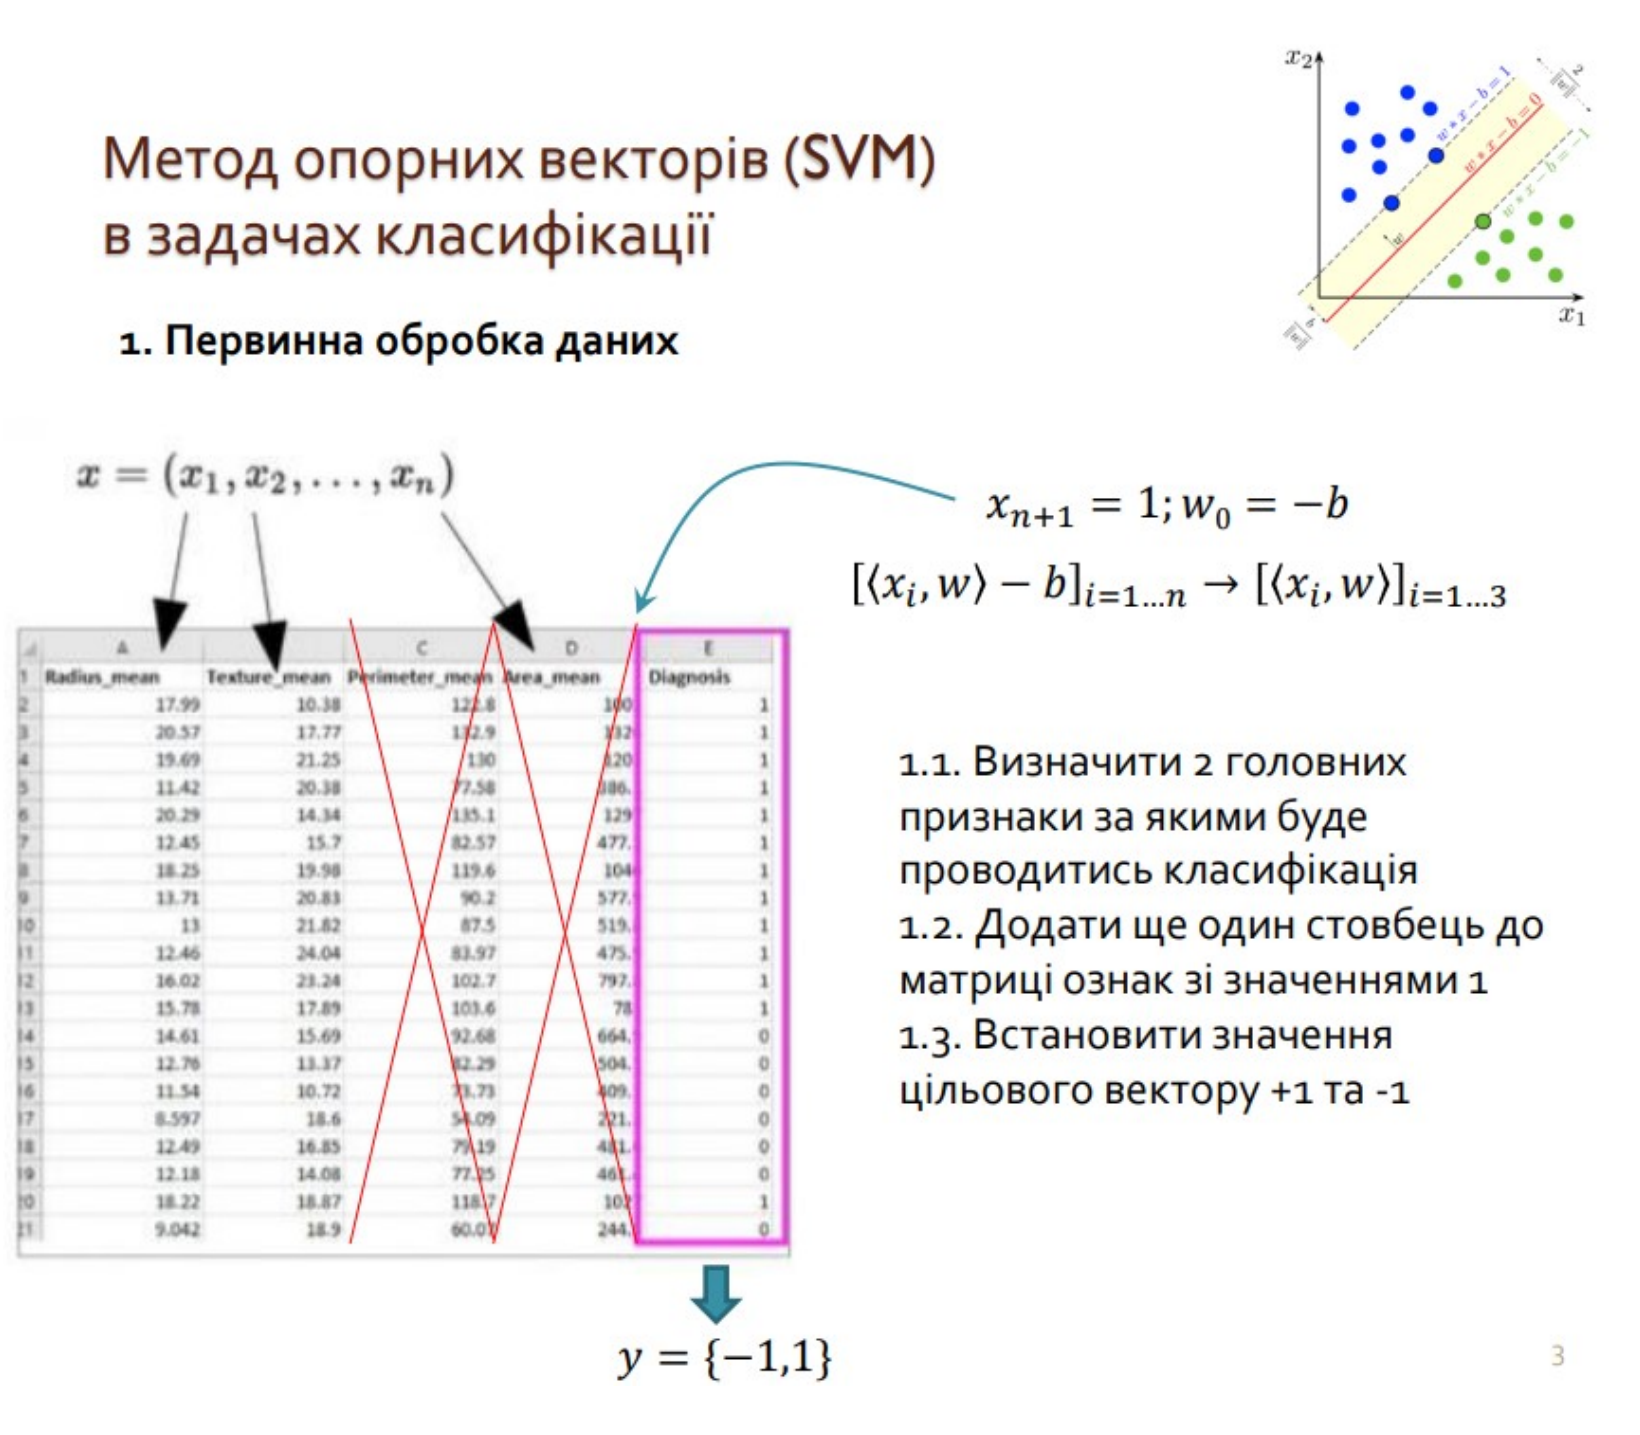

Метод опорних векторів (SVM) в задачах класифікації

1. Первинна обробка даних

$x = (x_1, x_2, \dots, x_n)$

$x_{n+1} = 1; w_0 = -b$

$[\langle x_i, w\rangle - b]_{i=1\dots n} \to [\langle x_i, w\rangle]_{i=1\dots 3}$

	A	B	C	D	E
1	Radius_mean	Texture_mean	Perimeter_mean	Area_mean	Diagnosis
2	17.99	10.38	122.8	100	1
3	20.57	17.77	132.9	132	1
4	19.69	21.25	130	120	1
5	11.42	20.38	77.58	386.	1
6	20.29	14.34	135.1	129	1
7	12.45	15.7	82.57	477.	1
8	18.25	19.98	119.6	104	1
9	13.71	20.83	90.2	577.	1
10	13	21.82	87.5	519.	1
11	12.46	24.04	83.97	475.	1
12	16.02	23.24	102.7	797.	1
13	15.78	17.89	103.6	78	1
14	14.61	15.69	92.68	664.	0
15	12.76	13.37	82.29	504.	0
16	11.54	10.72	73.73	409.	0
17	8.597	18.6	54.09	221.	0
18	12.49	16.85	79.19	481.	0
19	12.18	14.08	77.25	461.	0
20	18.22	18.87	118.7	102	1
21	9.042	18.9	60.01	244.	0

$y = \{-1, 1\}$

1.1. Визначити 2 головних признаки за якими буде проводитись класифікація
1.2. Додати ще один стовбець до матриці ознак зі значеннями 1
1.3. Встановити значення цільового вектору +1 та -1

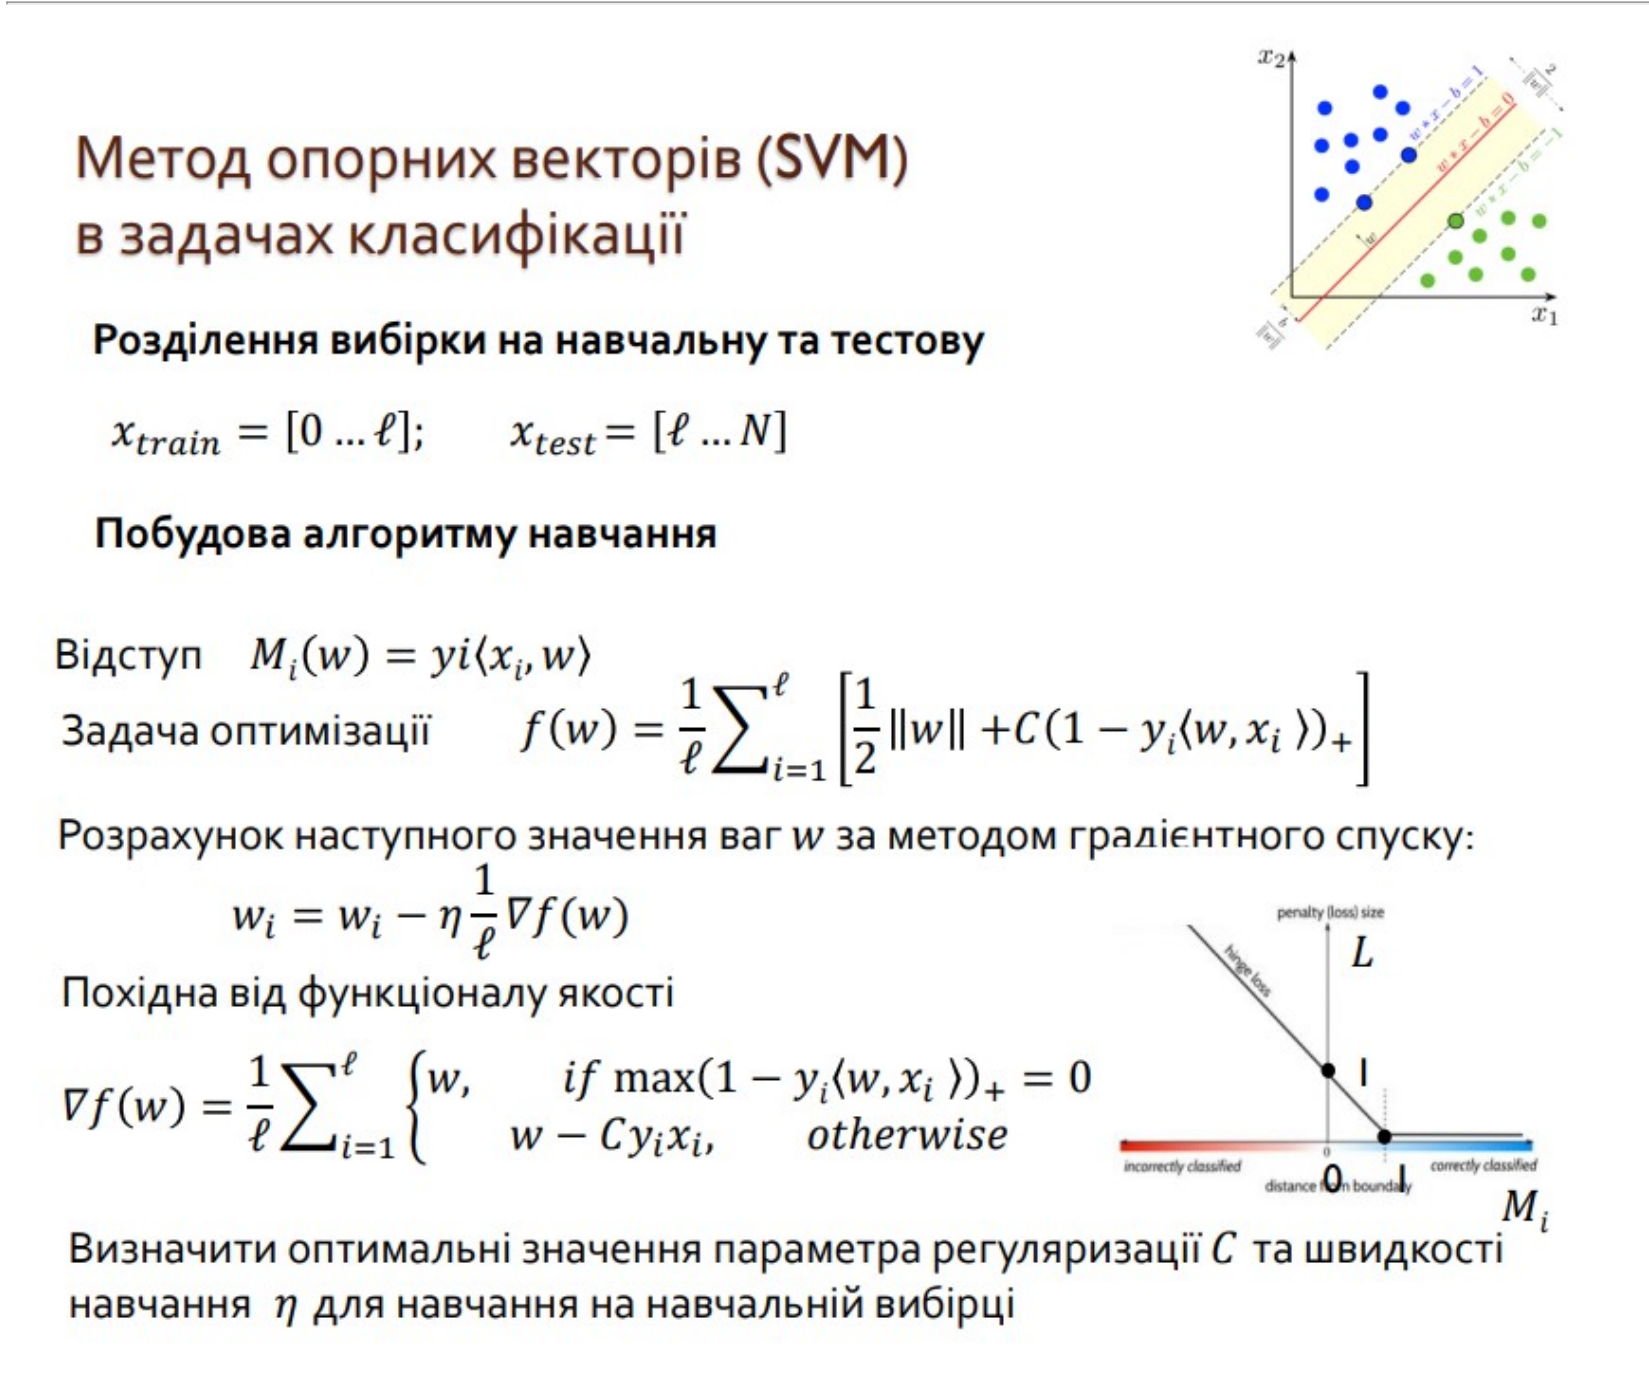

Метод опорних векторів (SVM) в задачах класифікації

Розділення вибірки на навчальну та тестову

$x_{train} = [0 \dots \ell]; \qquad x_{test} = [\ell \dots N]$

Побудова алгоритму навчання

Відступ $\quad M_i(w) = yi\langle x_i, w\rangle$

Задача оптимізації $\quad f(w) = \frac{1}{\ell}\sum_{i=1}^{\ell}\left[\frac{1}{2}\|w\| + C(1 - y_i\langle w, x_i\rangle)_+\right]$

Розрахунок наступного значення ваг w за методом градієнтного спуску:

$$w_i = w_i - \eta\frac{1}{\ell}\nabla f(w)$$

Похідна від функціоналу якості

$$\nabla f(w) = \frac{1}{\ell}\sum_{i=1}^{\ell}\begin{cases} w, & if \max(1 - y_i\langle w, x_i\rangle)_+ = 0 \\ w - Cy_ix_i, & otherwise \end{cases}$$

Визначити оптимальні значення параметра регуляризації C та швидкості навчання η для навчання на навчальній вибірці

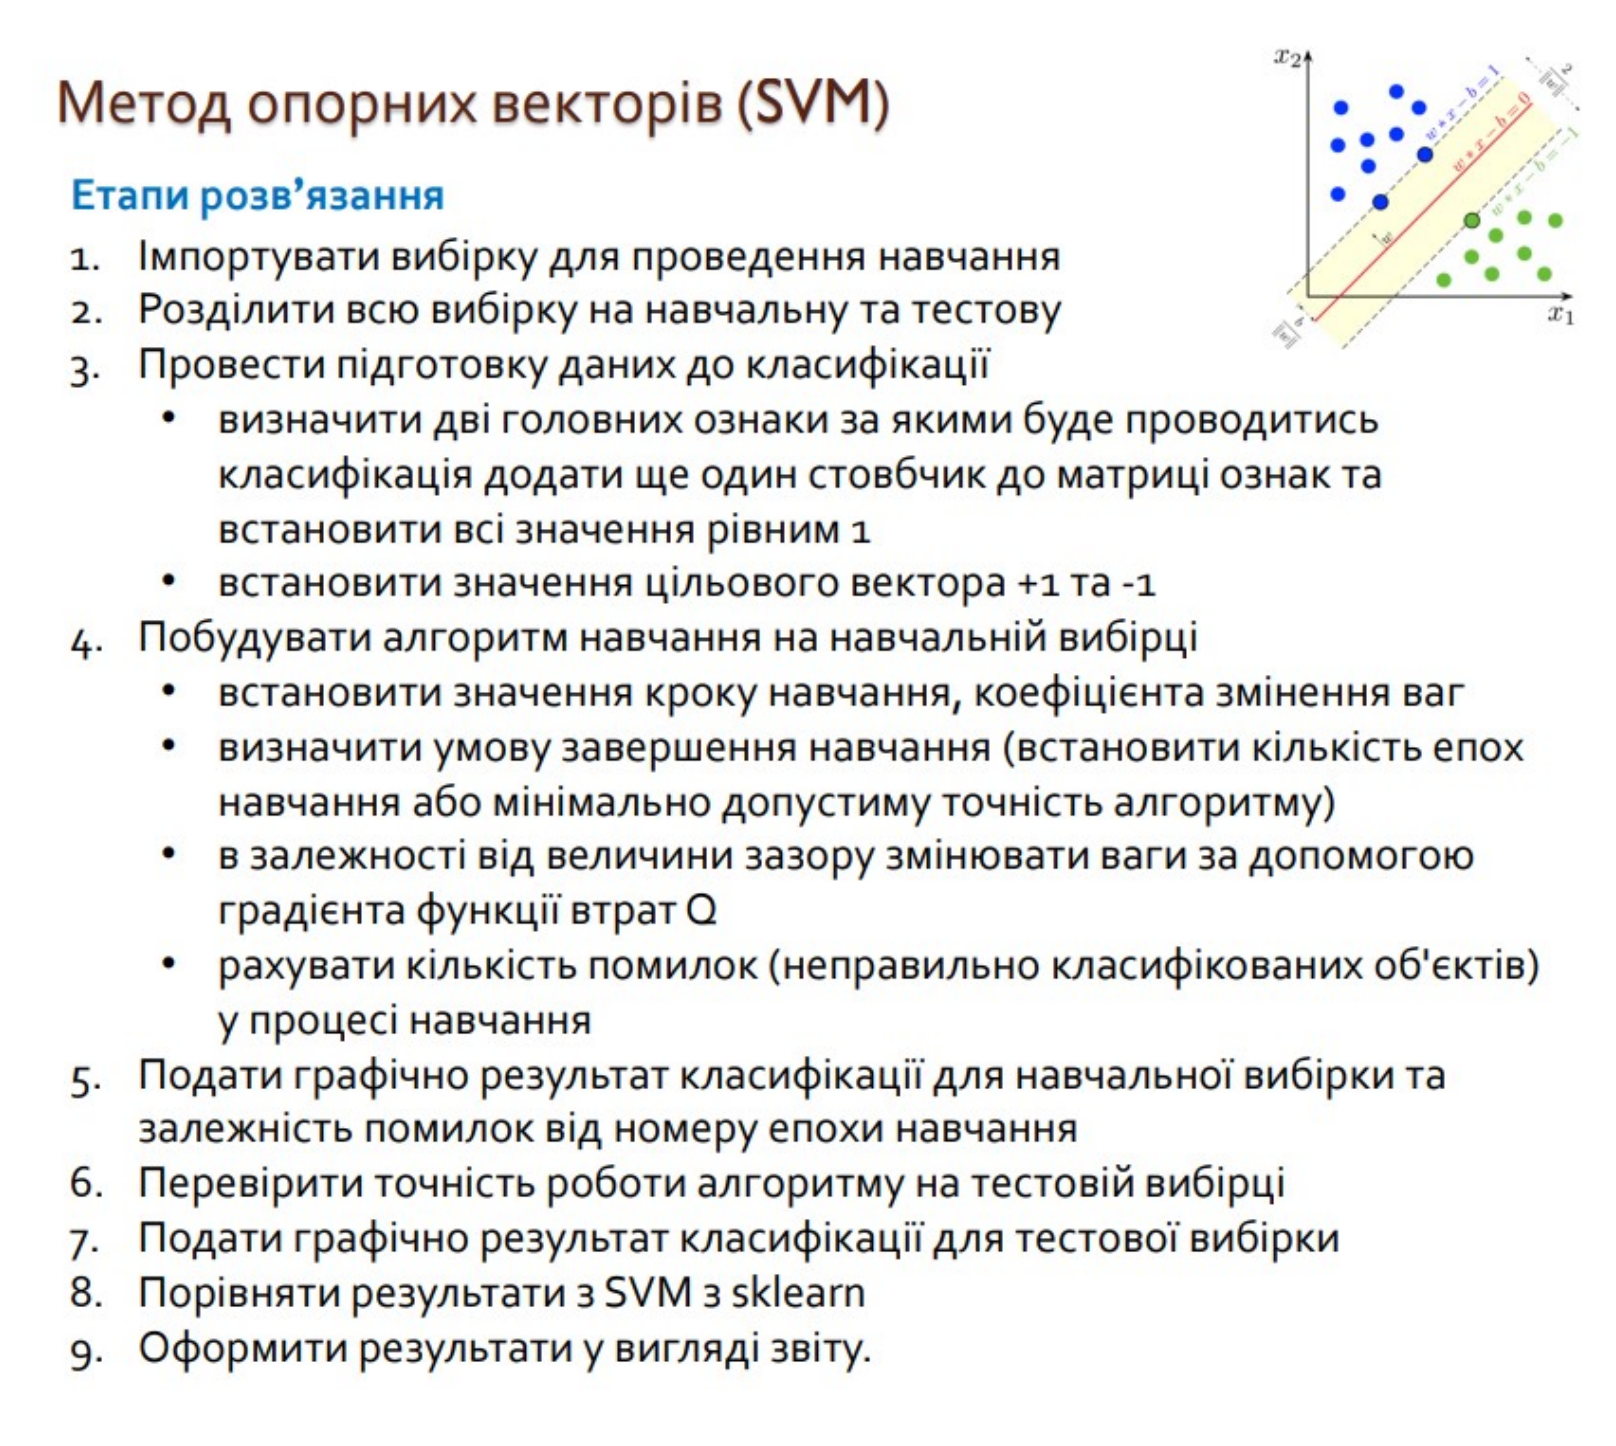

Метод опорних векторів (SVM)

Етапи розв'язання

1. Імпортувати вибірку для проведення навчання
2. Розділити всю вибірку на навчальну та тестову
3. Провести підготовку даних до класифікації
   - визначити дві головних ознаки за якими буде проводитись класифікація додати ще один стовбчик до матриці ознак та встановити всі значення рівним 1
   - встановити значення цільового вектора +1 та -1
4. Побудувати алгоритм навчання на навчальній вибірці
   - встановити значення кроку навчання, коефіцієнта змінення ваг
   - визначити умову завершення навчання (встановити кількість епох навчання або мінімально допустиму точність алгоритму)
   - в залежності від величини зазору змінювати ваги за допомогою градієнта функції втрат Q
   - рахувати кількість помилок (неправильно класифікованих об'єктів) у процесі навчання
5. Подати графічно результат класифікації для навчальної вибірки та залежність помилок від номеру епохи навчання
6. Перевірити точність роботи алгоритму на тестовій вибірці
7. Подати графічно результат класифікації для тестової вибірки
8. Порівняти результати з SVM з sklearn
9. Оформити результати у вигляді звіту.

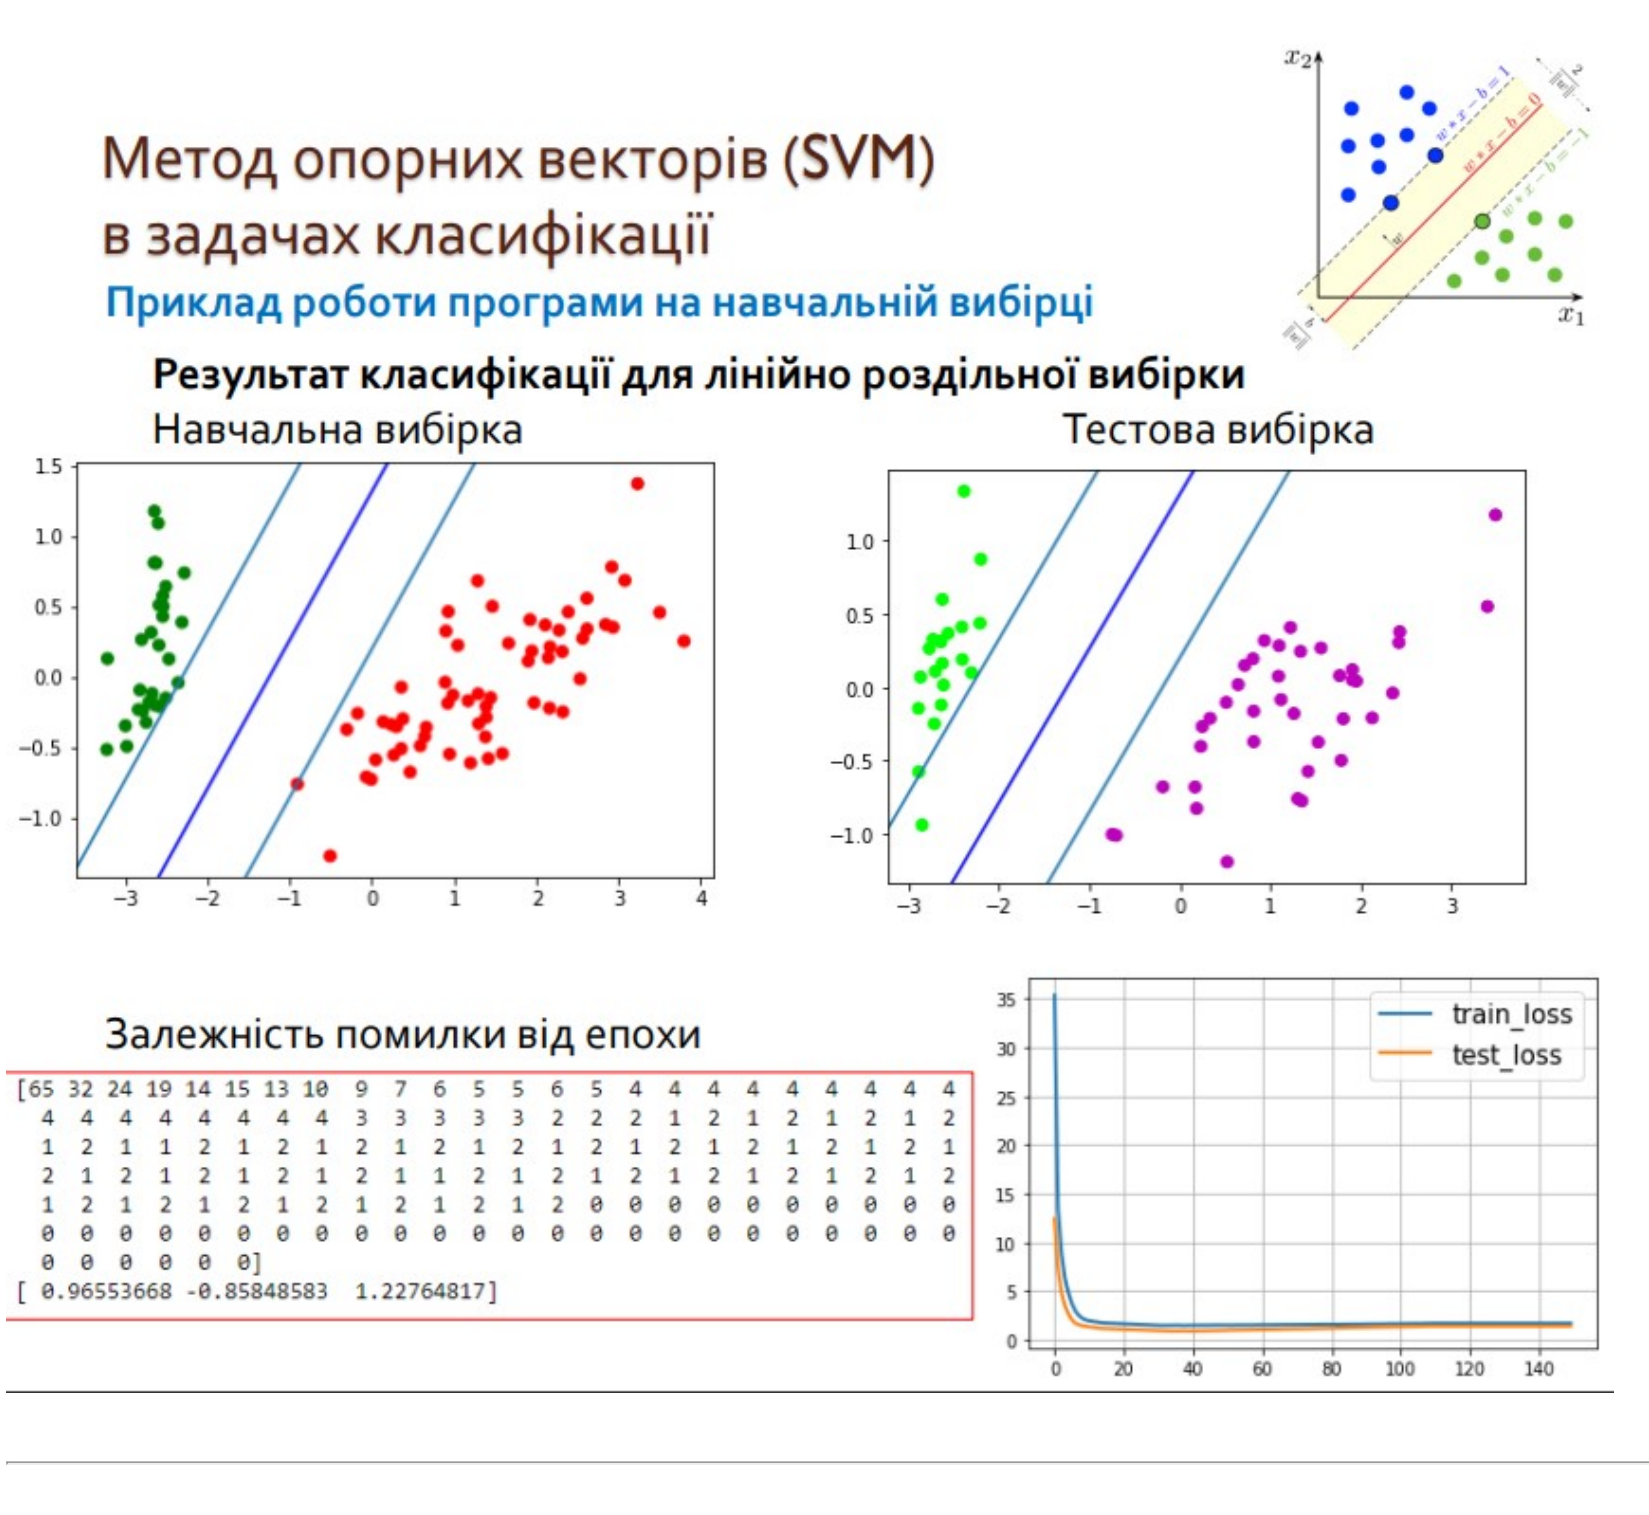

Метод опорних векторів (SVM) в задачах класифікації

Приклад роботи програми на навчальній вибірці

Результат класифікації для лінійно роздільної вибірки

Навчальна вибірка

Тестова вибірка

Залежність помилки від епохи

```
[65 32 24 19 14 15 13 10  9  7  6  5  5  6  5  4  4  4  4  4  4  4  4  4
  4  4  4  4  4  4  4  4  3  3  3  3  3  2  2  2  1  2  1  2  1  2  1  2
  1  2  1  1  2  1  2  1  2  1  2  1  2  1  2  1  2  1  2  1  2  1  2  1
  2  1  2  1  2  1  2  1  2  1  1  2  1  2  1  2  1  2  1  2  1  2  1  2
  1  2  1  2  1  2  1  2  1  2  1  2  1  2  0  0  0  0  0  0  0  0  0  0
  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0
  0  0  0  0  0  0]
[ 0.96553668 -0.85848583  1.22764817]
```

- **Імпортуємо потрібні бібліотеки**:

In [1]:
```
import numpy as np
import pandas as pd

import warnings
warnings.filterwarnings('ignore')

import seaborn as sns
import matplotlib.pyplot as plt
import matplotlib.lines as mlines
plt.rcParams['figure.figsize'] = (8,6)
%matplotlib inline

from sklearn.datasets import load_iris
from sklearn.decomposition import PCA
from sklearn.model_selection import train_test_split
from sklearn import metrics
```

- **Визначаємо функції, що реалізовують Метод опорних векторів (svm):**

In [2]:
```
 # функція для зображення лінії
def newline(p1, p2, color=None):
    ax = plt.gca()
    xmin, xmax = ax.get_xbound()

    if(p2[0] == p1[0]):
        xmin = xmax = p1[0]
        ymin, ymax = ax.get_ybound()
    else:
        ymax = p1[1]+(p2[1]-p1[1])/(p2[0]-p1[0])*(xmax-p1[0])
        ymin = p1[1]+(p2[1]-p1[1])/(p2[0]-p1[0])*(xmin-p1[0])

    l = mlines.Line2D([xmin,xmax], [ymin,ymax], color=color)
    ax.add_line(l)
    return l
```

In [3]:
```
def add_bias_feature(a):
    a_extended = np.zeros((a.shape[0],a.shape[1]+1))
    a_extended[:,:-1] = a
    a_extended[:,-1] = int(1)
    return a_extended
```

In [4]:
```
class CustomSVM(object):
    __class__ = "CustomSVM"
    __doc__ = """
    Це реалізація алгоритму класифікації SVM (тільки для бінарної класифікації)

    # Параметри
    etha: float(default - 0.01)
        Швидкість навчання, крок градієнта

    alpha: float, (default - 0.1)
        Параметр регуляризації в 0.5*alpha*||w||^2

    epochs: int, (default - 200)
        Кількість епох навчання
    """

    def __init__(self, etha=0.01, alpha=0.1, epochs=200):
        self._epochs = epochs
        self._etha = etha
        self._alpha = alpha
        self._w = None
        self.history_w = []
        self.train_errors = None
        self.val_errors = None
        self.train_loss = None
        self.val_loss = None

    def fit(self, X_train, Y_train, X_val, Y_val, verbose=False): #arrays: X; Y =-1,1

        if len(set(Y_train)) != 2 or len(set(Y_val)) != 2:
            raise ValueError("Кількість класів в Y не дорівнює 2!")

        X_train = add_bias_feature(X_train)
        X_val = add_bias_feature(X_val)
        self._w = np.random.normal(loc=0, scale=0.05, size=X_train.shape[1])
        self.history_w.append(self._w)
        train_errors = []
        val_errors = []
        train_loss_epoch = []
        val_loss_epoch = []

        for epoch in range(self._epochs):
            tr_err = 0
            val_err = 0
            tr_loss = 0
            val_loss = 0
            for i,x in enumerate(X_train):
                margin = Y_train[i]*np.dot(self._w,X_train[i])
                if margin >= 1: # классифицируем верно
                    self._w = self._w - self._etha*self._alpha*self._w/self._epochs
                    tr_loss += self.soft_margin_loss(X_train[i],Y_train[i])
                else: # классифицируем неверно или попадаем на полосу разделения при 0<m<1
                    self._w = self._w +\
                    self._etha*(Y_train[i]*X_train[i] - self._alpha*self._w/self._epochs)
                    tr_err += 1
                    tr_loss += self.soft_margin_loss(X_train[i],Y_train[i])
                self.history_w.append(self._w)
            for i,x in enumerate(X_val):
                val_loss += self.soft_margin_loss(X_val[i], Y_val[i])
                val_err += (Y_val[i]*np.dot(self._w,X_val[i])<1).astype(int)
            if verbose:
                print('epoch {}. Errors={}. Mean Hinge_loss={}'\
                      .format(epoch,err,loss))
            train_errors.append(tr_err)
            val_errors.append(val_err)
            train_loss_epoch.append(tr_loss)
            val_loss_epoch.append(val_loss)
        self.history_w = np.array(self.history_w)
        self.train_errors = np.array(train_errors)
        self.val_errors = np.array(val_errors)
        self.train_loss = np.array(train_loss_epoch)
        self.val_loss = np.array(val_loss_epoch)

    def predict(self, X:np.array) -> np.array:
        y_pred = []
        X_extended = add_bias_feature(X)
        for i in range(len(X_extended)):
            y_pred.append(np.sign(np.dot(self._w,X_extended[i])))
        return np.array(y_pred)

    def hinge_loss(self, x, y):
        return max(0,1 - y*np.dot(x, self._w))

    def soft_margin_loss(self, x, y):
        return self.hinge_loss(x,y)+self._alpha*np.dot(self._w, self._w)
```

- **Імпортуємо вибірку для проведення навчання**

In [5]:
```
iris = load_iris()
X = iris.data
y = iris.target
```

In [6]:
```
print(np.shape(X))
print(np.shape(y))
```

```
(150, 4)
(150,)
```

In [7]:
```
dfIris = pd.DataFrame(data = np.c_[X, y], columns = iris['feature_names'] + ['target'])
dfIris
```

Out[7]:

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	target
0	5.1	3.5	1.4	0.2	0.0
1	4.9	3.0	1.4	0.2	0.0
2	4.7	3.2	1.3	0.2	0.0
3	4.6	3.1	1.5	0.2	0.0
4	5.0	3.6	1.4	0.2	0.0
...	...	...	...	...	...
145	6.7	3.0	5.2	2.3	2.0
146	6.3	2.5	5.0	1.9	2.0
147	6.5	3.0	5.2	2.0	2.0
148	6.2	3.4	5.4	2.3	2.0
149	5.9	3.0	5.1	1.8	2.0

150 rows × 5 columns

In [8]:
```
print(dfIris['target'].unique())
```

```
[0. 1. 2.]
```

- **Проводимо підготовку даних до класифікації:**

In [9]:
```
pca = PCA(n_components=2)
X = pca.fit_transform(X)

y = (y > 0).astype(int)*2-1 # [0,1,2] --> [False,True,True] --> [0,1,1] --> [0,2,2] --> [-1,1,1]
```

In [10]:
```
dfIris2 = pd.DataFrame(data = np.c_[X, y], columns = ['x1', 'x2'] + ['y'])
dfIris2
```

Out[10]:

	x1	x2	y
0	-2.684126	0.319397	-1.0
1	-2.714142	-0.177001	-1.0
2	-2.888991	-0.144949	-1.0
3	-2.745343	-0.318299	-1.0
4	-2.728717	0.326755	-1.0
...	...	...	...
145	1.944110	0.187532	1.0
146	1.527167	-0.375317	1.0
147	1.764346	0.078859	1.0
148	1.900942	0.116628	1.0
149	1.390189	-0.282661	1.0

150 rows × 3 columns

In [11]:
```
sns.scatterplot(x = dfIris2['x1'], y = dfIris2['x2'], hue = dfIris2['y'])
plt.title('Дані з 2-ма класами')
#plt.legend(bbox_to_anchor=(1,1), loc="upper left")
```

Out[11]:
```
Text(0.5, 1.0, 'Дані з 2-ма класами')
```

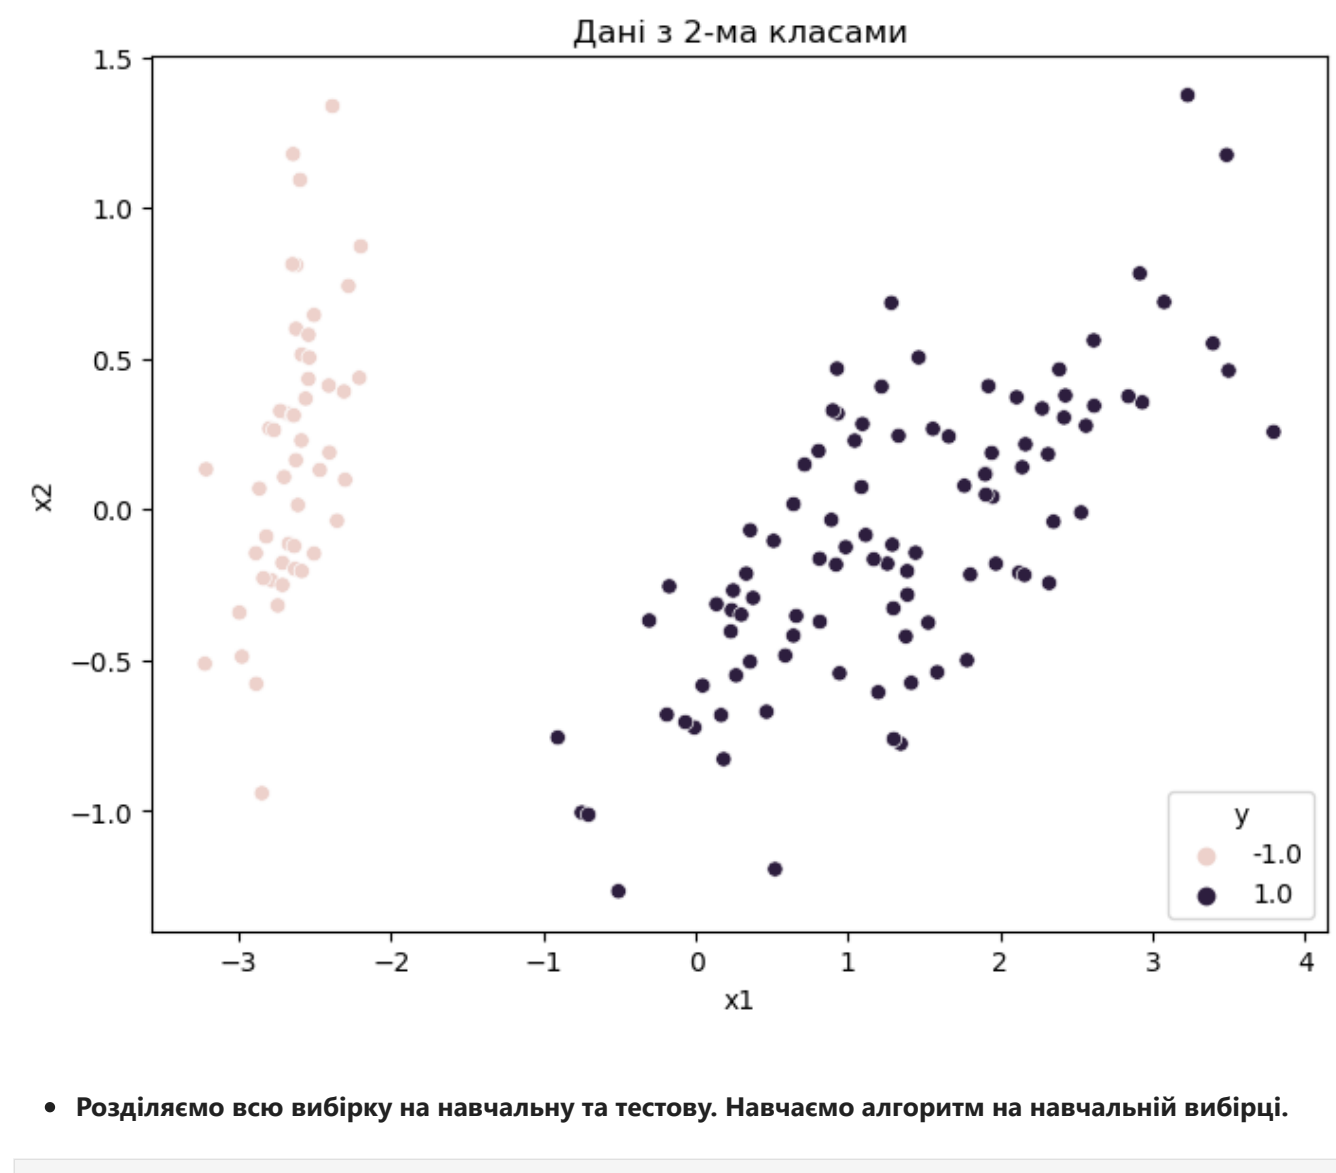

- **Розділяємо всю вибірку на навчальну та тестову. Навчаємо алгоритм на навчальній вибірці.**

In [12]:
```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.25, random_state=2023)
```

In [13]:
```
# блок ініціалізації та навчання
svm = CustomSVM(etha=0.005, alpha=0.006, epochs=150)
svm.fit(X_train, y_train, X_test, y_test)
```

- **Подаємо графічно результат класифікації для навчальної вибірки та залежність помилок від номеру епохи навчання**

In [14]:
```
df_train = pd.DataFrame(data = np.c_[X_train, y_train], columns = ['x1', 'x2'] + ['y'])
display(df_train.head(5))
```

	x1	x2	y
0	1.764346	0.078859	1.0
1	-2.310256	0.391346	-1.0
2	-0.173925	-0.254854	1.0
3	1.971531	-0.179728	1.0
4	0.136429	-0.314032	1.0

In [15]:
```
sns.scatterplot(x = df_train['x1'], y = df_train['x2'], hue = df_train['y'])

# в w0*x_i[0]+w1*x_i[1]+w2*1=0 по черзі
# підставляємо x_i[0]=0, x_i[1]=0
newline([0,-svm._w[2]/svm._w[1]],[-svm._w[2]/svm._w[0],0], 'blue')

# w0*x_i[0] + w1*x_i[1] + w2*1 = 1
newline([0,  1 / svm._w[1]-svm._w[2]/svm._w[1]], [ 1 / svm._w[0]-svm._w[2]/svm._w[0], 0], 'pink')

# w0*x_i[0] + w1*x_i[1] + w2*1 = -1
newline([0, -1 / svm._w[1]-svm._w[2]/svm._w[1]], [-1 / svm._w[0]-svm._w[2]/svm._w[0], 0], 'gold')

plt.xlabel("x1")
plt.ylabel("x2")
plt.title("Результат класифікації для навчальної вибірки" )
plt.legend(bbox_to_anchor=(1,1), loc="upper left", prop={'size': 12})
plt.show()
```

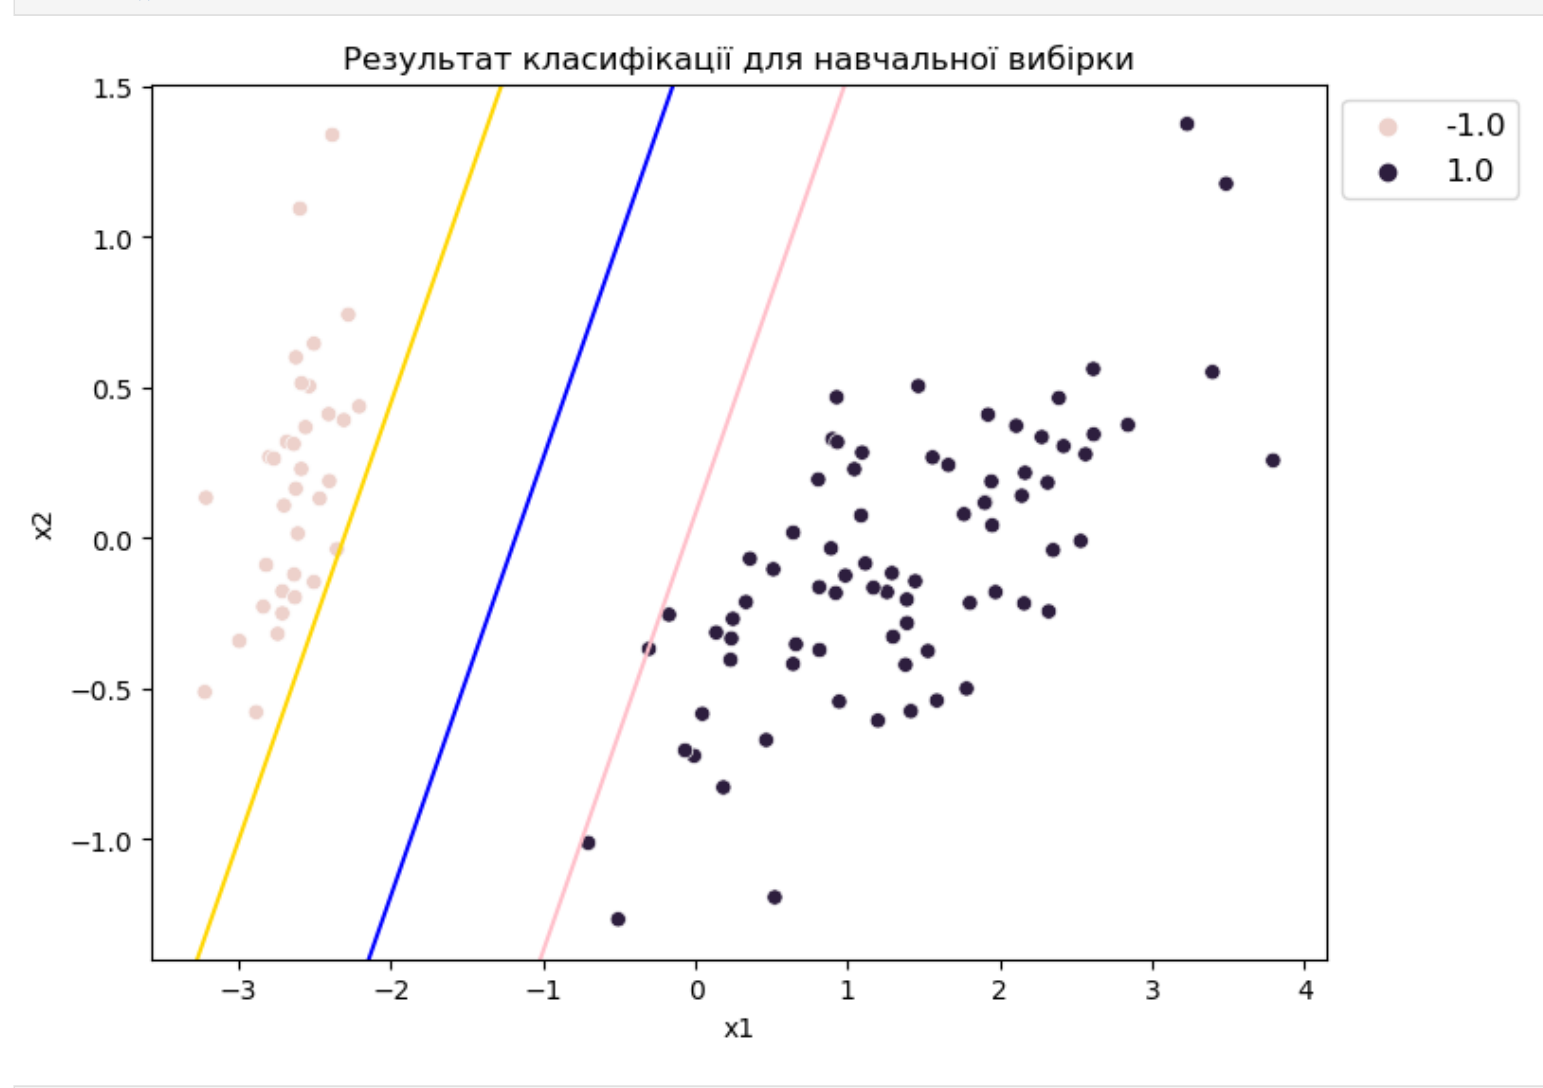

In [16]:
```
print('Кількість помилок у кожну епоху:\n', svm.train_errors, '\n')
print('Значення ваг або коефіцієнтів для прямої w0*x_i[0]+w1*x_i[1]+w2=0 :\n', svm._w)

plt.plot(svm.train_errors, linewidth=2, label='train')
plt.xlabel("Епоха")
plt.ylabel("Кількість помилок")
plt.title("Кількість помилок у кожну епоху на тренувальній вибірці" )
plt.legend(bbox_to_anchor=(1,1), loc="upper left", prop={'size': 12})
plt.show()
```

```
Кількість помилок у кожну епоху:
 [84 36 26 18 15 14 13  8  8  5  5  5  6  4  4  4  4  4  4  4  4  4  4  4
  4  4  4  4  4  3  3  3  1  2  1  1  2  1  1  1  0  0  0  0  0  0  0  0
  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0
  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0
  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0
  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  2  1  0
  0  0  0  0  0  0]

Значення ваг або коефіцієнтів для прямої w0*x_i[0]+w1*x_i[1]+w2=0 :
 [ 0.88713539 -0.61137468  1.0493689 ]
```

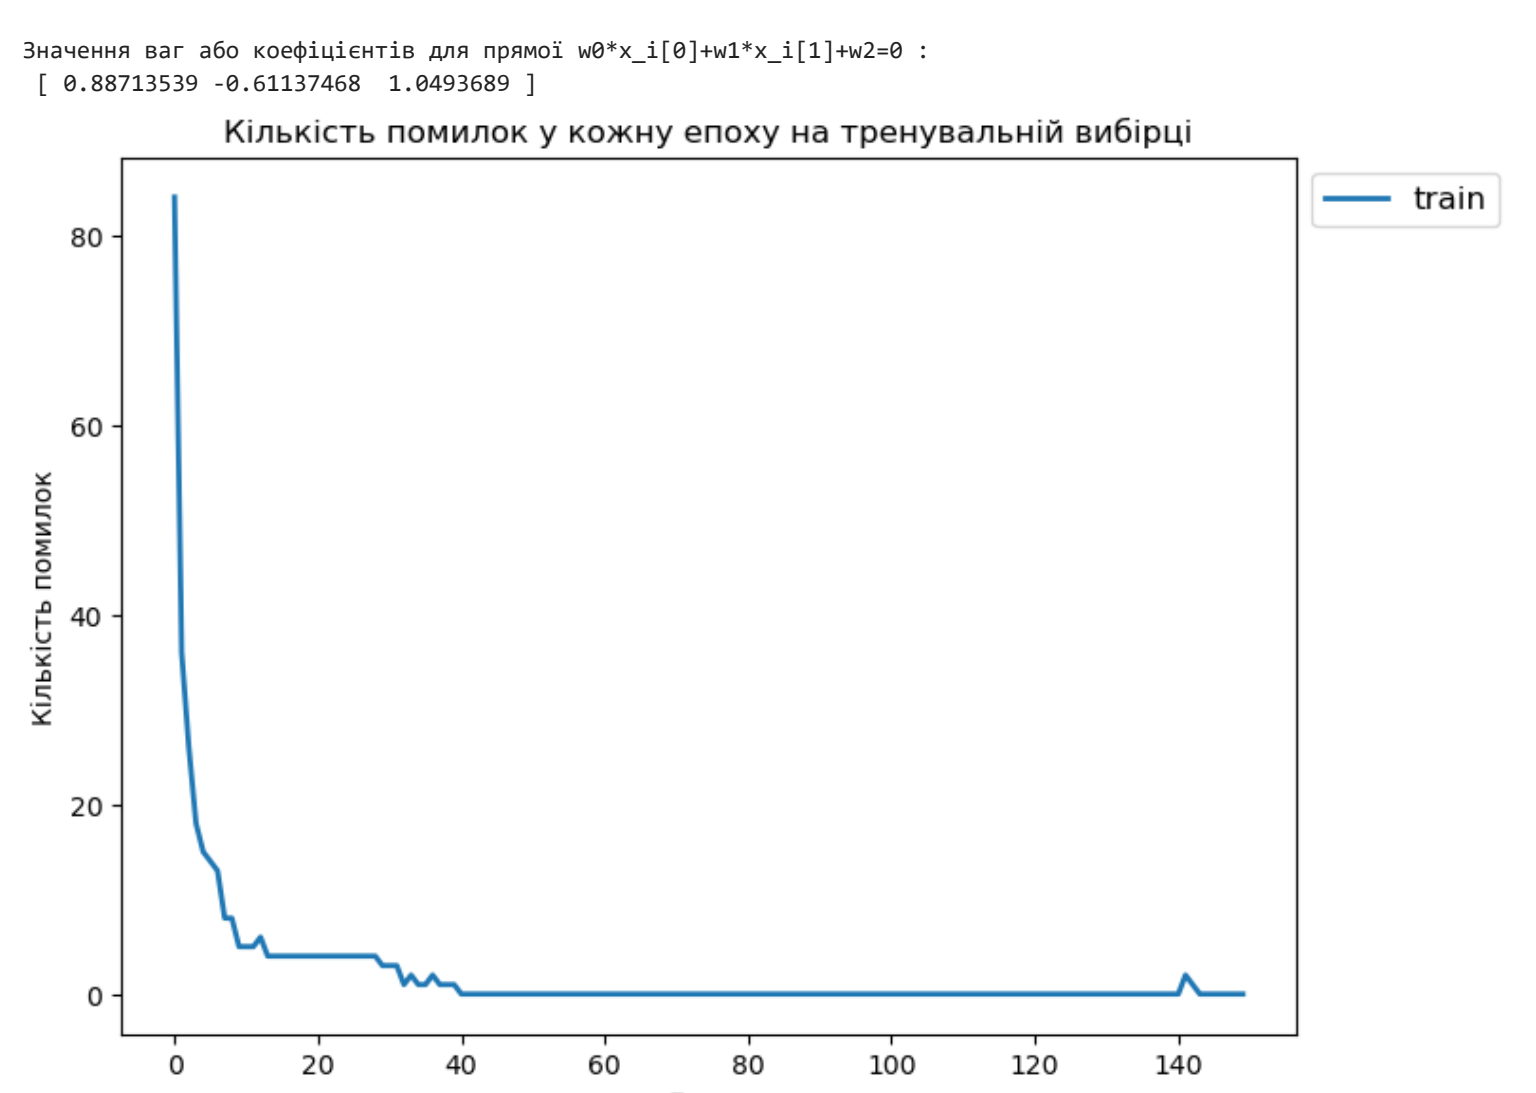

- **Перевіряємо точність роботи алгоритму на тестовій вибірці:**

In [17]:
```
# Прогнозуємо значення на тестовій вибірці
y_predict = svm.predict(X_test)
```

In [18]:
```
# Вимірюємо точність прогнозів
print("Accuracy:", metrics.accuracy_score(y_test, y_predict))
#print("Accuracy score: %.3f" %metrics.accuracy_score(y_test, y_predict))
```

```
Accuracy: 1.0
```

- **Подаємо графічно результат класифікації для тестової вибірки**

In [19]:
```
df_test = pd.DataFrame(data = np.c_[X_test, y_test], columns = ['x1', 'x2'] + ['y'])
display(df_test.head(5))
```

	x1	x2	y
0	2.123609	-0.209729	1.0
1	0.714853	0.149056	1.0
2	0.299001	-0.348898	1.0
3	2.932587	0.355500	1.0
4	1.332024	0.244441	1.0

In [20]:
```
sns.scatterplot(x = df_test['x1'], y = df_test['x2'], hue = df_test['y'])
#d = {-1:'yellow', 1:'blue'}
#plt.scatter(X_test[:,0], X_test[:,1], c=[d[y] for y in y_test], label = d)

# в w0*x_i[0] + w1*x_i[1] + w2*1 = 0 по черзі
# підставляємо x_i[0] = 0, x_i[1] = 0
newline([0, -svm._w[2] / svm._w[1]], [-svm._w[2]/svm._w[0], 0], 'blue')

# w0*x_i[0] + w1*x_i[1] + w2*1 = 1
newline([0,  1 / svm._w[1]-svm._w[2]/svm._w[1]], [ 1 / svm._w[0]-svm._w[2]/svm._w[0], 0], 'pink')

# w0*x_i[0] + w1*x_i[1] + w2*1 = -1
newline([0, -1 / svm._w[1]-svm._w[2]/svm._w[1]], [-1 / svm._w[0]-svm._w[2]/svm._w[0], 0], 'gold')

plt.xlabel("x1")
plt.ylabel("x2")
plt.title("Результат класифікації для тестової вибірки" )
plt.legend(bbox_to_anchor=(1,1), loc="upper left", prop={'size': 12})
plt.show()
```

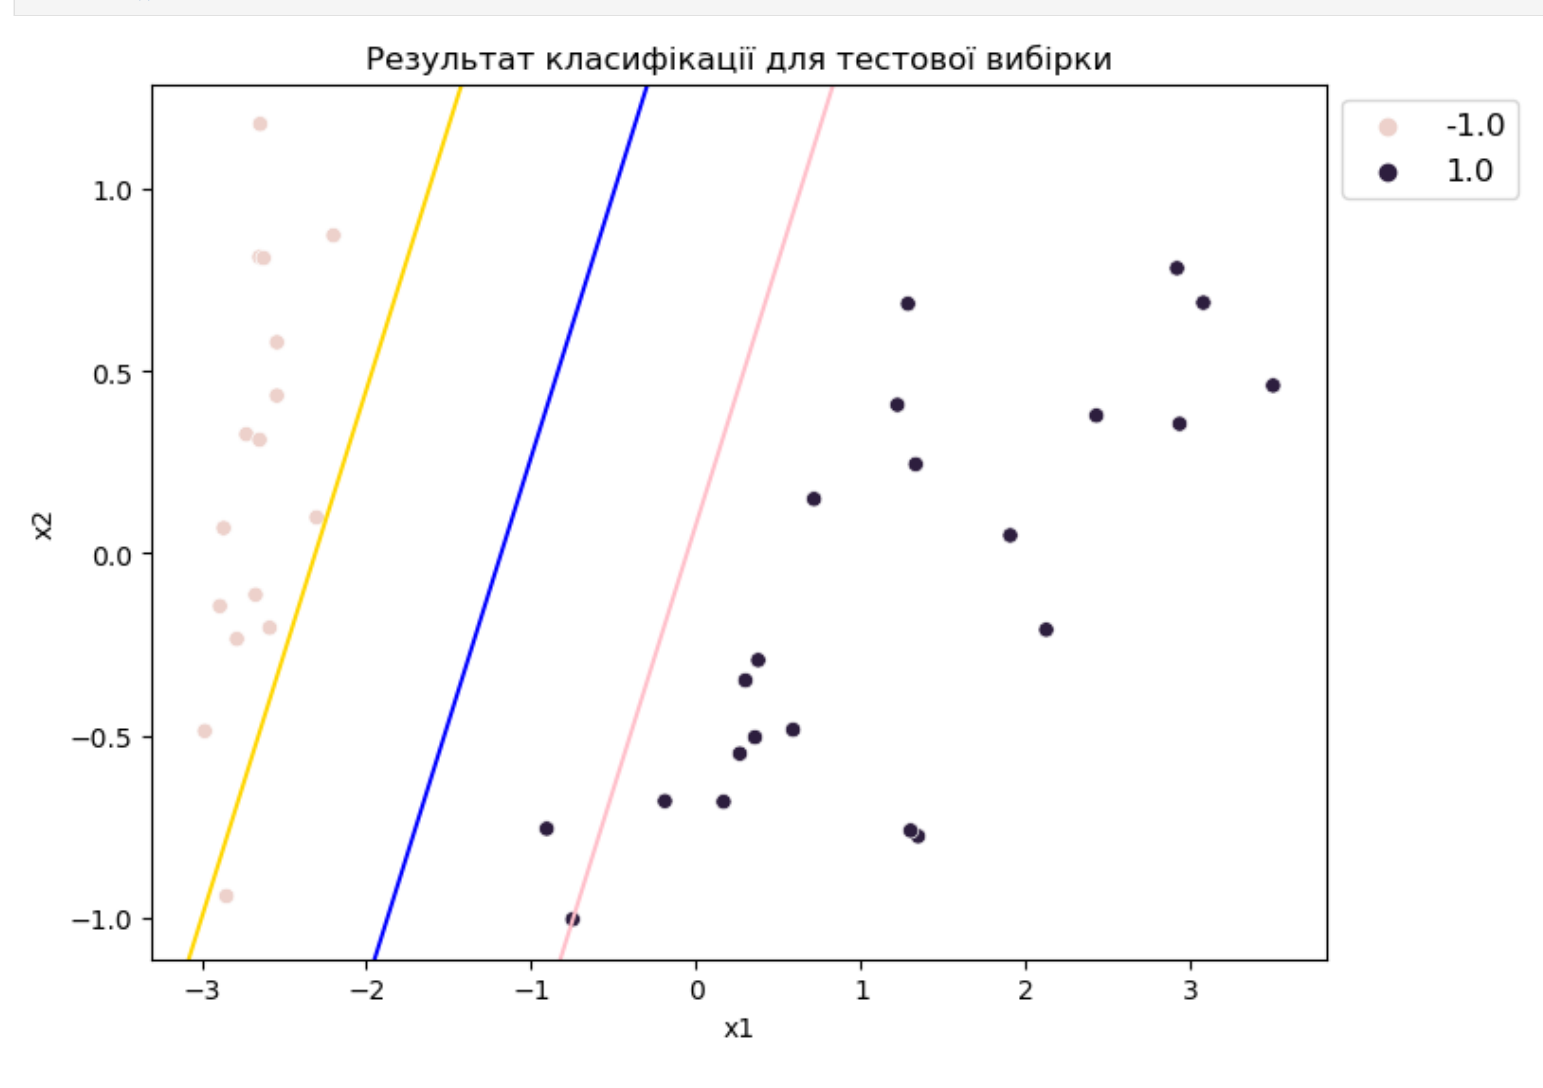

- Побудуємо функції втрат навчальної та тестовоої вибірки.

In [21]:
```
plt.plot(svm.train_loss, linewidth=2, label='train_loss')
plt.plot(svm.val_loss, linewidth=2, label='test_loss', c = 'c')
plt.ylabel("Значення функції втрат")
plt.title("Функція втрат" )
plt.legend(bbox_to_anchor=(1,1), loc="upper left", prop={'size': 12})
plt.show()
```

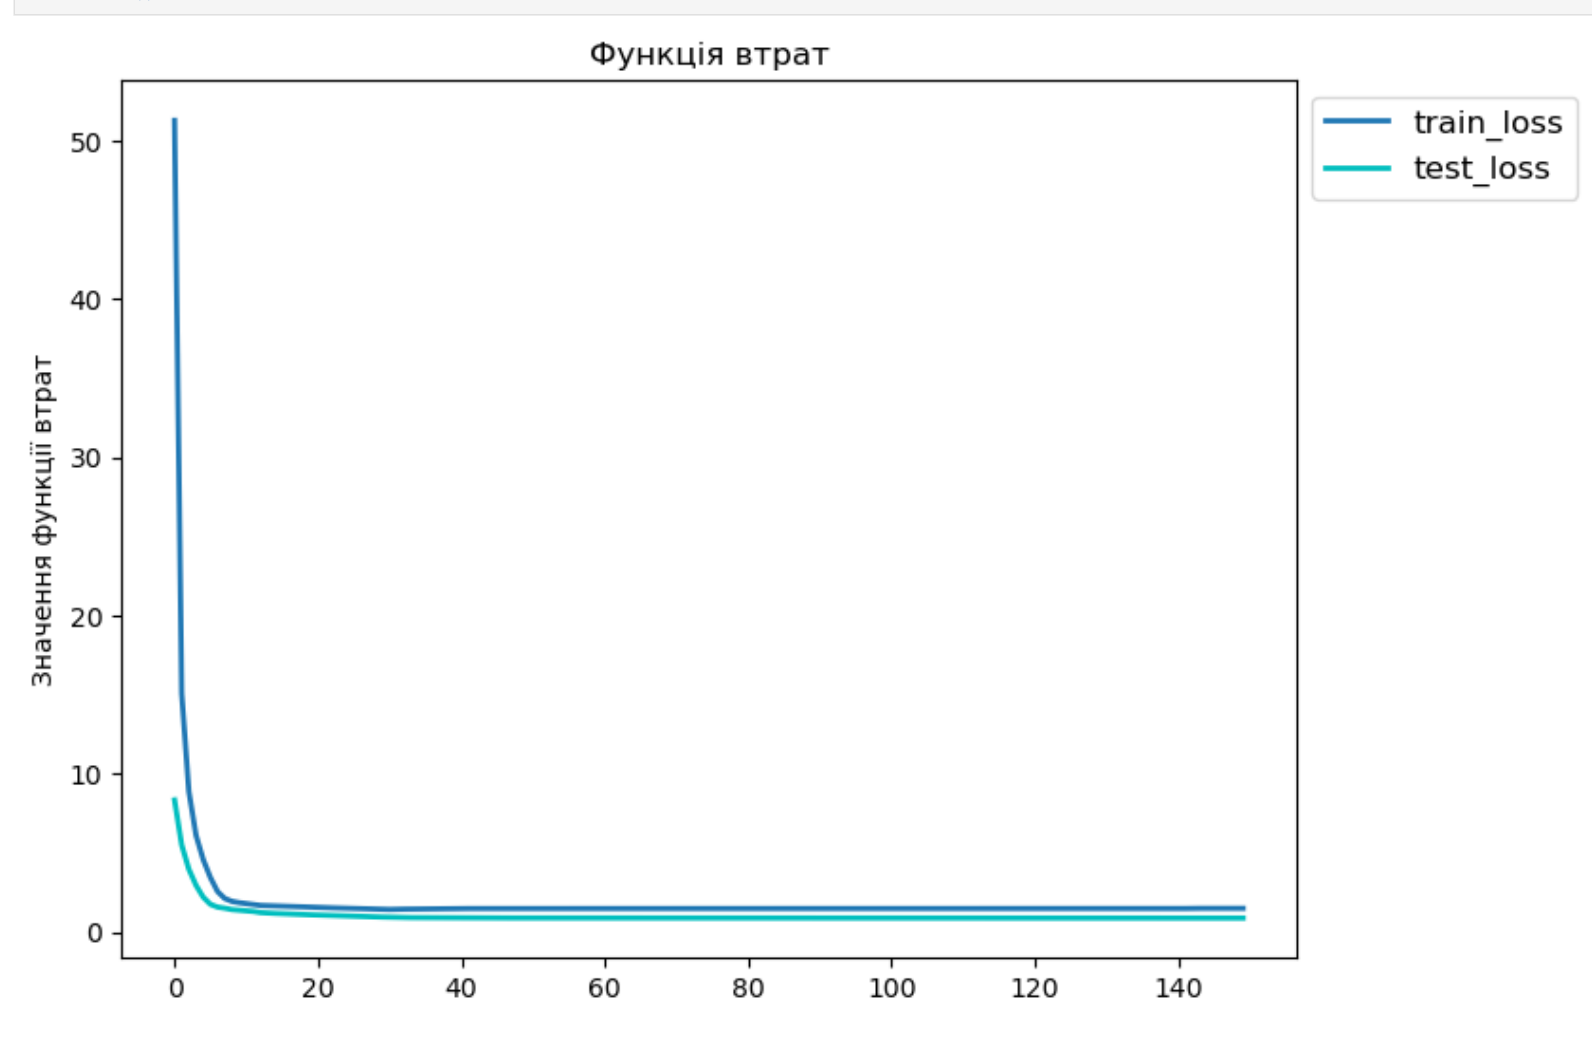

- **Порівняємо результати з SVM з sklearn.**

In [22]:
```
#Import svm model
from sklearn import svm

# Створюємо svm Класифікатор
clf = svm.SVC(kernel='linear') # Linear Kernel

# Навчаємо модель за допомогою навчальних наборів
clf.fit(X_train, y_train)

# Прогнозуємо значення цільової змінної для тестового набору даних
y_pred = clf.predict(X_test)
```

In [23]:
```
# Вимірюємо точність прогнозів
print("Accuracy:", metrics.accuracy_score(y_test, y_pred))
#print("Accuracy score: %.3f" %metrics.accuracy_score(y_test, y_predict))
```

```
Accuracy: 1.0
```

Отже, результати співпадають.

Машинне навчання

Метод головних компонент (PCA)

Лабораторна робота 4

Студентка Пороскун Олена. Група ПМ.м-21

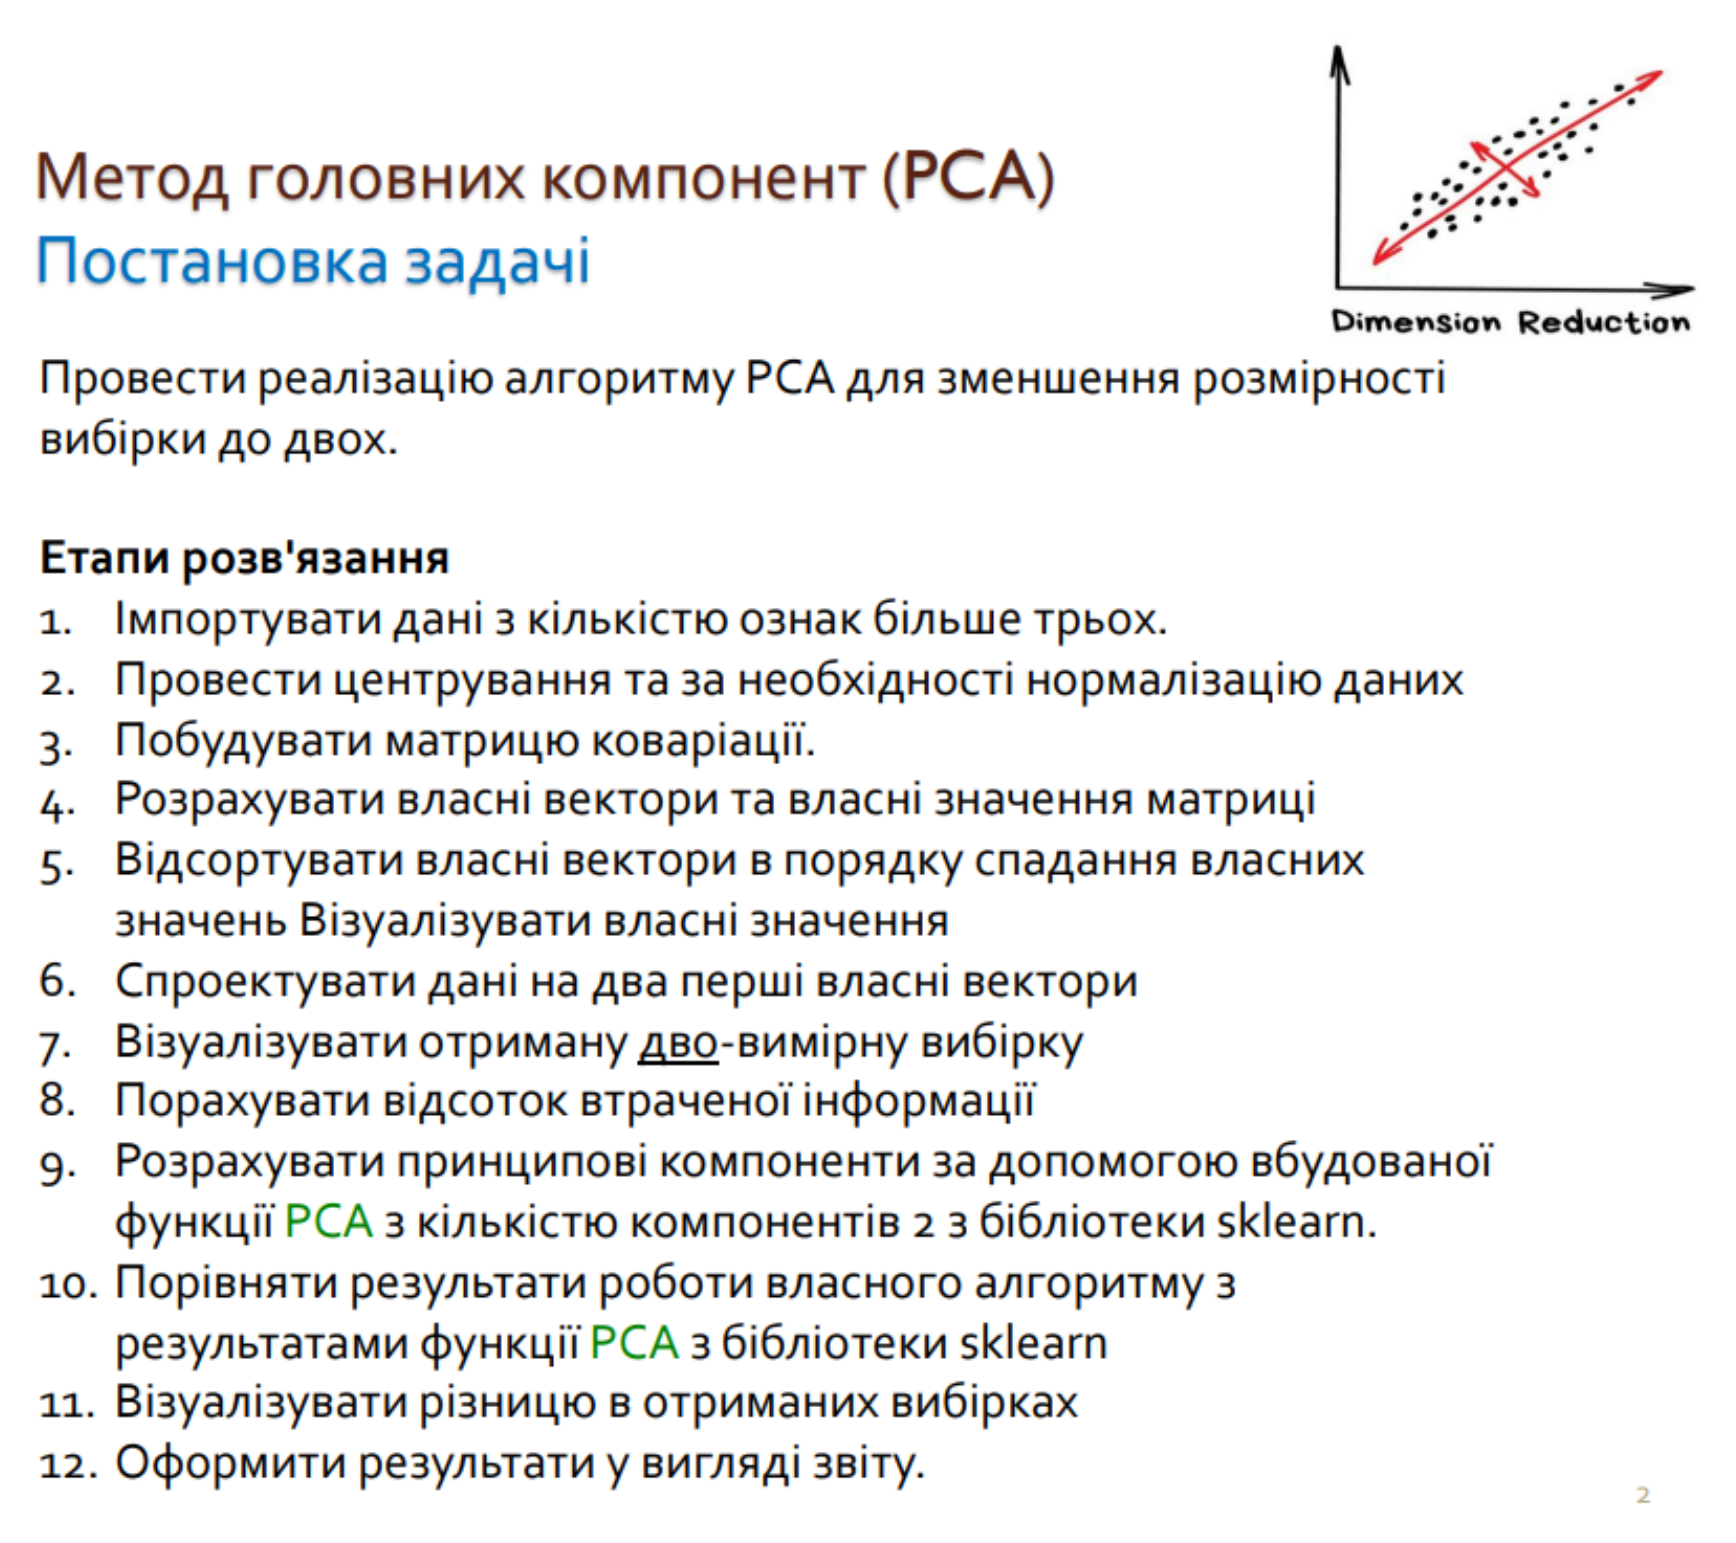
Dimension Reduction

Метод головних компонент (PCA)
Постановка задачі

Провести реалізацію алгоритму PCA для зменшення розмірності вибірки до двох.

Етапи розв'язання

1. Імпортувати дані з кількістю ознак більше трьох.
2. Провести центрування та за необхідності нормалізацію даних
3. Побудувати матрицю коваріації.
4. Розрахувати власні вектори та власні значення матриці
5. Відсортувати власні вектори в порядку спадання власних значень Візуалізувати власні значення
6. Спроектувати дані на два перші власні вектори
7. Візуалізувати отриману дво-вимірну вибірку
8. Порахувати відсоток втраченої інформації
9. Розрахувати принципові компоненти за допомогою вбудованої функції PCA з кількістю компонентів 2 з бібліотеки sklearn.
10. Порівняти результати роботи власного алгоритму з результатами функції PCA з бібліотеки sklearn
11. Візуалізувати різницю в отриманих вибірках
12. Оформити результати у вигляді звіту.

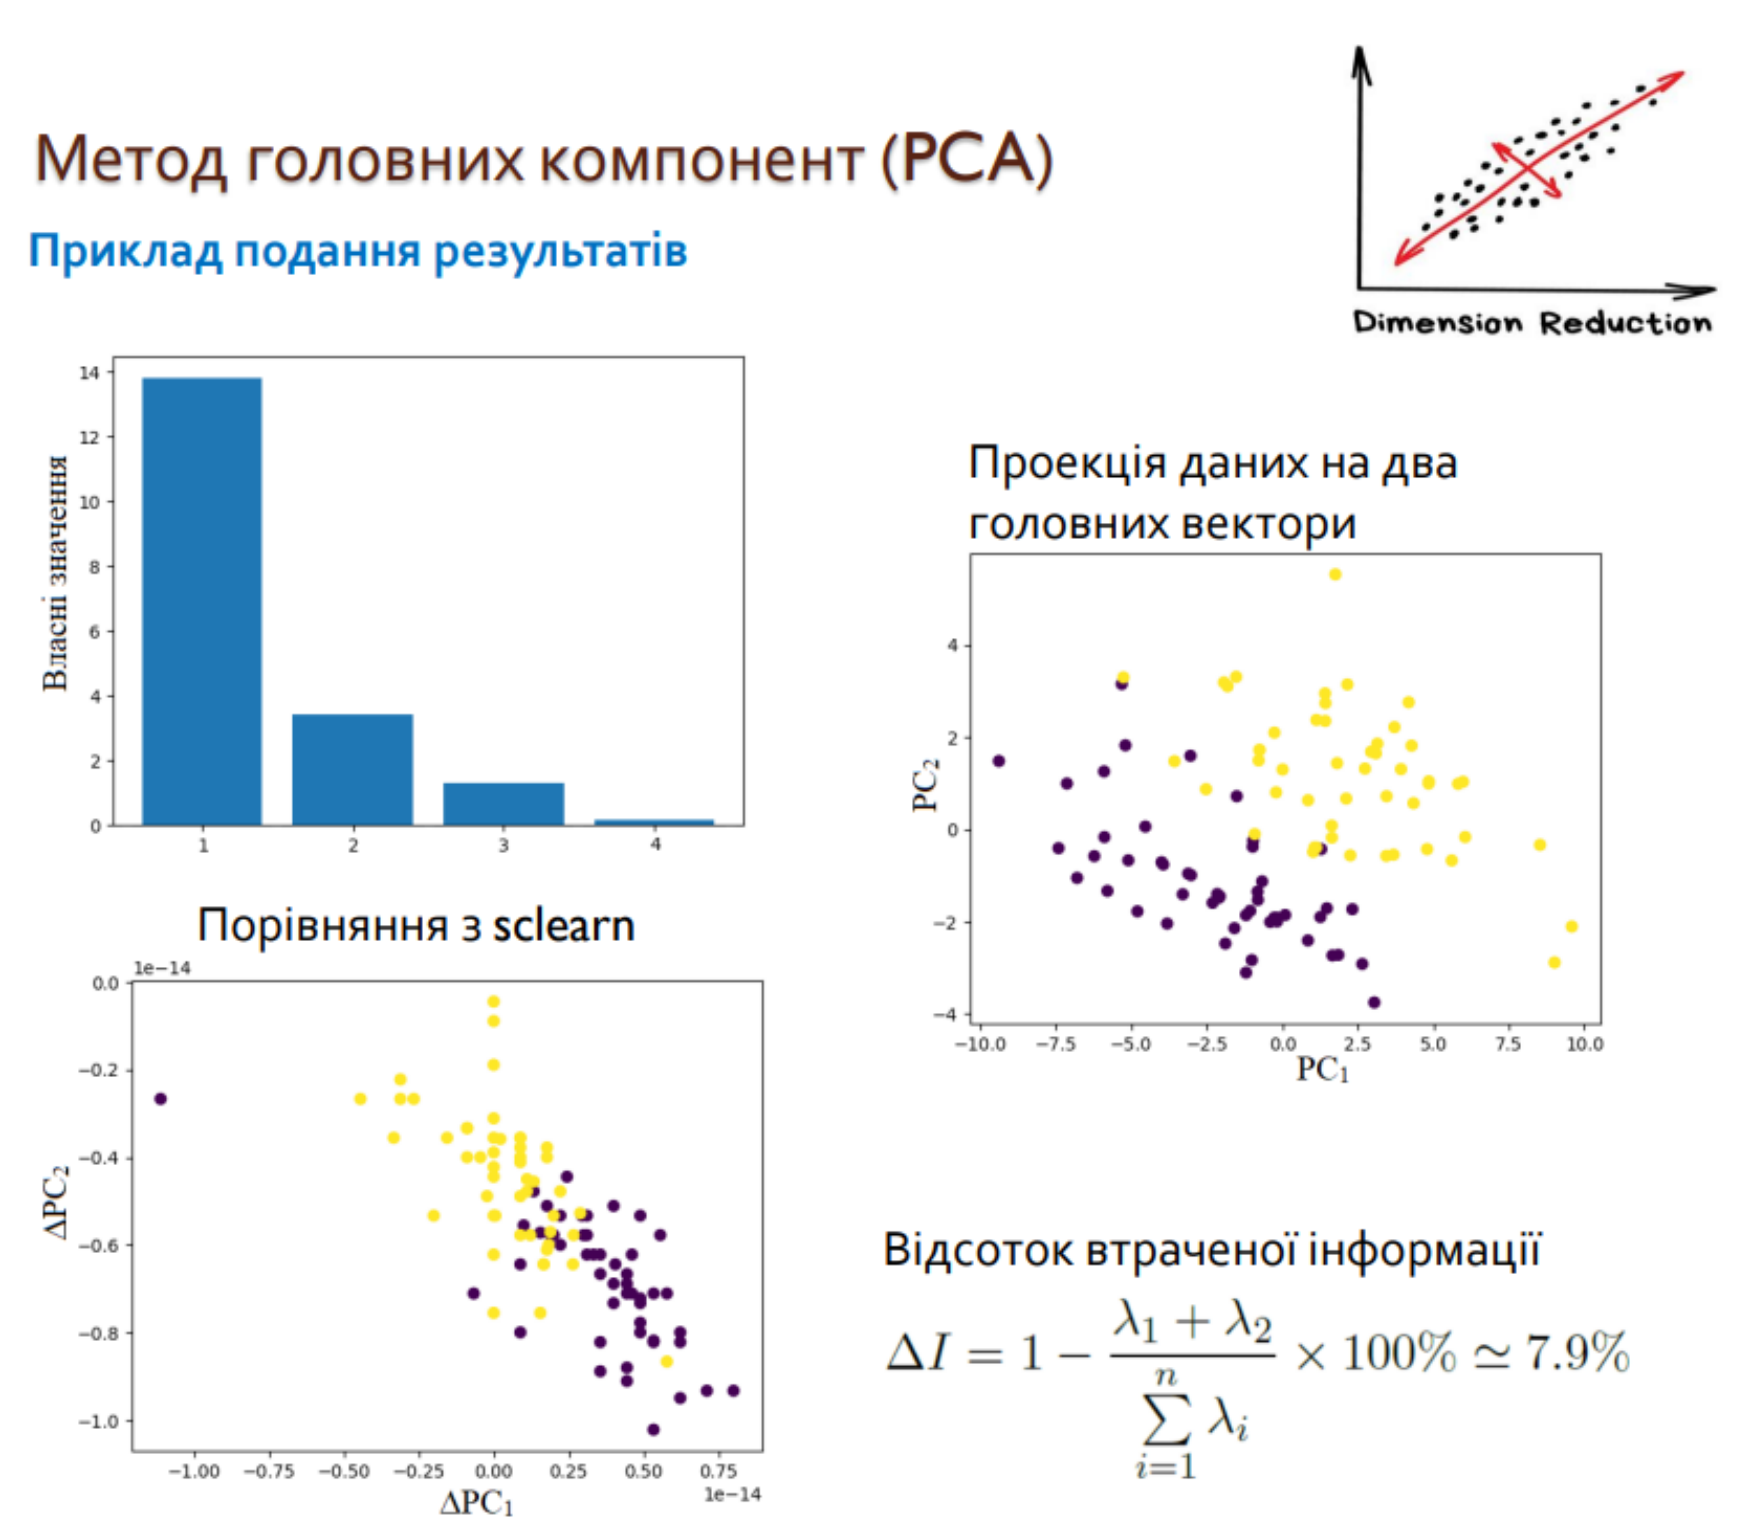

Метод головних компонент (PCA)
Приклад подання результатів

Проекція даних на два головних вектори

Порівняння з sclearn

Відсоток втраченої інформації

$$\Delta I = 1 - \frac{\lambda_1 + \lambda_2}{\sum_{i=1}^{n} \lambda_i} \times 100\% \simeq 7.9\%$$

- **Імпортуємо потрібні бібліотеки:**

In [1]:
```
#!pip install seaborn
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
```

In [2]:
```
import warnings
warnings.filterwarnings('ignore')
```

In [3]:
```
from sklearn.datasets import load_iris
from sklearn.decomposition import PCA
from sklearn.model_selection import train_test_split
#from sklearn import metrics
```

1. Імпортувати дані з кількістю ознак більше трьох.

In [4]:
```
iris = load_iris()
features = iris.data
target = iris.target
```

In [5]:
```
print(np.shape(features))
print(np.shape(target))
```
```
(150, 4)
(150,)
```

In [6]:
```
dfIris = pd.DataFrame(data = np.c_[features, target], columns = iris['feature_names'] + ['target'])
dfIris
```

Out[6]:

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	target
0	5.1	3.5	1.4	0.2	0.0
1	4.9	3.0	1.4	0.2	0.0
2	4.7	3.2	1.3	0.2	0.0
3	4.6	3.1	1.5	0.2	0.0
4	5.0	3.6	1.4	0.2	0.0
...	...	...	...	...	...
145	6.7	3.0	5.2	2.3	2.0
146	6.3	2.5	5.0	1.9	2.0
147	6.5	3.0	5.2	2.0	2.0
148	6.2	3.4	5.4	2.3	2.0
149	5.9	3.0	5.1	1.8	2.0

150 rows × 5 columns

In [7]:
```
print(dfIris['target'].unique())
```
```
[0. 1. 2.]
```

In [8]:
```
sns.pairplot(dfIris, hue ='target', palette = "flare")
plt.show()
```

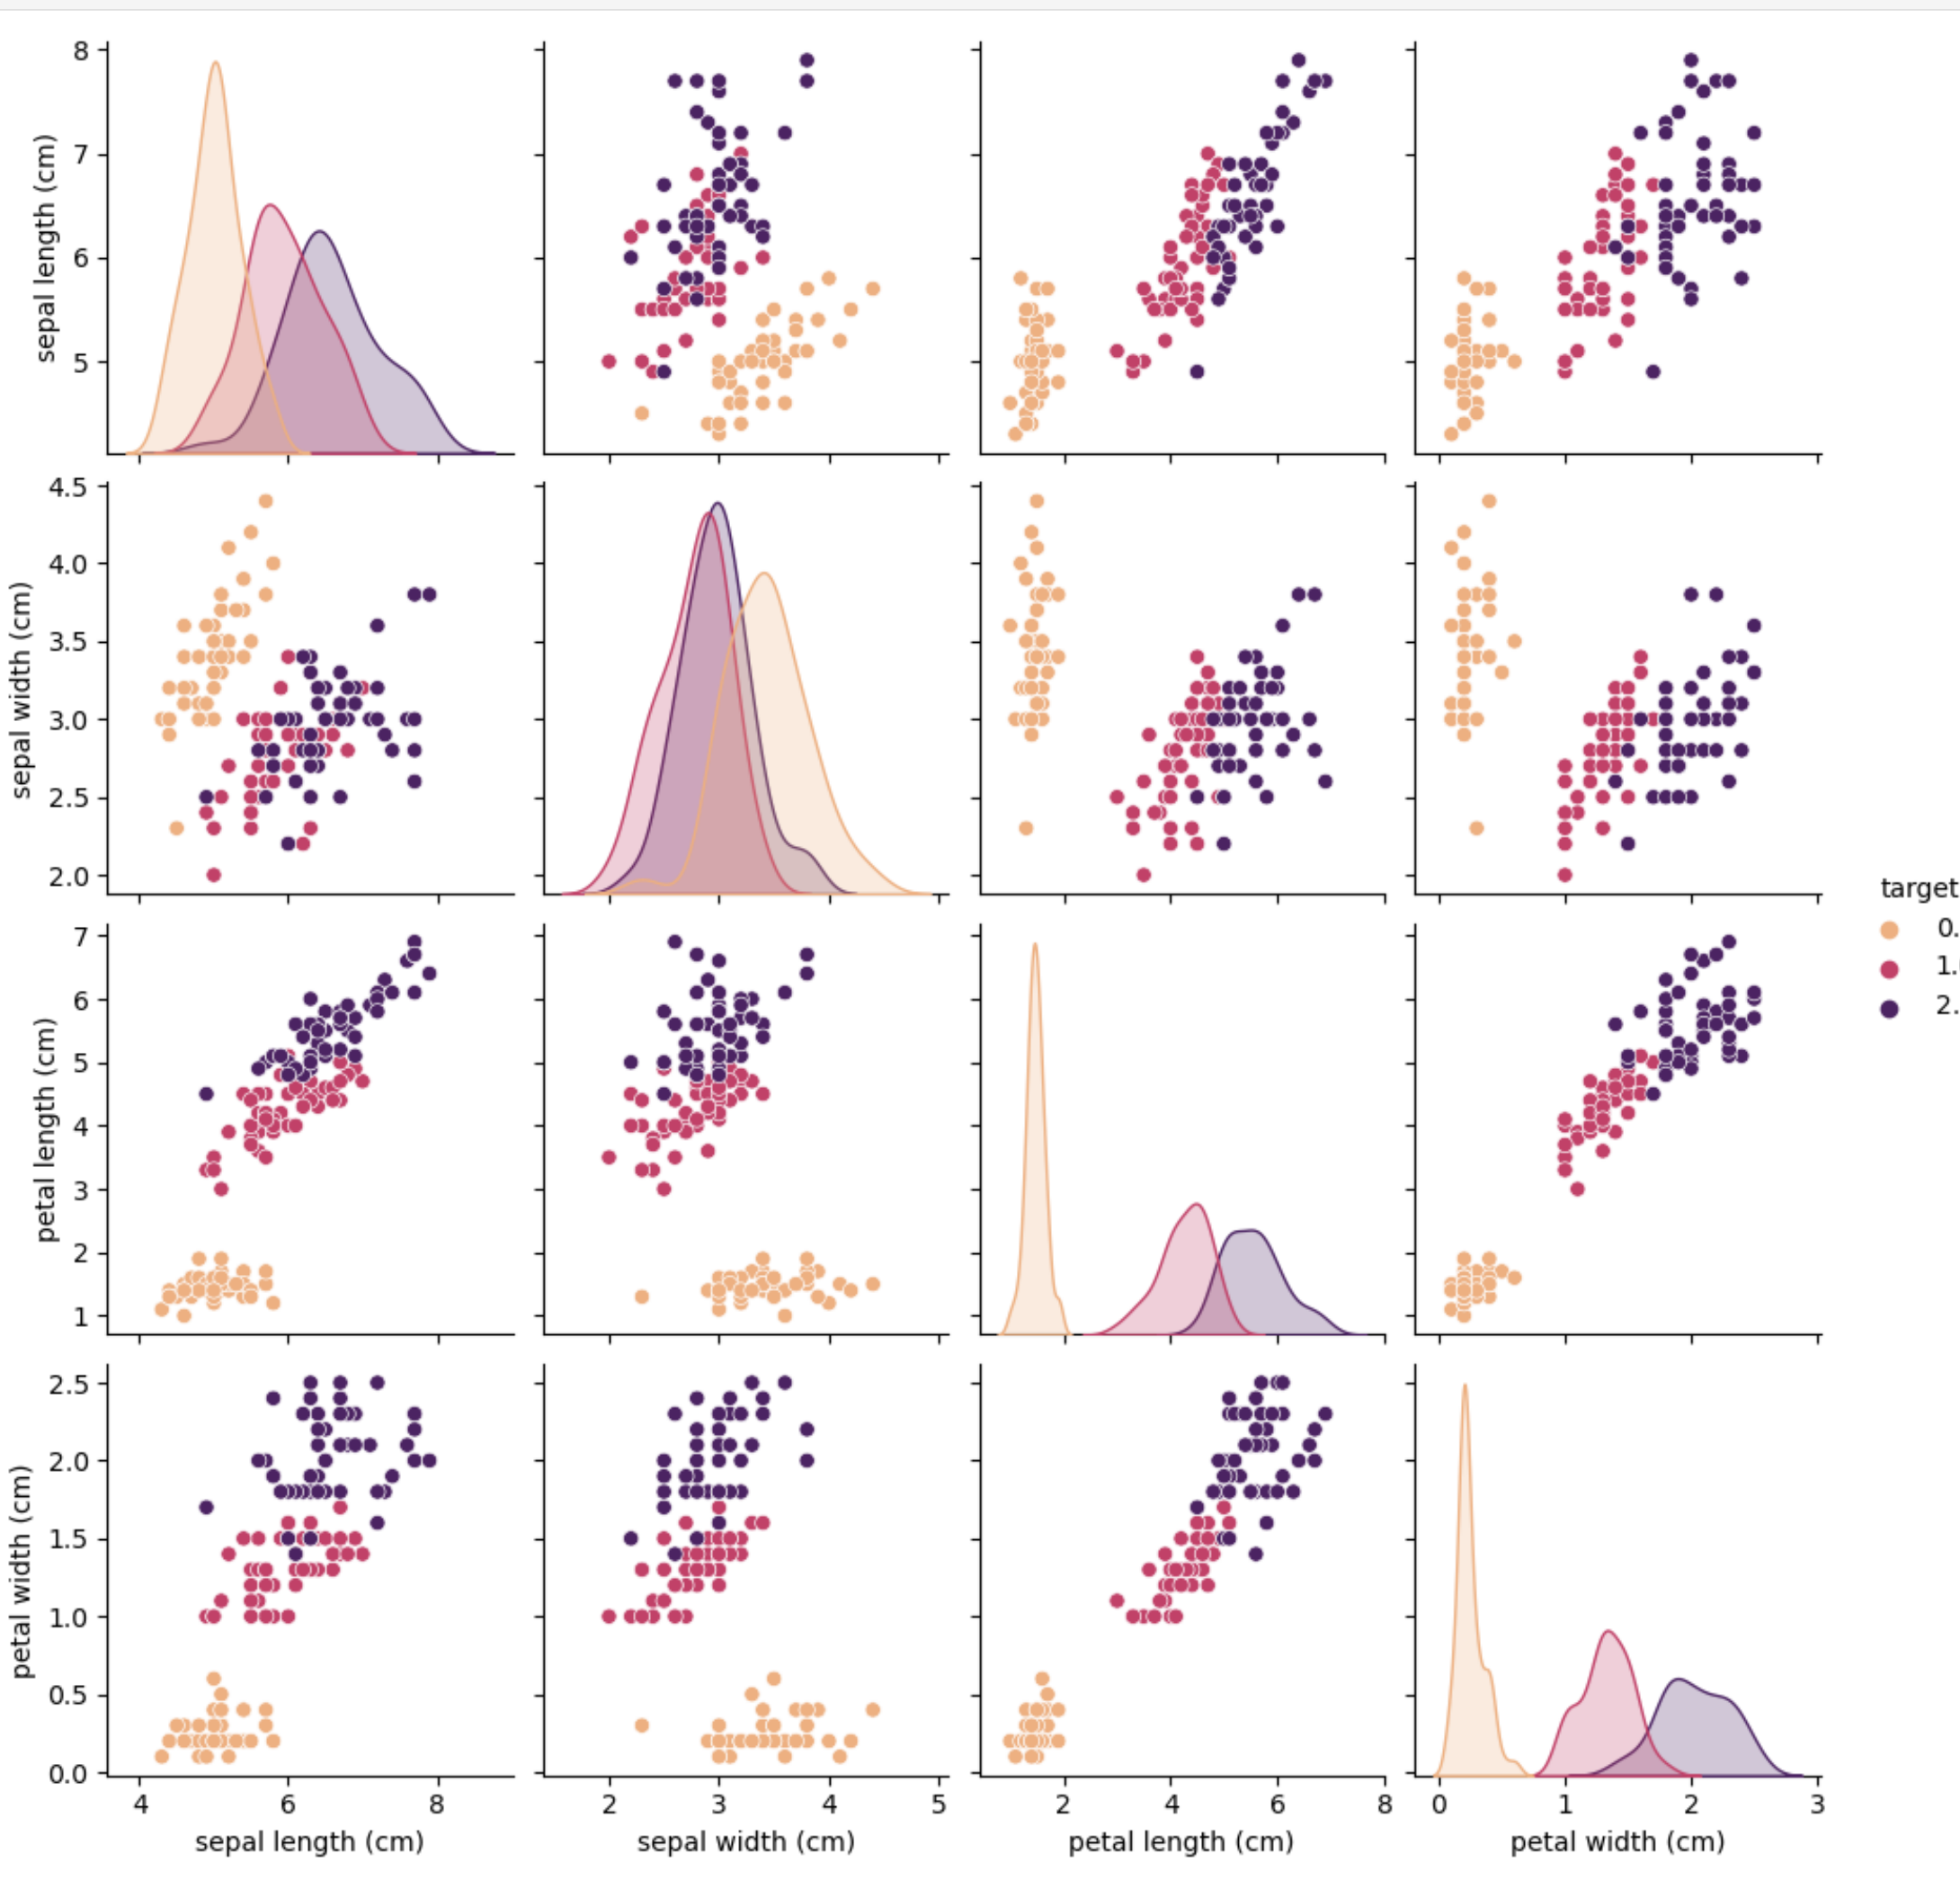

Оскільки перший клас добре виділяється від інших двох залишимо у вибірці лише дані для другого та третього класів. Отримуємо вибірку X = [ℓ×n], де ℓ – кількість об'єктів, n – кількість ознак (для даного прикладу n = 4).

In [9]:
```
dfIris2 = dfIris.query("`target` != 0")
dfIris2
```

Out[9]:

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	target
50	7.0	3.2	4.7	1.4	1.0
51	6.4	3.2	4.5	1.5	1.0
52	6.9	3.1	4.9	1.5	1.0
53	5.5	2.3	4.0	1.3	1.0
54	6.5	2.8	4.6	1.5	1.0
...	...	...	...	...	...
145	6.7	3.0	5.2	2.3	2.0
146	6.3	2.5	5.0	1.9	2.0
147	6.5	3.0	5.2	2.0	2.0
148	6.2	3.4	5.4	2.3	2.0
149	5.9	3.0	5.1	1.8	2.0

100 rows × 5 columns

In [10]:
```
dfIris2['target'].unique()
```

Out[10]:
```
array([1., 2.])
```

In [11]:
```
X = np.array((dfIris2.drop(columns='target')).values)
X[:5]
```

Out[11]:
```
array([[7. , 3.2, 4.7, 1.4],
       [6.4, 3.2, 4.5, 1.5],
       [6.9, 3.1, 4.9, 1.5],
       [5.5, 2.3, 4. , 1.3],
       [6.5, 2.8, 4.6, 1.5]])
```

In [12]:
```
#y = np.array((dfIris2.drop(columns=['sepal length (cm)','sepal width (cm)','petal length (cm)','petal width (cm)'])).values)
#y
```

2. Провести центрування та за необхідності нормалізацію даних.

In [13]:
```
from sklearn.preprocessing import StandardScaler
# масштабування даних
x_scaled = StandardScaler().fit_transform(X)
```

In [14]:
```
X[0]
```

Out[14]:
```
array([7. , 3.2, 4.7, 1.4])
```

In [15]:
```
x_scaled[0]
```

Out[15]:
```
array([ 1.11900931,  0.99068792, -0.25077906, -0.65303909])
```

In [16]:
```
x_matrix = np.array([x_scaled[:, 0], x_scaled[:, 1], x_scaled[:, 2], x_scaled[:, 3]])
```

3. Побудувати матрицю коваріації.

In [17]:
```
covmat = np.cov(x_matrix)
covmat
```

Out[17]:
```
array([[1.01010101, 0.55944934, 0.83684713, 0.59970648],
       [0.55944934, 1.01010101, 0.52505282, 0.57192176],
       [0.83684713, 0.52505282, 1.01010101, 0.83166424],
       [0.59970648, 0.57192176, 0.83166424, 1.01010101]])
```

In [18]:
```
np.shape(covmat)
```

Out[18]:
```
(4, 4)
```

4. Розрахувати власні вектори та власні значення матриці.

In [19]:
```
w, v = np.linalg.eig(covmat)
print('Власні значення (вектор):\n', w)
```
```
Власні значення (вектор):
 [2.98778909 0.08206412 0.40983199 0.56071884]
```

In [20]:
```
print('Власні вектори(масив):\n', v)
```
```
Власні вектори(масив):
 [[-0.5071303  -0.4623842  -0.69307315  0.22061124]
 [-0.43474966  0.13624797 -0.05558682 -0.88844771]
 [-0.54369524  0.74828559  0.01943532  0.37958719]
 [-0.5081408  -0.45574777  0.71845806  0.13380926]]
```

Відповідність власних значень та векторів:

- w[0] відповідає 0-му стовпчику v (v[:,0]),
- w[1] відповідає 1-му стовпчику v (v[:,1]),
- w[i] відповідає i-му стовпчику v (v[:,i]).

In [21]:
```
w[0]
```

Out[21]:
```
2.9877890906474667
```

In [22]:
```
v[:,0]
```

Out[22]:
```
array([-0.5071303 , -0.43474966, -0.54369524, -0.5081408 ])
```

Перевірка $Au = w_1 u$:

In [23]:
```
u = v[:, 1]
print('u ', u)

w1 = w[1]
print('w1 ', w1, '\n')

print('Au \t', np.dot(covmat, u))
print('w1 u \t', w1*u)
```
```
u  [-0.4623842   0.13624797  0.74828559 -0.45574777]
w1  0.08206411695786031

Au      [-0.03794515  0.01118107  0.0614074  -0.03740054]
w1 u    [-0.03794515  0.01118107  0.0614074  -0.03740054]
```

5. Відсортувати власні вектори в порядку спадання власних значень. Візуалізувати власні значення.

In [24]:
```
data = [('1', w[0]),
        ('2', w[1]),
        ('3', w[2]),
        ('4', w[3])]
df = pd.DataFrame(data, columns =['№ ознаки', 'Власне значення'])
df
```

Out[24]:

	№ ознаки	Власне значення
0	1	2.987789
1	2	0.082064
2	3	0.409832
3	4	0.560719

In [25]:
```
plt.bar(df['№ ознаки'], df['Власне значення'])
plt.ylabel('Власні значення')
plt.title('Власні значення')
```

Out[25]:
```
Text(0.5, 1.0, 'Власні значення')
```

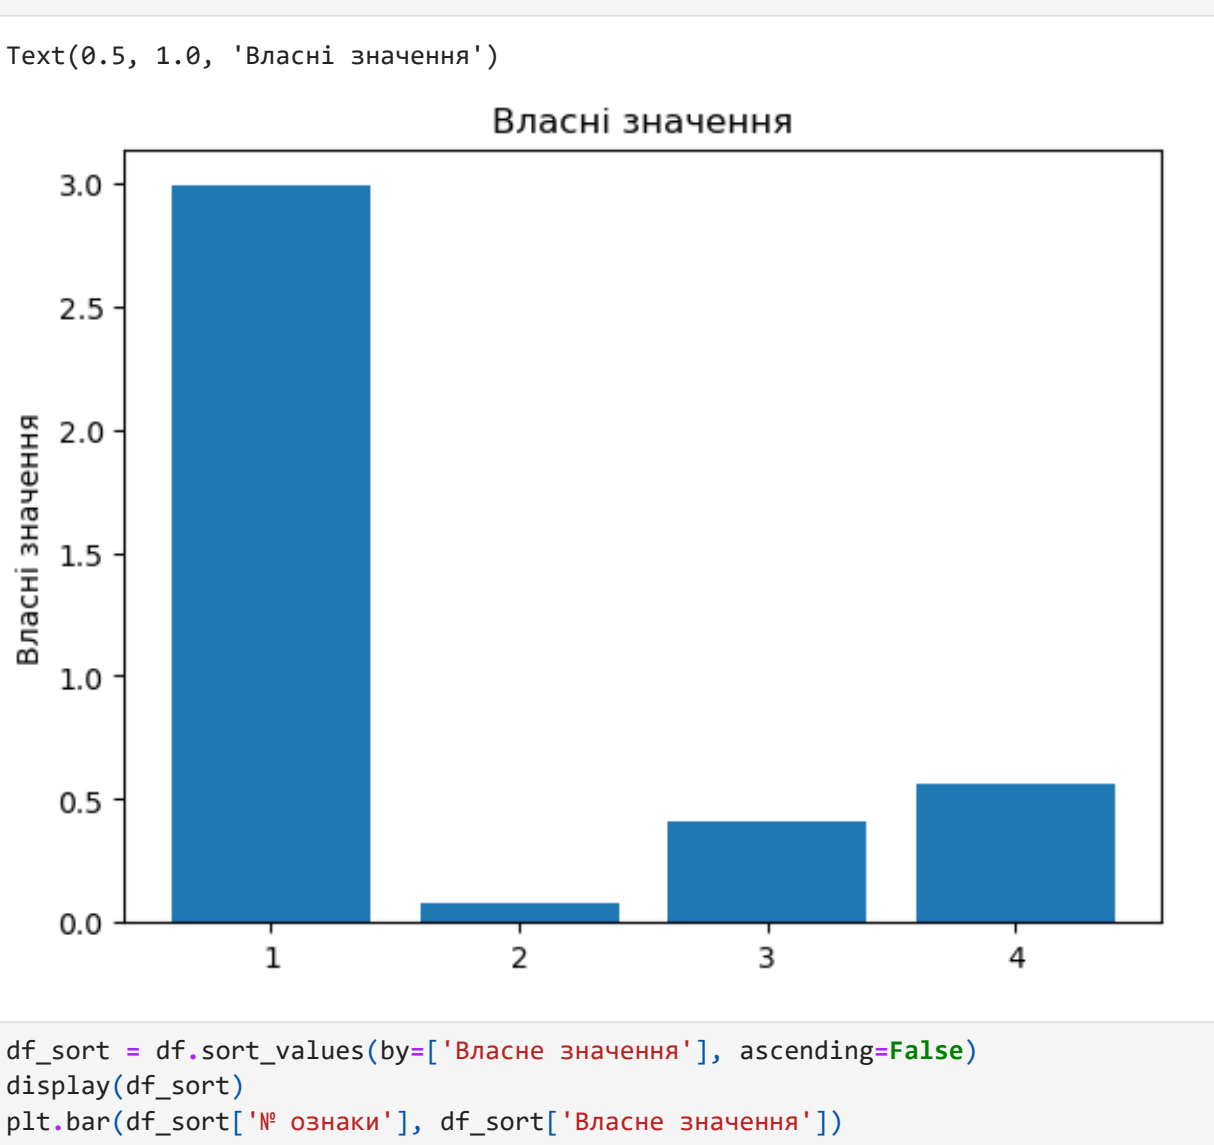

In [26]:
```
df_sort = df.sort_values(by=['Власне значення'], ascending=False)
display(df_sort)
plt.bar(df_sort['№ ознаки'], df_sort['Власне значення'])
plt.ylabel('Власні значення')
plt.title('Власні значення (відсортовані за спаданням)')
```

	№ ознаки	Власне значення
0	1	2.987789
3	4	0.560719
2	3	0.409832
1	2	0.082064

Out[26]:
```
Text(0.5, 1.0, 'Власні значення (відсортовані за спаданням)')
```

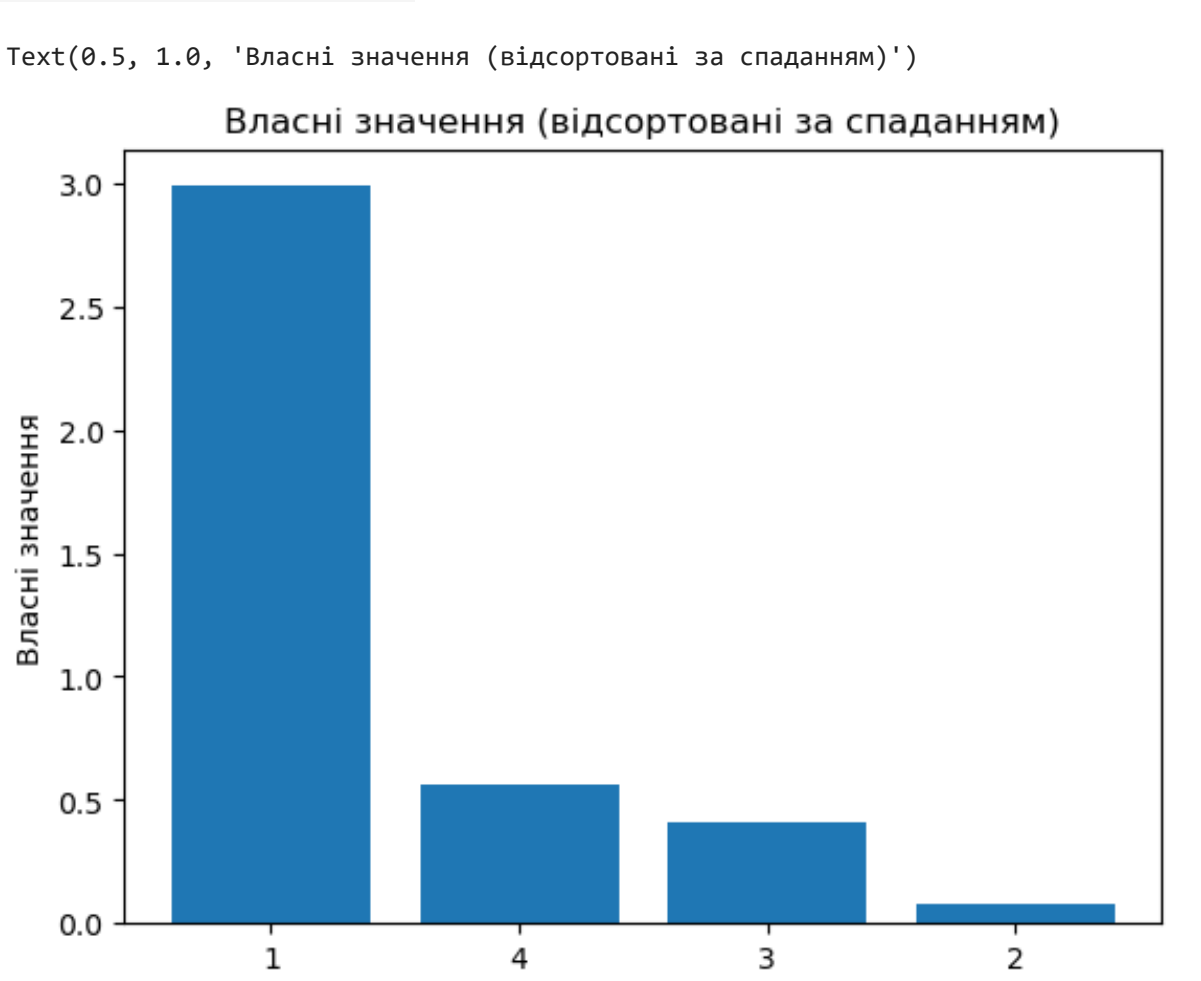

6. Спроектувати дані на два перші власні вектори. Встановимо кількість головних компонент $nPC = 2$. Проектуємо дані на перші два власні вектори матриці коваріації, що характеризуються найбільшими власними значеннями.

Множимо вихідну матрицюданих розміру $[\ell \times n]$ на транспоновану матрицю двох власних векторів розміру $[n \times nPC]$ для отримання нової матриці даних розміром $[\ell \times nPC]$. Візуалізуємо отримані дані.

In [27]:
```
np.shape(x_scaled) # [ℓ × n]
```

Out[27]:
```
(100, 4)
```

In [28]:
```
index1, index2 = (df_sort['№ ознаки'].head(2)).values
index1, index2 = int(index1), int(index2)
print(index1, index2)
```
```
1 4
```

In [29]:
```
eigenvectors = np.array([v[index1-1], v[index2-1]])
vT = eigenvectors.transpose()
print(np.shape(vT)) # [n × nPC]
print(vT)
```
```
(4, 2)
[[-0.5071303  -0.5081408 ]
 [-0.4623842  -0.45574777]
 [-0.69307315  0.71845806]
 [ 0.22061124  0.13380926]]
```

In [30]:
```
x_new = np.dot(x_scaled, vT)
np.shape(x_new) # [ℓ × nPC]
```

Out[30]:
```
(100, 2)
```

7. Візуалізувати отриману дво-вимірну вибірку.

In [31]:
```
lab = dfIris2['target'].unique()
plt.plot(x_new, 'o', markersize = 5,
         #markerfacecolor='white',
         #markeredgecolor='gray',
         markeredgewidth = 2, label=lab)

plt.xlabel('PC1')
plt.ylabel('PC2')
plt.title('Проекція даних на два головних вектори')
plt.legend(bbox_to_anchor=(1,1), loc="upper left", prop={'size': 12})
```

Out[31]:
```
<matplotlib.legend.Legend at 0x220a26b86a0>
```

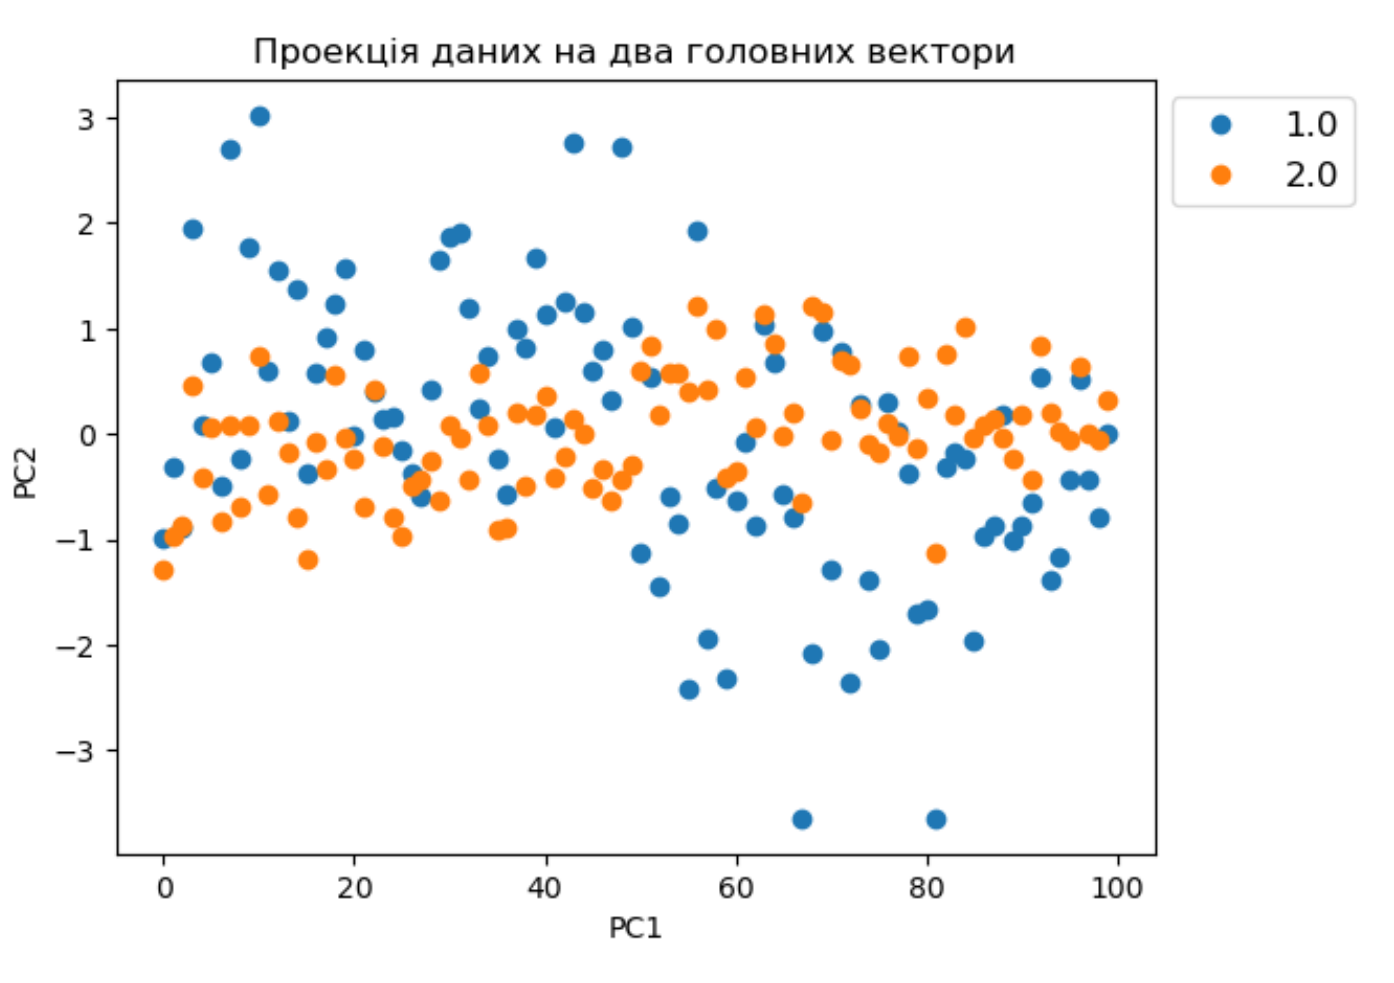

8. Порахувати відсоток втраченої інформації, використовуючи власні значення матриці коваріацій при зменшенні розмірності з чотирьох ознак до двох:

In [32]:
```
df_sort
```

Out[32]:

	№ ознаки	Власне значення
0	1	2.987789
3	4	0.560719
2	3	0.409832
1	2	0.082064

In [33]:
```
l1 = df_sort['Власне значення'].values[0]
l2 = df_sort['Власне значення'].values[1]
print('l1 {:.6f}\nl2 {:.6f}'.format(l1, l2))

l_sum = np.sum(df_sort['Власне значення'])

delt_I = 1 - ((l1+l2)/l_sum)
delt_I *= 100
print('Відсоток втраченої інформації:\n{:.3} %'.format(delt_I))
```
```
l1 2.987789
l2 0.560719
Відсоток втраченої інформації:
12.2 %
```

9. Розрахувати принципові компоненти за допомогою вбудованої функції PCA з кількістю компонентів 2 з бібліотеки sklearn.

In [34]:
```
pca = PCA(n_components = 2)
XPCAreduced = pca.fit_transform(np.transpose(x_matrix))
```

10. Порівняти результати роботи власного алгоритму з результатами функції PCA з бібліотеки sklearn.

In [35]:
```
print ('Sklearn reduced X [:5]: \n', XPCAreduced[:5])
```
```
Sklearn reduced X [:5]:
 [[ 0.53000157 -0.81588358]
 [ 0.05648712 -1.0773472 ]
 [ 0.5744019  -0.4569081 ]
 [-2.38876911  0.74233881]
 [-0.32567545  0.07569688]]
```

In [36]:
```
x_new[:5]
```

Out[36]:
```
array([[-0.99582149, -1.28767501],
       [-0.31350845, -0.96865302],
       [-0.89581604, -0.86638657],
       [ 1.95293489,  0.46302455],
       [ 0.08385608, -0.40762341]])
```

In [37]:
```
print('x_scaled \t', np.shape(x_scaled))       # [ℓ × n]
print('x_new    \t', np.shape(x_new))          # [ℓ × nPC]
print('XPCAreduced \t', np.shape(XPCAreduced)) # [ℓ × nPC]
```
```
x_scaled         (100, 4)
x_new            (100, 2)
XPCAreduced      (100, 2)
```

11. Візуалізувати різницю в отриманих вибірках.

In [38]:
```
difference = (XPCAreduced-x_new)
```

In [39]:
```
lab = dfIris2['target'].unique()
plt.plot(difference, 's', markersize = 5,
         #markerfacecolor='white',
         #markeredgecolor='gray',
         markeredgewidth = 2, label=lab)

plt.xlabel('delt PC1')
plt.ylabel('delt PC2')
plt.title('Порівняння з sclearn')
plt.legend(bbox_to_anchor=(1,1), loc="upper left", prop={'size': 12})
```

Out[39]:
```
<matplotlib.legend.Legend at 0x220a2745700>
```

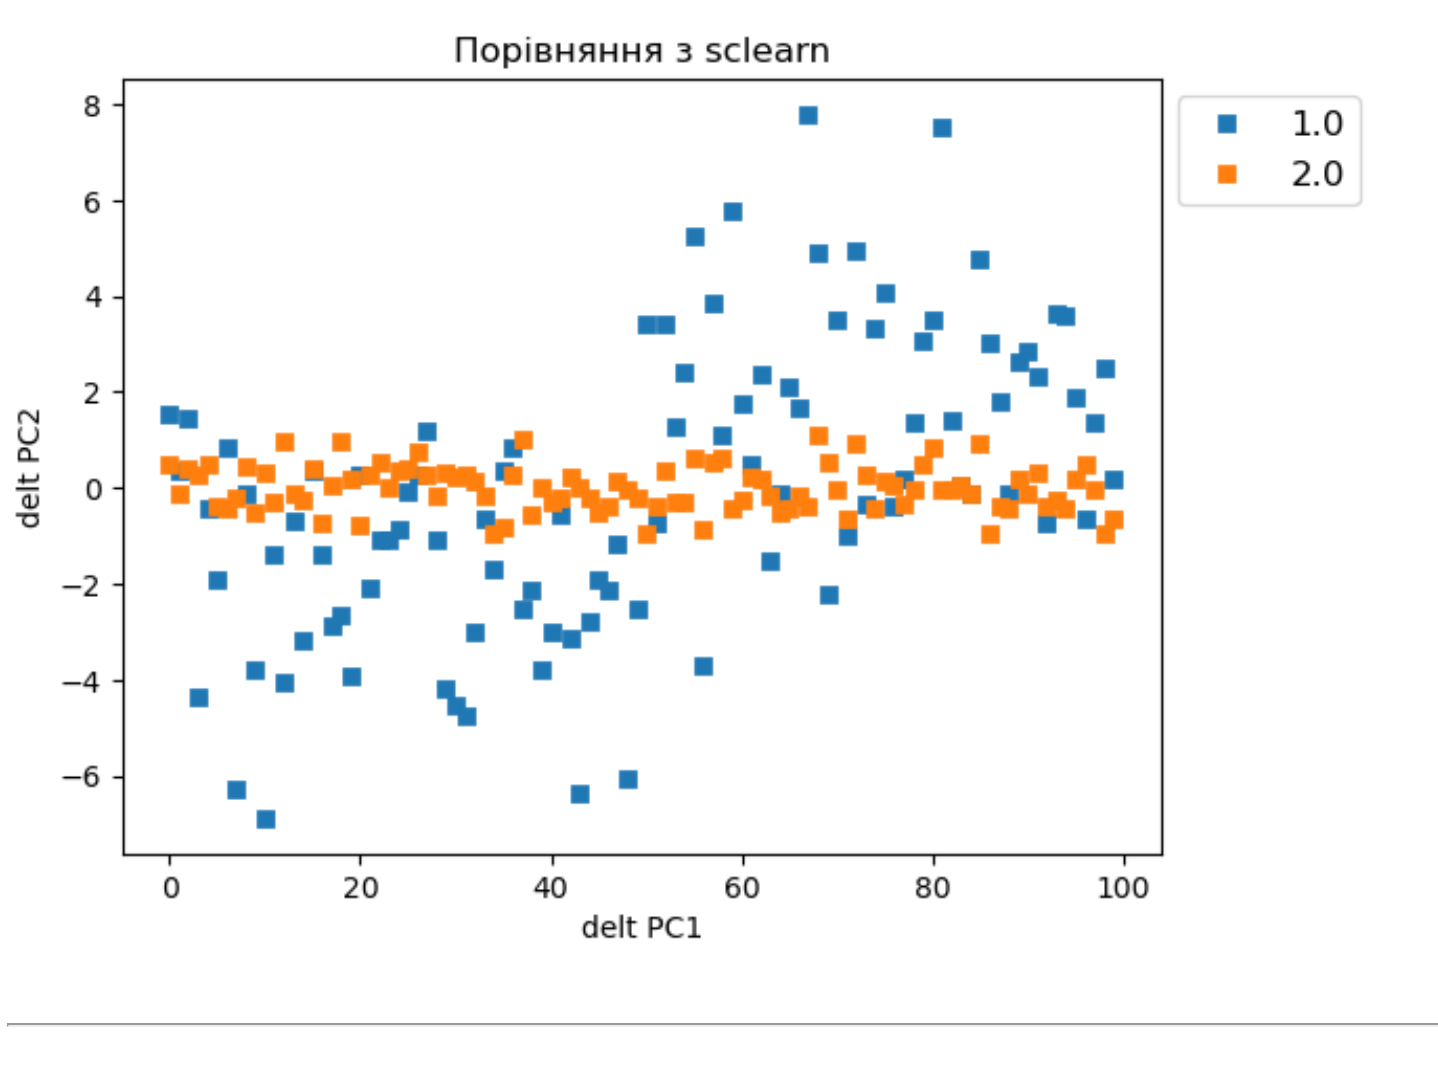

Машинне навчання

Редукування даних: метод SVD

Лабораторна робота 5

Студентка Пороскун Олена. Група ПМ.м-21

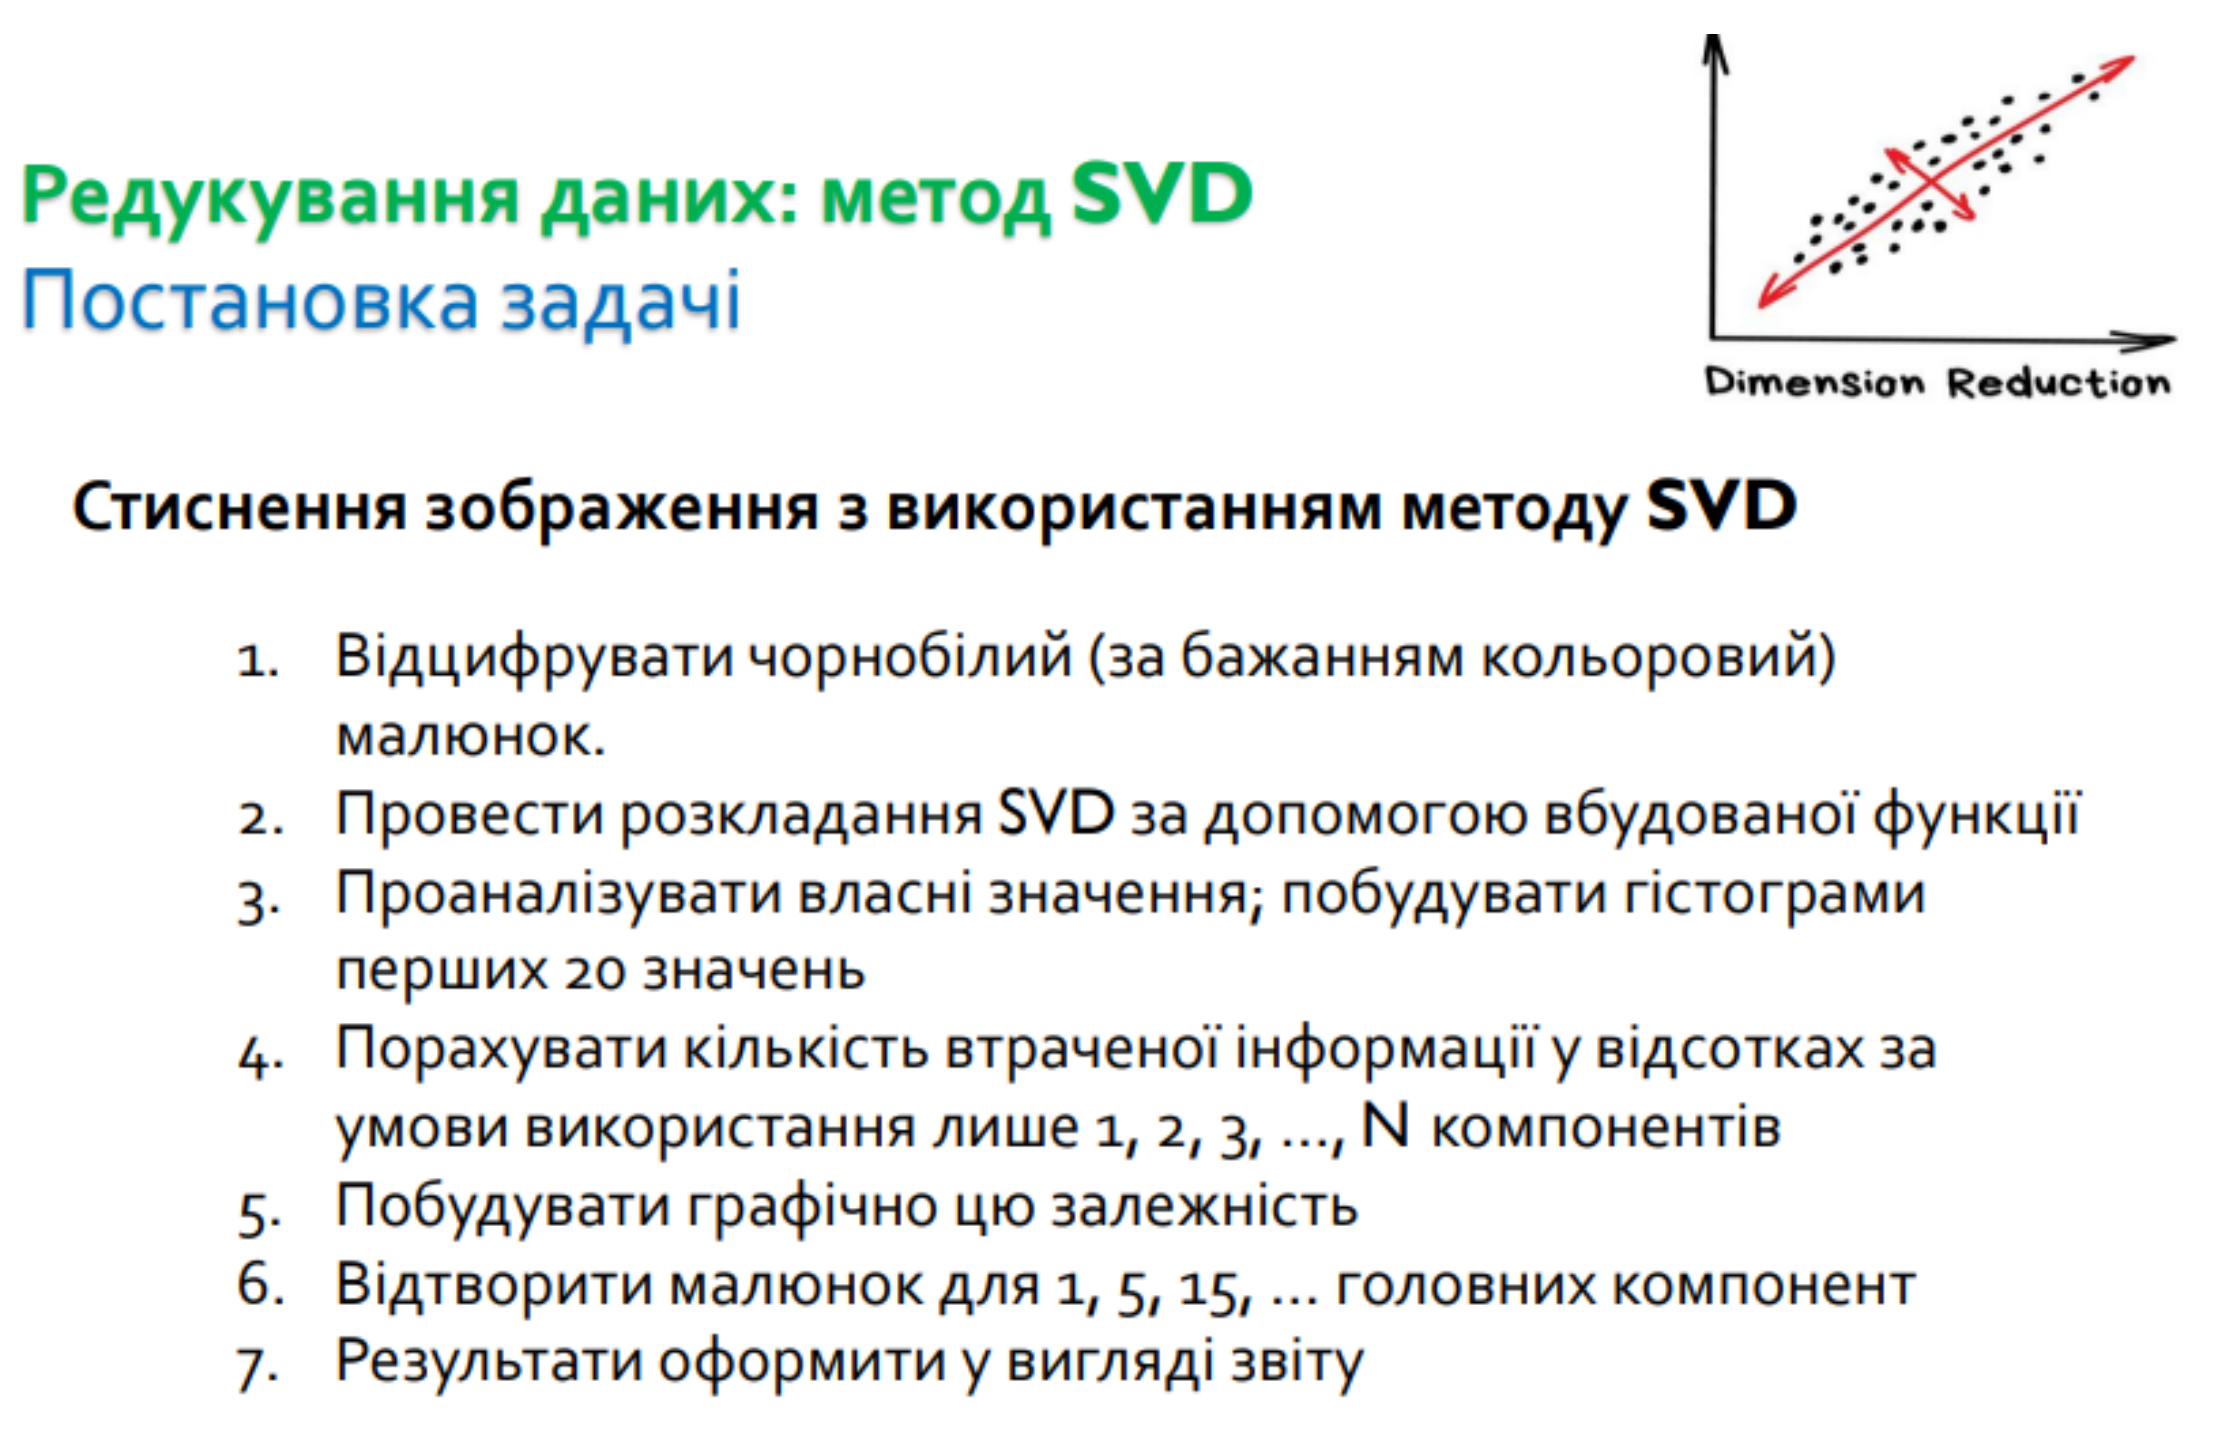

Редукування даних: метод SVD

Постановка задачі

Dimension Reduction

Стиснення зображення з використанням методу SVD

1. Відцифрувати чорнобілий (за бажанням кольоровий) малюнок.
2. Провести розкладання SVD за допомогою вбудованої функції
3. Проаналізувати власні значення; побудувати гістограми перших 20 значень
4. Порахувати кількість втраченої інформації у відсотках за умови використання лише 1, 2, 3, …, N компонентів
5. Побудувати графічно цю залежність
6. Відтворити малюнок для 1, 5, 15, … головних компонент
7. Результати оформити у вигляді звіту

In [1]:

```
!pip install opencv-python
!pip install imutils
```

```
Requirement already satisfied: opencv-python in c:\users\admin\anaconda3\lib\site-packages (4.7.0.72)
Requirement already satisfied: numpy>=1.17.0 in c:\users\admin\anaconda3\lib\site-packages (from opencv-python) (1.22.4)
Requirement already satisfied: imutils in c:\users\admin\anaconda3\lib\site-packages (0.5.4)
```

In [2]:

```
%matplotlib inline

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import matplotlib.image as mpimg
from matplotlib.image import imread
import os

# Import opencv
import cv2
```

In [3]:

```
import warnings
warnings.filterwarnings('ignore')
```

- **1**

In [4]:

```
name_img = 'beach.jpg'
img_orig = mpimg.imread(name_img)
imgplot = plt.imshow(img_orig)
```

0
100
200
300
400
500
600
0
200
400
600
800

- **2-3**

In [5]:

```
def fun_matrixs(name_img, components):
    # Завантажте вхідне зображення і перетворіть в чорнобіле
    img = cv2.imread(name_img, 0)

    original_shape = img.shape
    print('Розміри початкового зображення:', original_shape)

    U, S, V = np.linalg.svd(img)
    print('\nРозміри матриць отриманих з np.linalg.svd(...):\n U.shape, S.shape, V.shape')
    print(U.shape, S.shape, V.shape)

    first = [min(np.shape(img))]
    #comps = [first, 200, 50, 15, 5, 1]
    comps = first + components
    print('\nСписок числа компонент:', comps)

    matr = []
    for i in range(len(comps)):
        low_rank = U[:, :comps[i]] @ np.diag(S[:comps[i]]) @ V[:comps[i], :]
        #print(np.shape(low_rank))
        matr.append(low_rank)

    return matr
```

In [6]:

```
components0 = [200, 100, 50, 25, 15, 10, 5, 4, 3, 2, 1]
matr0 = fun_matrixs(name_img, components0)
print(np.shape(matr0))
```

```
Розміри початкового зображення: (638, 960)

Розміри матриць отриманих з np.linalg.svd(...):
 U.shape, S.shape, V.shape
(638, 638) (638,) (960, 960)

Список числа компонент: [638, 200, 100, 50, 25, 15, 10, 5, 4, 3, 2, 1]
(12, 638, 960)
```

In [7]:

```
matr0_ = matr0[0]
covmat = np.cov(matr0_)
w, v = np.linalg.eig(covmat)
```

In [8]:

```
d2 = {'Власні значення': w[:20]}
df1 = pd.DataFrame(d2)
display(df1.head())
```

	Власні значення
0	310432.929103
1	116198.452046
2	71619.792069
3	21235.600645
4	16093.473605

In [9]:

```
numbers = np.arange(20)
plt.bar(numbers, height=df1['Власні значення'])
plt.xticks(numbers)
plt.title('Гістограма перших 20 власних значень')
plt.xlabel('Номер власного вектору')
plt.ylabel('Власні значення коваріаційної матриці')
```

Out[9]:

```
Text(0, 0.5, 'Власні значення коваріаційної матриці')
```

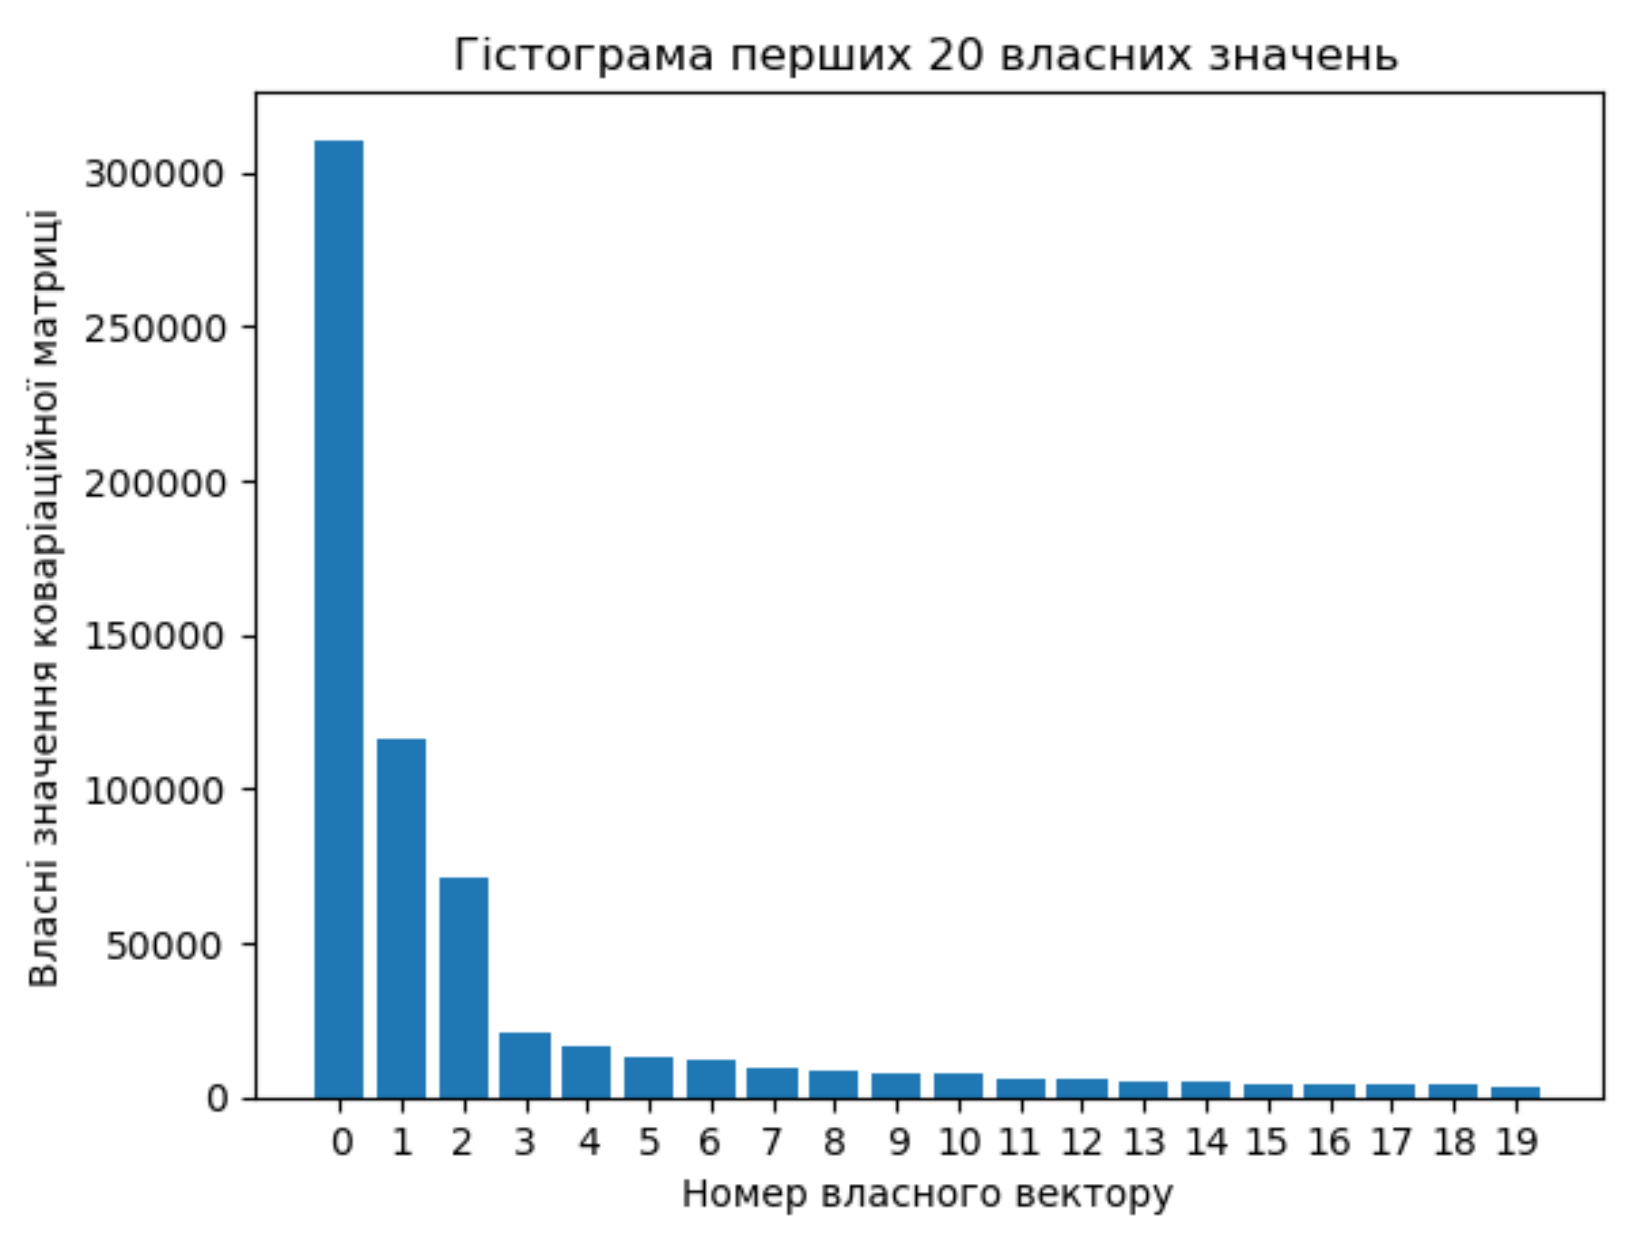

- **4**

In [10]:

```
def plot_components(name_img):
    # Завантажте вхідне зображення і перетворіть в чорнобіле
    img = cv2.imread(name_img, 0)
    original_shape = img.shape
    print('Розміри початкового зображення:', original_shape)

    # Отримання svd
    U, S, V = np.linalg.svd(img)

    print('\nРозміри матриць отриманих з np.linalg.svd(...):\n U.shape, S.shape, V.shape')
    print(U.shape, S.shape, V.shape)

    # зображення з різною кількістю компонентів
    first = min(np.shape(img))
    components = [first, 200, 50, 15, 5, 4, 3, 2, 1]
    print('\nСписок числа компонент:', components, '\n')

    plt.figure(figsize = (16, 8))
    for i in range(len(components)):
        low_rank = U[:, :components[i]] @ np.diag(S[:components[i]]) @ V[:components[i], :]
    return components

components = plot_components(name_img)
```

```
Розміри початкового зображення: (638, 960)

Розміри матриць отриманих з np.linalg.svd(...):
 U.shape, S.shape, V.shape
(638, 638) (638,) (960, 960)

Список числа компонент: [638, 200, 50, 15, 5, 4, 3, 2, 1]

<Figure size 1600x800 with 0 Axes>
```

In [11]:

```
x = components[::-1]
percentage = [(1 - x[i]/x[-1])*100 for i in range(len(x))]
print('Втрати інформації')
for i in percentage:
    print(round(i,3), '%')
```

```
Втрати інформації
99.843 %
99.687 %
99.53 %
99.373 %
99.216 %
97.649 %
92.163 %
68.652 %
0.0 %
```

- **5**

In [12]:

```
plt.figure(figsize = (6, 5))
plt.plot(x, percentage, 'o--', label = 'Втрати інформації %')
plt.title('Втрати інформації %')
plt.xlabel('Кількість використаних компонент')
plt.ylabel('Втрати інформації %')
plt.legend(bbox_to_anchor=(1,1), loc="upper left", prop={'size': 12})
```

Out[12]:

```
<matplotlib.legend.Legend at 0x1d82b7c14c0>
```

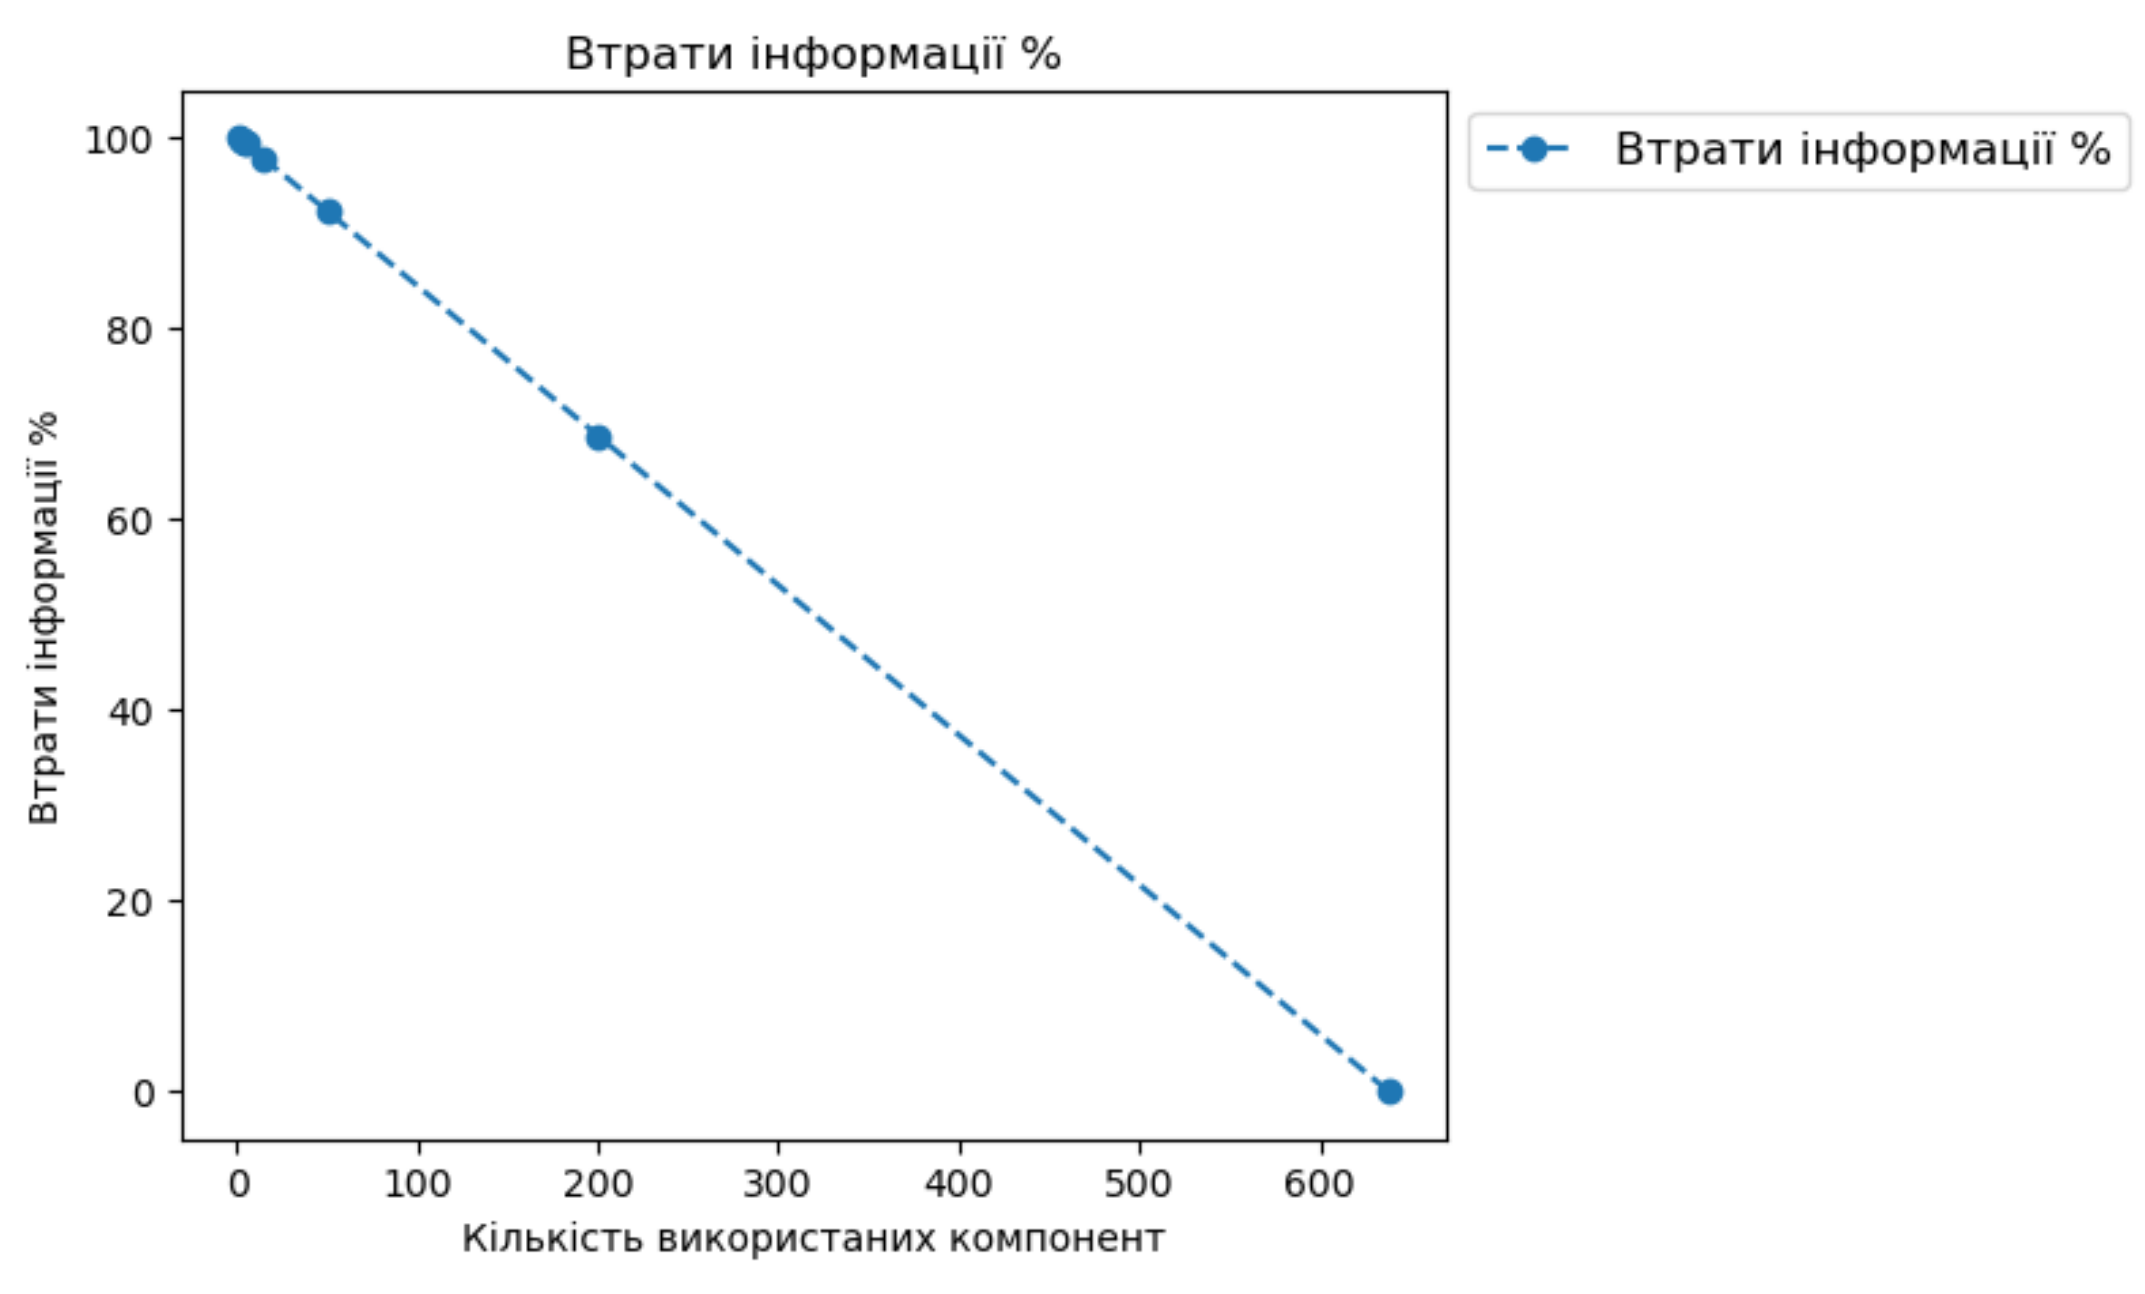

- **6**

In [13]:

```
def plot_n_comp(name_img):
    # Завантажте вхідне зображення і перетворіть в чорнобіле
    img = cv2.imread(name_img, 0)
    original_shape = img.shape
    print('Розміри початкового зображення:', original_shape)

    # Отримання svd
    U, S, V = np.linalg.svd(img)

    print('\nРозміри матриць отриманих з np.linalg.svd(...):\n U.shape, S.shape, V.shape')
    print(U.shape, S.shape, V.shape)

    # зображення з різною кількістю компонентів
    first = min(np.shape(img))
    components = [first, 300, 75, 15, 5, 1]
    print('\nСписок числа компонент:', components, '\n')

    plt.figure(figsize = (16, 8))
    for i in range(len(components)):
        low_rank = U[:, :components[i]] @ np.diag(S[:components[i]]) @ V[:components[i], :]
        if(i == 0):
            plt.subplot(2, 3, i+1), plt.imshow(low_rank, cmap = 'gray'), plt.axis('off'), \
            plt.title("Початкове зображення з n_components =" + str(components[i]))
        else:
            plt.subplot(2, 3, i+1), plt.imshow(low_rank, cmap = 'gray'), plt.axis('off'), \
            plt.title("n_components =" + str(components[i]))

        #matr.append(low_rank)
        #print()

plot_n_comp(name_img)
```

```
Розміри початкового зображення: (638, 960)

Розміри матриць отриманих з np.linalg.svd(...):
 U.shape, S.shape, V.shape
(638, 638) (638,) (960, 960)

Список числа компонент: [638, 300, 75, 15, 5, 1]
```

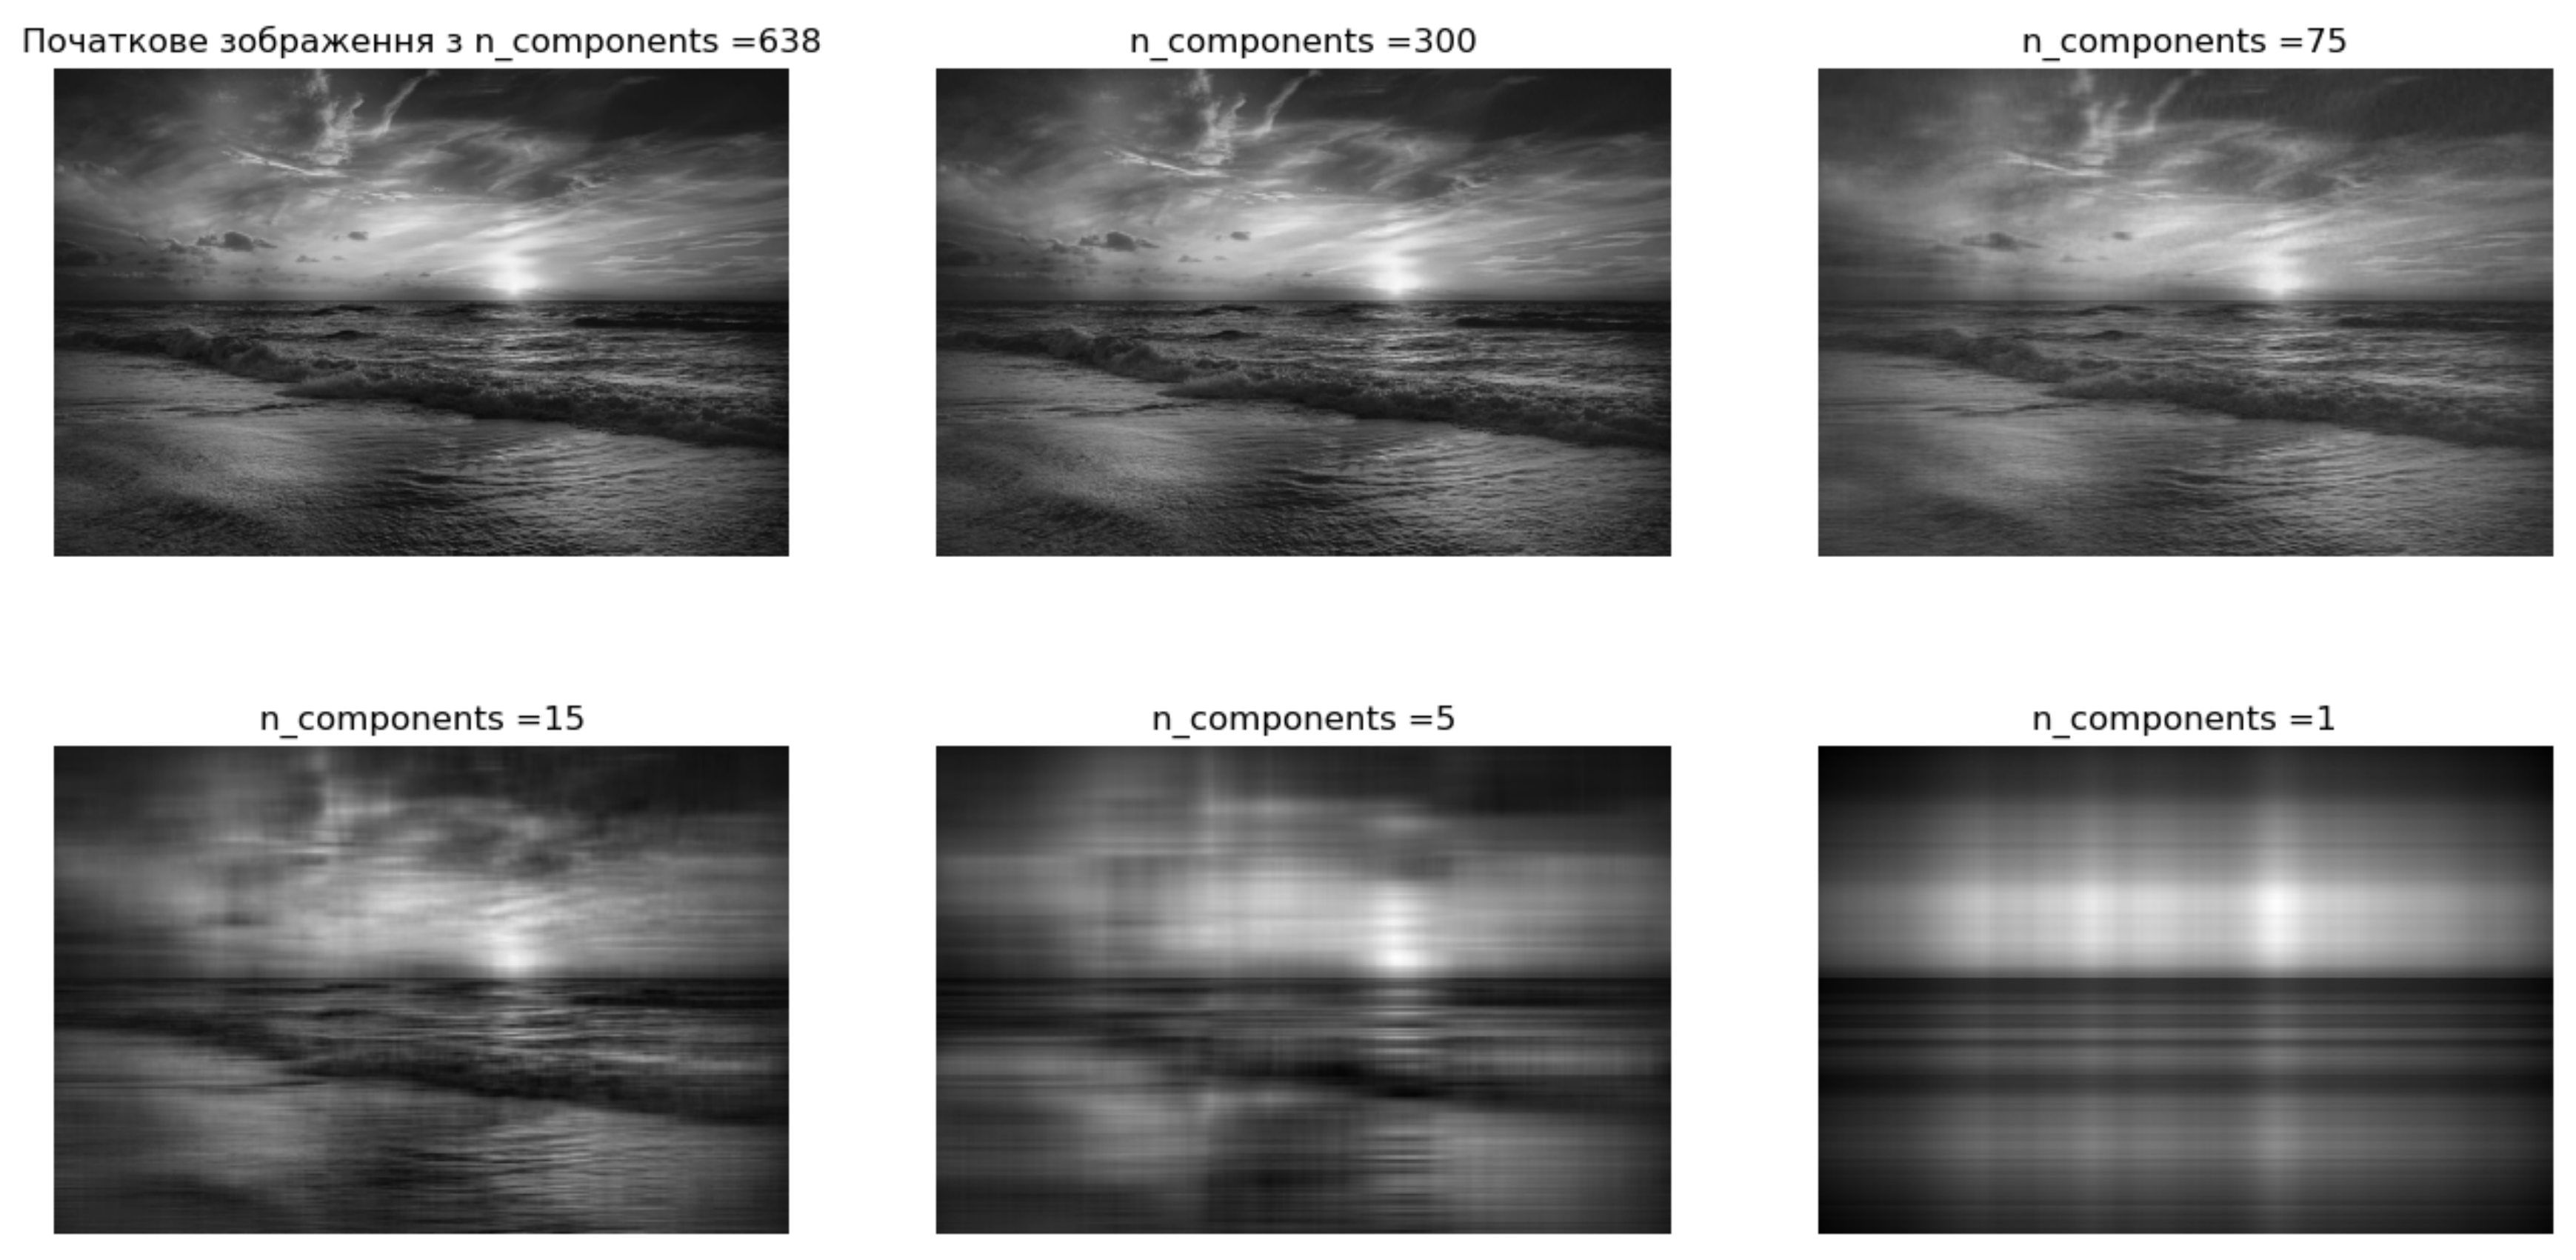

Машинне навчання

Навчання без учителя: задачі кластеризації

Метод k-середніх (k-Means)

Лабораторна робота 6

Студентка Пороскун Олена. Група ПМ.м-21

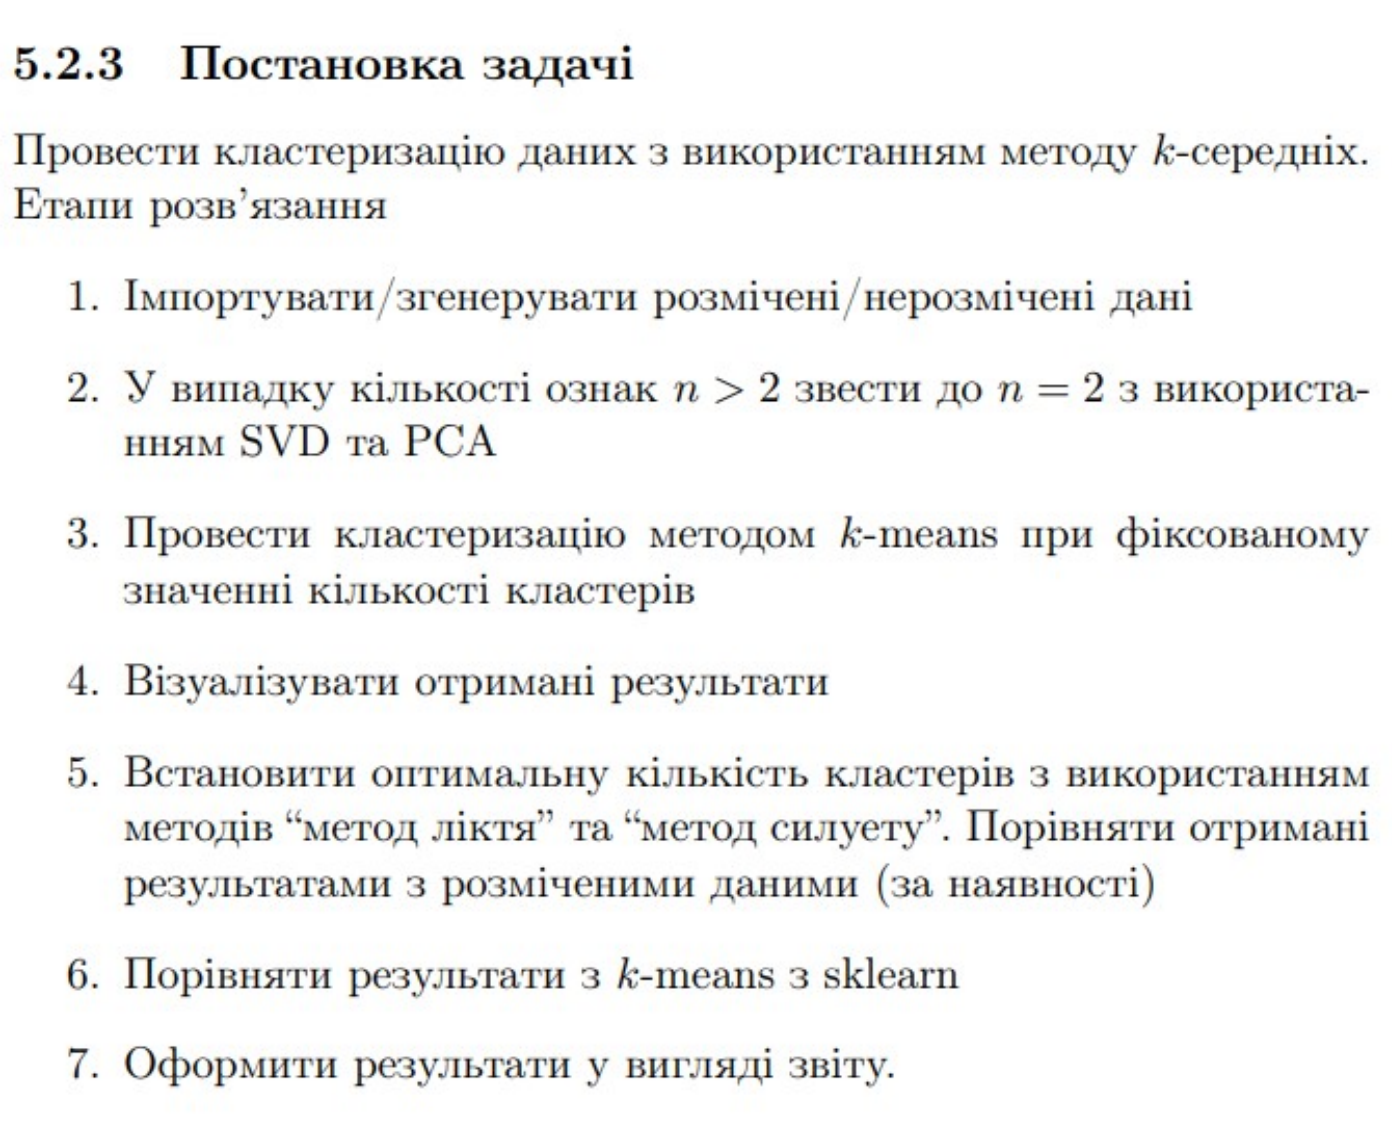

5.2.3 Постановка задачі

Провести кластеризацію даних з використанням методу k-середніх. Етапи розв'язання

1. Імпортувати/згенерувати розмічені/нерозмічені дані
2. У випадку кількості ознак $n > 2$ звести до $n = 2$ з використанням SVD та PCA
3. Провести кластеризацію методом k-means при фіксованому значенні кількості кластерів
4. Візуалізувати отримані результати
5. Встановити оптимальну кількість кластерів з використанням методів "метод ліктя" та "метод силуету". Порівняти отримані результатами з розміченими даними (за наявності)
6. Порівняти результати з k-means з sklearn
7. Оформити результати у вигляді звіту.

In [1]:
```
import warnings
warnings.filterwarnings('ignore')
```

In [2]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from matplotlib.colors import ListedColormap
%matplotlib inline
```

1. Імпортувати/згенерувати розмічені/нерозмічені дані

In [3]:
```
blobs = pd.read_csv('kmeans_blobs.csv')
colnames = list(blobs.columns[1:-1])
blobs.head()
```

Out[3]:

	ID	x	y	cluster
0	0	24.412	32.932	2
1	1	35.190	12.189	1
2	2	26.288	41.718	2
3	3	0.376	15.506	0
4	4	26.116	3.963	1

In [4]:
```
customcmap = ListedColormap(["crimson", "mediumblue", "darkmagenta"])

fig, ax = plt.subplots(figsize=(8, 6))
plt.scatter(x=blobs['x'], y=blobs['y'], s=50,
            c=blobs['cluster'].astype('category'),
            cmap = customcmap)
ax.set_xlabel(r'x', fontsize=14)
ax.set_ylabel(r'y', fontsize=14)
plt.xticks(fontsize=12)
plt.yticks(fontsize=12)
plt.show()
```

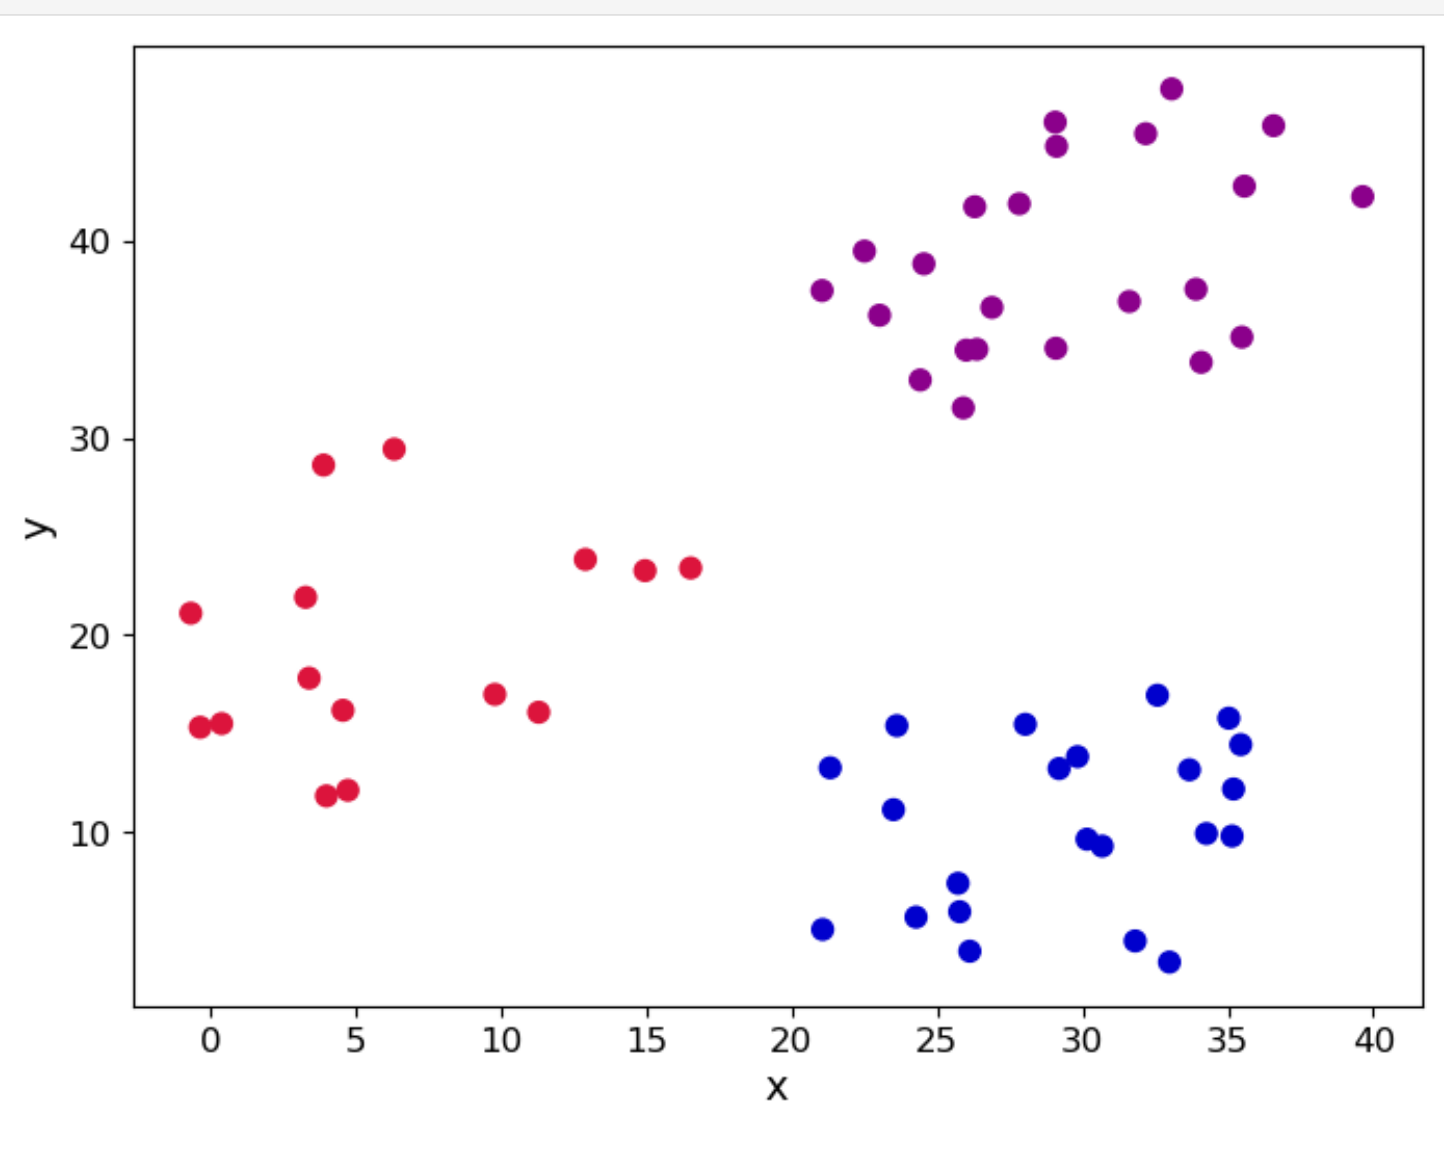

3. Провести кластеризацію методом k-means при фіксованому значенні кількості кластерів.

4. Візуалізувати отримані результати.

Кроки 1 і 2 - Визначення та ініціювання центроїдів.

In [5]:
```
def initiate_centroids(k, dset):
    '''
    Вибрати k точок даних як центроїди
    k: кількість центроїдів
    dset: pandas dataframe
    '''
    centroids = dset.sample(k)
    return centroids

np.random.seed(42)
k=3
df = blobs[['x','y']]
centroids = initiate_centroids(k, df)
centroids
```

Out[5]:

	x	y
0	24.412	32.932
5	25.893	31.515
36	26.878	36.609

Крок 3 - Розрахуйте відстань.

In [6]:
```
def rsserr(a,b):
    # Обчислити квадратний корінь з суми похибок. a та b - питру масиви
    return np.square(np.sum((a-b)**2))
```

Крок 4 - Призначте центроїди.

In [7]:
```
def centroid_assignation(dset, centroids):
    '''
    Маючи датафрейм `dset` і набір `centroids`, ми призначаємо кожній
    точці даних у `dset` призначаємо центроїд.
    - dset - pandas датафрейм зі спостереженнями
    - centroids - фрейм даних з центроїдами
    '''
    k = centroids.shape[0]
    n = dset.shape[0]
    assignation = []
    assign_errors = []

    for obs in range(n):
        # Похибка оцінки
        all_errors = np.array([])
        for centroid in range(k):
            err = rsserr(centroids.iloc[centroid, :], dset.iloc[obs,:])
            all_errors = np.append(all_errors, err)

        # найближчий центроїд і помилку
        nearest_centroid =  np.where(all_errors==np.amin(all_errors))[0].tolist()[0]
        nearest_centroid_error = np.amin(all_errors)

        assignation.append(nearest_centroid)
        assign_errors.append(nearest_centroid_error)

    return assignation, assign_errors
```

In [8]:
```
df['centroid'], df['error'] = centroid_assignation(df, centroids)
df.head()
```

Out[8]:

	x	y	centroid	error
0	24.412	32.932	0	0.000000
1	35.190	12.189	1	211534.211314
2	26.288	41.718	2	699.601495
3	0.376	15.506	0	776856.744109
4	26.116	3.963	1	576327.599678

In [9]:
```
fig, ax = plt.subplots(figsize=(8, 6))
plt.scatter(df.iloc[:,0], df.iloc[:,1],  marker = 'o',
            c=df['centroid'].astype('category'),
            cmap = customcmap, s=80, alpha=0.5)
plt.scatter(centroids.iloc[:,0], centroids.iloc[:,1],
            marker = 's', s=200, c=[0, 1, 2],
            cmap = customcmap)
ax.set_xlabel(r'x', fontsize=14)
ax.set_ylabel(r'y', fontsize=14)
plt.xticks(fontsize=12)
plt.yticks(fontsize=12)
plt.show()
```

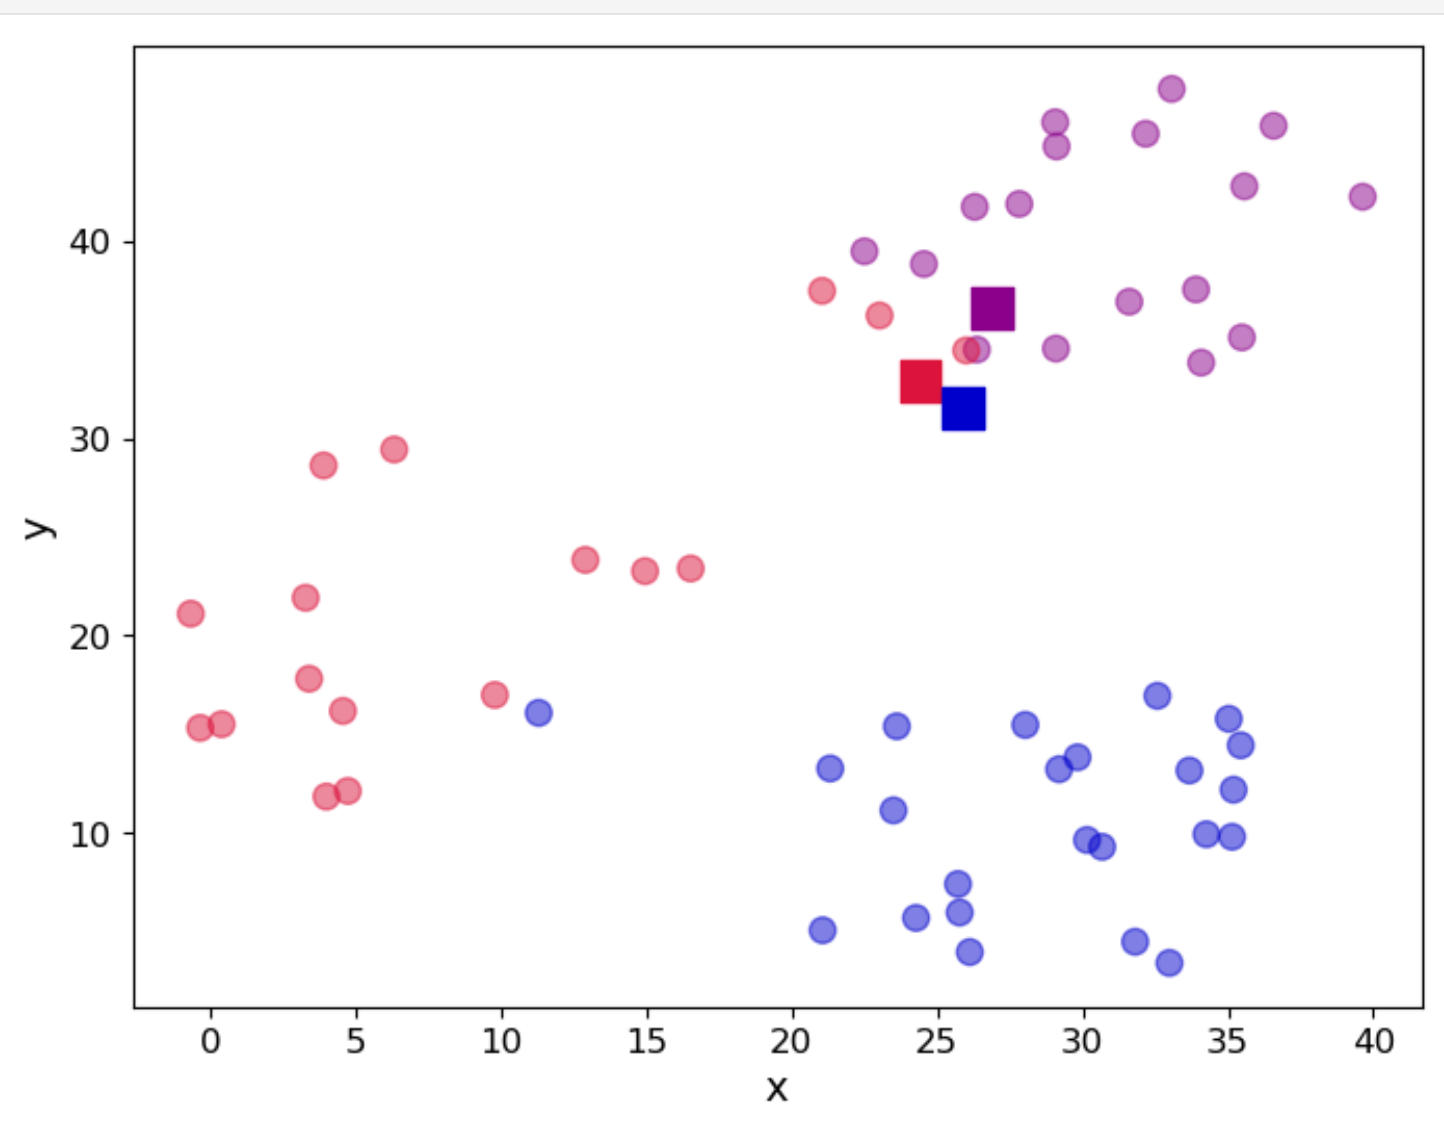

In [10]:
```
print("Сумарна помилка is {0:.2f}".format(df['error'].sum()))
```

```
Сумарна помилка is 11927659.01
```

Крок 5 - Оновлення розташування центроїда.

In [11]:
```
centroids = df.groupby('centroid').agg('mean').loc[:, colnames].reset_index(drop = True)
centroids
```

Out[11]:

	x	y
0	9.889444	23.242611
1	28.435750	11.546250
2	30.759333	40.311167

In [12]:
```
fig, ax = plt.subplots(figsize=(8, 6))
plt.scatter(df.iloc[:,0], df.iloc[:,1],  marker = 'o',
            c=df['centroid'].astype('category'),
            cmap = customcmap, s=80, alpha=0.5)
plt.scatter(centroids.iloc[:,0], centroids.iloc[:,1],
            marker = 's', s=200,
            c=[0, 1, 2], cmap = customcmap)
ax.set_xlabel(r'x', fontsize=14)
ax.set_ylabel(r'y', fontsize=14)
plt.xticks(fontsize=12)
plt.yticks(fontsize=12)
plt.show()
```

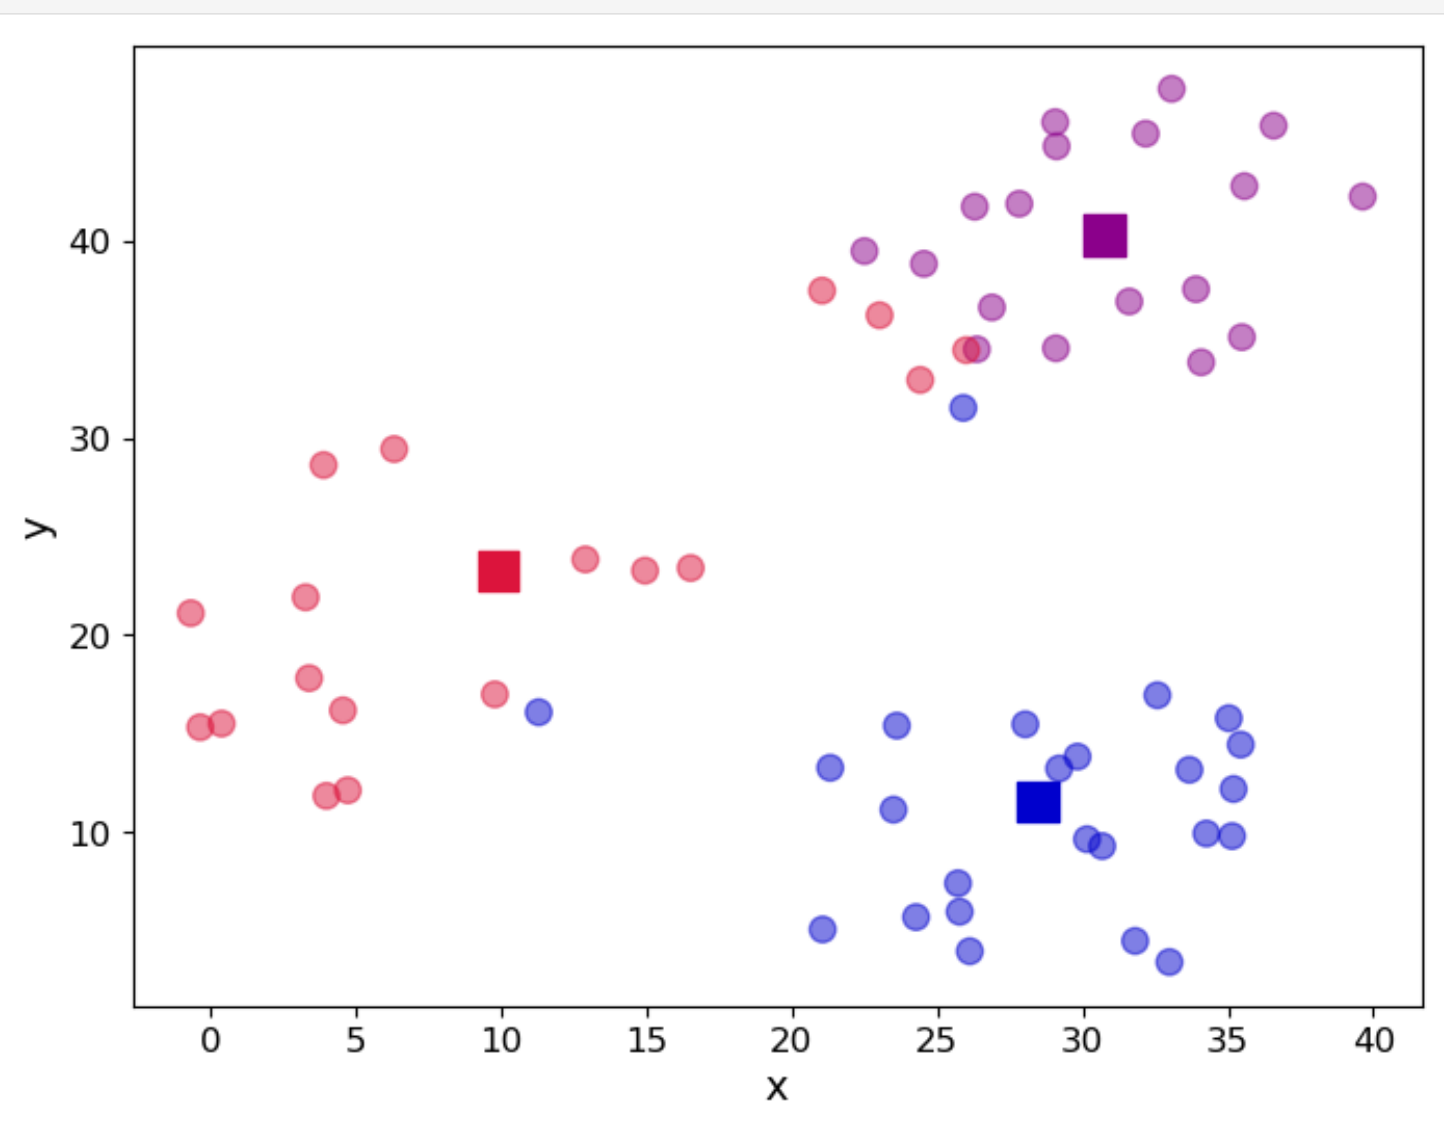

Крок 6 - Повторіть кроки 3-5.

In [13]:
```
def kmeans(dset, k=2, tol=1e-4):
    '''
    K-means реалізовано для набору
    `dset`:  датафрей зі спостереженнями
    `k`: кількість кластерів, за замовчуванням k=2
    `tol`: допуск=1E-4
    '''
    # Давайте працювати в копії, щоб не зіпсувати оригінал
    working_dset = dset.copy()

    # Визначимо деякі змінні для зберігання помилки,
    # сигналу зупинки та лічильник для ітерацій

    err = []
    goahead = True
    j = 0

    # Крок 2: Ініціюйте кластери, визначивши центроїди
    centroids = initiate_centroids(k, dset)

    while(goahead):
        # Крок 3 і 4 - Призначення центроїдів і розрахунок похибки
        working_dset['centroid'], j_err = centroid_assignation(working_dset, centroids)
        err.append(sum(j_err))

        # Крок 5 - Оновлення положення центроїда
        centroids = working_dset.groupby('centroid').agg('mean').reset_index(drop = True)

        # Крок 6 - Перезапустіть ітерацію
        if j>0:
            # Чи є похибка меншою за допуск (1E-4)
            if err[j-1]-err[j]<=tol:
                goahead = False
        j+=1

    working_dset['centroid'], j_err = centroid_assignation(working_dset, centroids)
    centroids = working_dset.groupby('centroid').agg('mean').reset_index(drop = True)
    return working_dset['centroid'], j_err, centroids
```

In [14]:
```
np.random.seed(42)
df['centroid'], df['error'], centroids =  kmeans(df[['x','y']], 3)
df.head()
```

Out[14]:

	x	y	centroid	error
0	24.412	32.932	2	3767.568743
1	35.190	12.189	1	1399.889001
2	26.288	41.718	2	262.961097
3	0.376	15.506	0	2683.086425
4	26.116	3.963	1	2723.650198

In [15]:
```
centroids
```

Out[15]:

	x	y
0	6.322867	19.559800
1	29.330864	10.432409
2	29.304957	39.050783

In [16]:
```
fig, ax = plt.subplots(figsize=(8, 6))
plt.scatter(df.iloc[:,0], df.iloc[:,1],  marker = 'o',
            c=df['centroid'].astype('category'),
            cmap = customcmap, s=80, alpha=0.5)
plt.scatter(centroids.iloc[:,0], centroids.iloc[:,1],
            marker = 's', s=200, c=[0, 1, 2],
            cmap = customcmap)
ax.set_xlabel(r'x', fontsize=14)
ax.set_ylabel(r'y', fontsize=14)
plt.xticks(fontsize=12)
plt.yticks(fontsize=12)
plt.show()
```

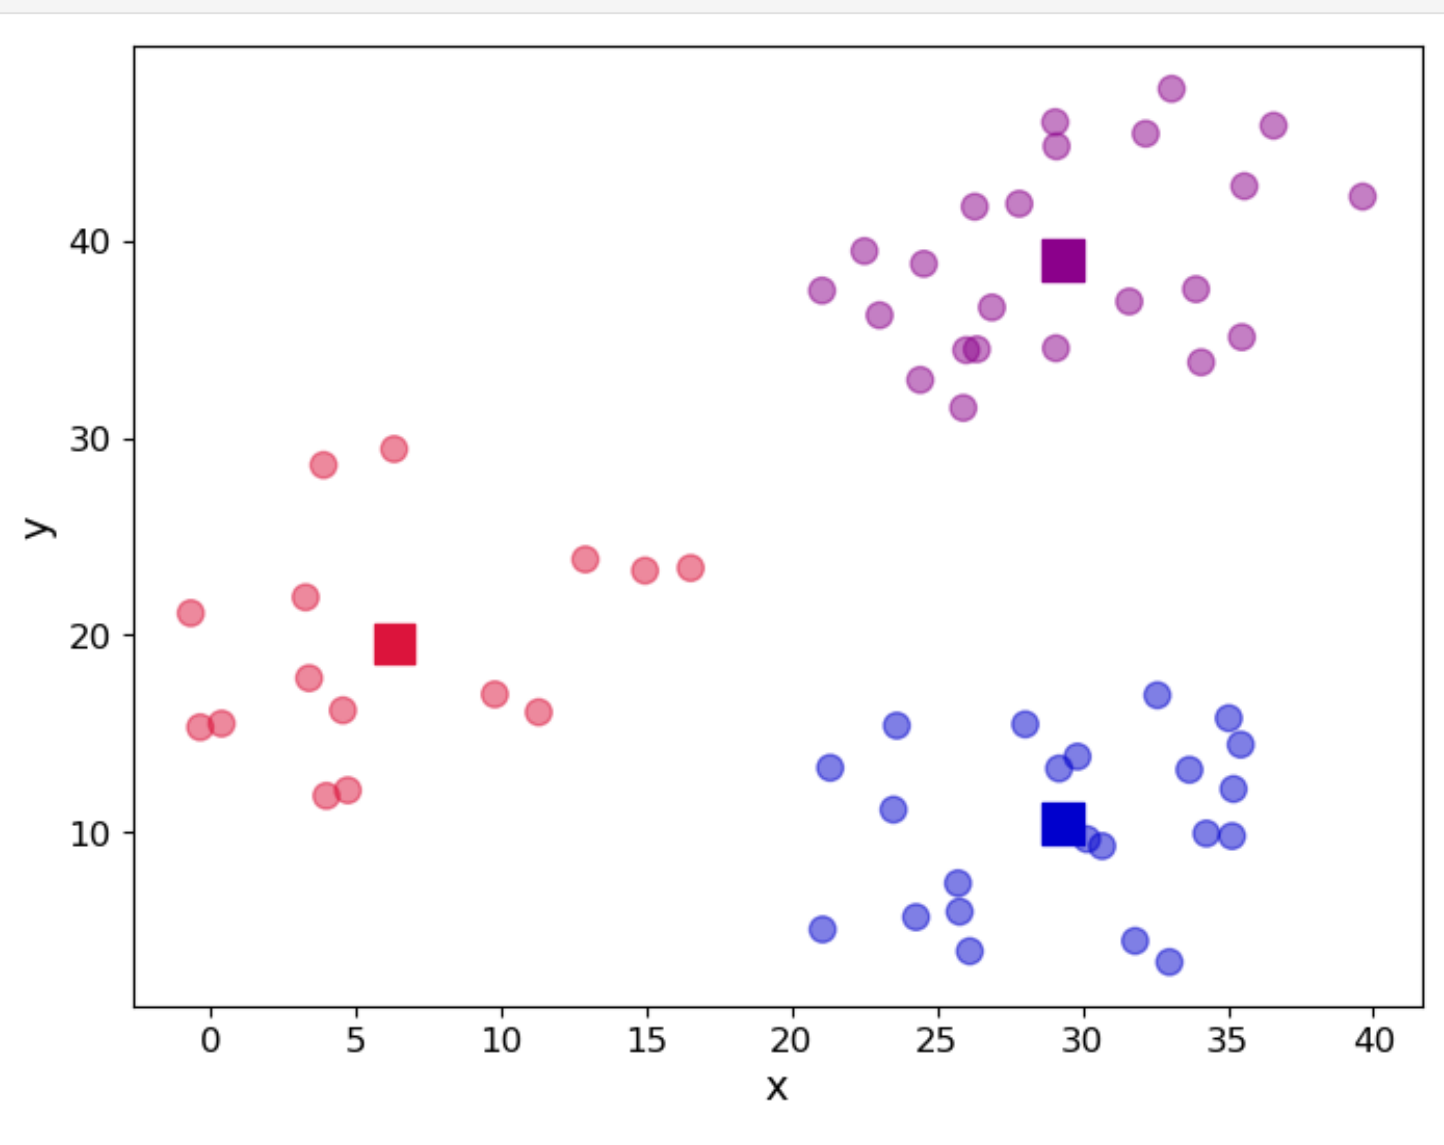

Отримали **3 групи**.У цьому конкретному прикладі дані такі, що різниця між групами є чіткою. Однак, нам може не так пощастити в кожному випадку. Тому питання про те, скільки груп існує, залишається відкритим. Ми можемо використати графік, який допоможе нам мінімізувати похибку, подивившись на запуск алгоритму з послідовністю і шукати "лікоть" на графіку, який вказує на достатню кількість кластерів для використання:

5. Встановити оптимальну кількість кластерів з використанням методів "метод ліктя" / "метод силуету". Порівняти отримані результатами з розміченими даними (за наявності).

In [17]:
```
n = 10
err_total = []

df_elbow = blobs[['x','y']]

for i in range(n):
    working_dset, my_errs, centroids = kmeans(df_elbow, i+1)
    err_total.append(sum(my_errs))

fig, ax = plt.subplots(figsize=(7, 4))
plt.plot(range(1,n+1), err_total, linewidth=3, marker='o')
ax.set_xlabel(r'Кількість кластерів', fontsize=14)
ax.set_ylabel(r'Загальна кількість помилок', fontsize=14)
plt.xticks(range(1, n+1), fontsize=12)
plt.yticks(fontsize=12)
plt.show()
```

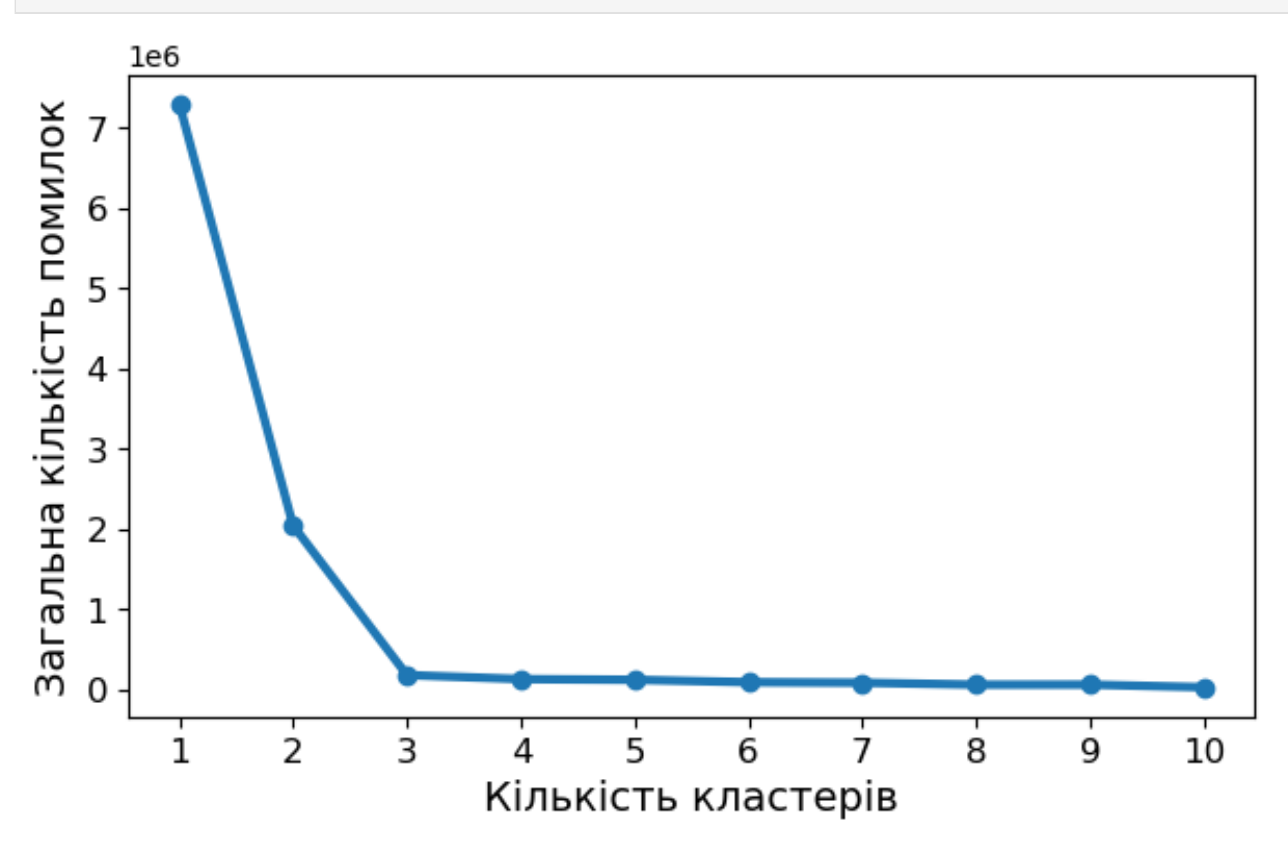

Тепер ми можемо застосувати "правило ліктя", яке є евристичним прийомом, що допоможе нам визначити кількість кластерів. Якщо уявити лінію, зображену вище, як руку, то "лікоть" - це точка перегину. У цьому випадку "лікоть" знаходиться між 2 і 4 кластерами, що вказує нам на те, що **вибір 3 є правильним**.

Порівняти отримані результатами з розміченими даними (за наявності).

In [18]:
```
blobs = pd.read_csv('kmeans_blobs.csv')
blobs.head()
```

Out[18]:

	ID	x	y	cluster
0	0	24.412	32.932	2
1	1	35.190	12.189	1
2	2	26.288	41.718	2
3	3	0.376	15.506	0
4	4	26.116	3.963	1

In [19]:
```
sns.scatterplot(x = blobs['x'], y = blobs['y'], hue = blobs['cluster'])
plt.xlabel("x")
plt.ylabel("y")
plt.title("Початкові кластери даних" )
plt.legend(bbox_to_anchor=(1,1), loc="upper left", prop={'size': 12})
plt.show()
```

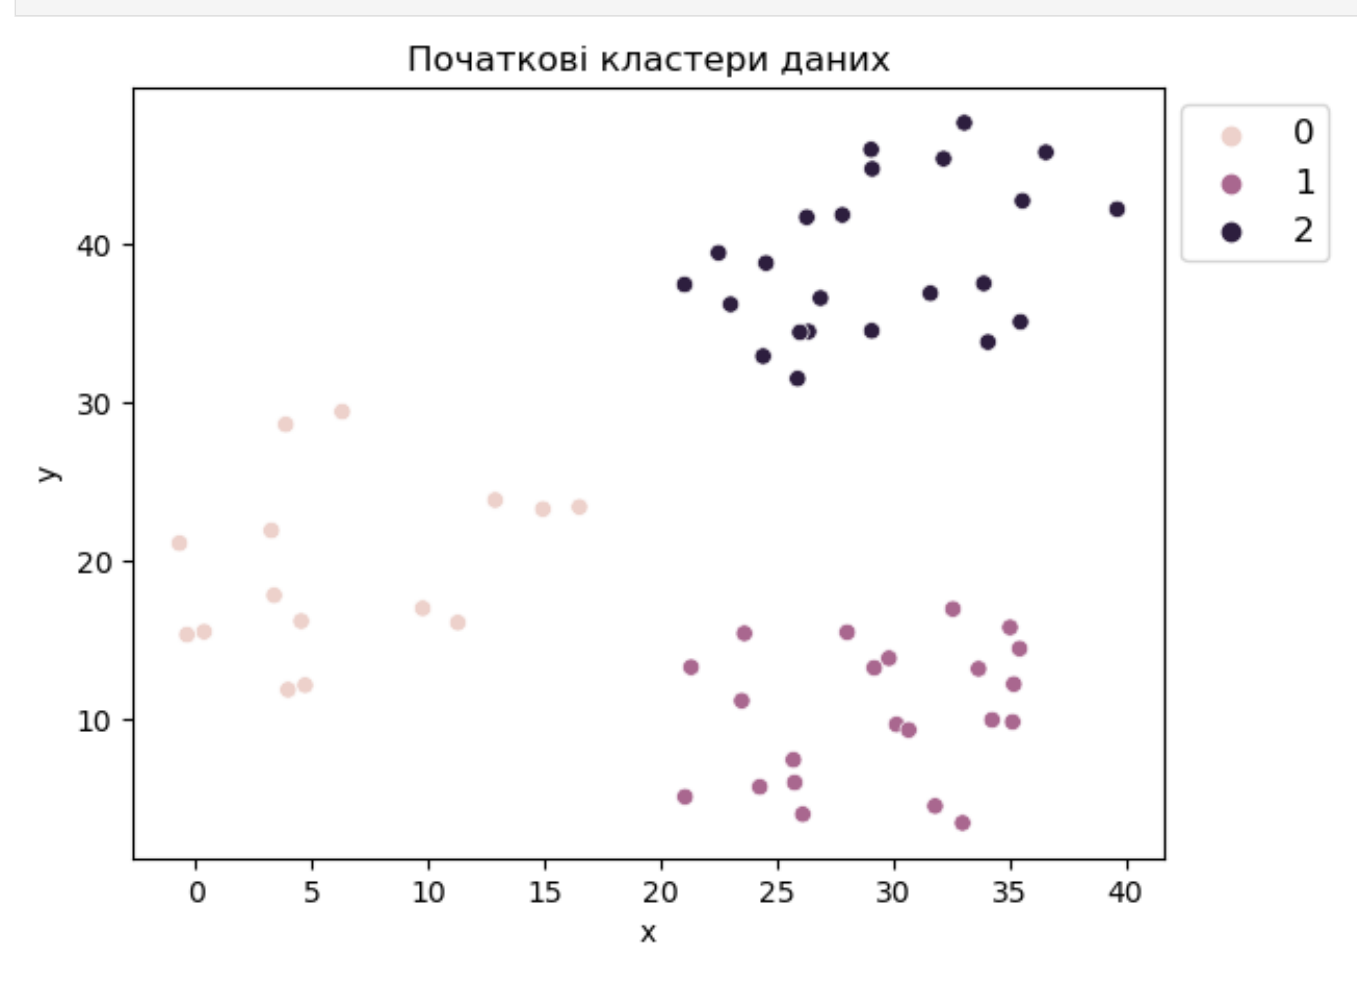

6. Порівняти результати з k-means з sklearn

In [20]:
```
from sklearn.cluster import KMeans
```

In [21]:
```
data = pd.read_csv('kmeans_blobs.csv')
data.head()
```

Out[21]:

	ID	x	y	cluster
0	0	24.412	32.932	2
1	1	35.190	12.189	1
2	2	26.288	41.718	2
3	3	0.376	15.506	0
4	4	26.116	3.963	1

In [22]:
```
data_xy = data[['x', 'y']]
data_xy.head()
```

Out[22]:

	x	y
0	24.412	32.932
1	35.190	12.189
2	26.288	41.718
3	0.376	15.506
4	26.116	3.963

In [23]:
```
inertias = []
n=10
for i in range(1,n+1):
    kmeans = KMeans(n_clusters=i)
    kmeans.fit(data_xy)
    inertias.append(kmeans.inertia_)

plt.plot(range(1,11), inertias, marker='o')
plt.title('Метод ліктя')
plt.xlabel('Кількість кластерів')
plt.ylabel('Сума квадратів відстаней вибірок \nдо найближчого центру кластера')
plt.xticks(range(1, n+1), fontsize=12)
plt.yticks(fontsize=12)
plt.show()
```

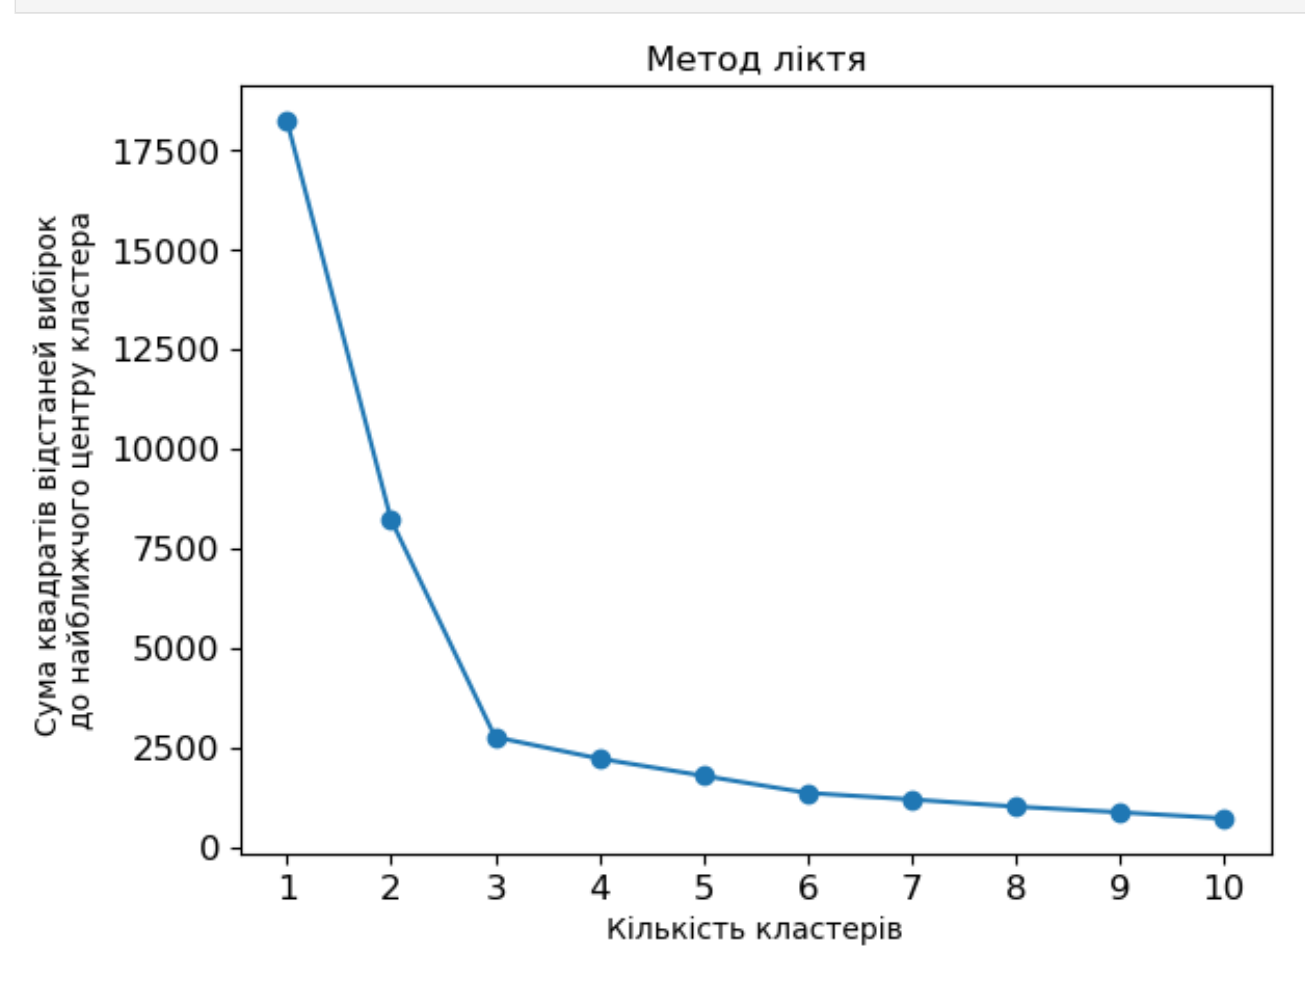

In [24]:
```
kmeans = KMeans(n_clusters=3)
kmeans.fit(data_xy)

plt.scatter(data_xy['x'], data_xy['y'], c=kmeans.labels_)
plt.show()
```

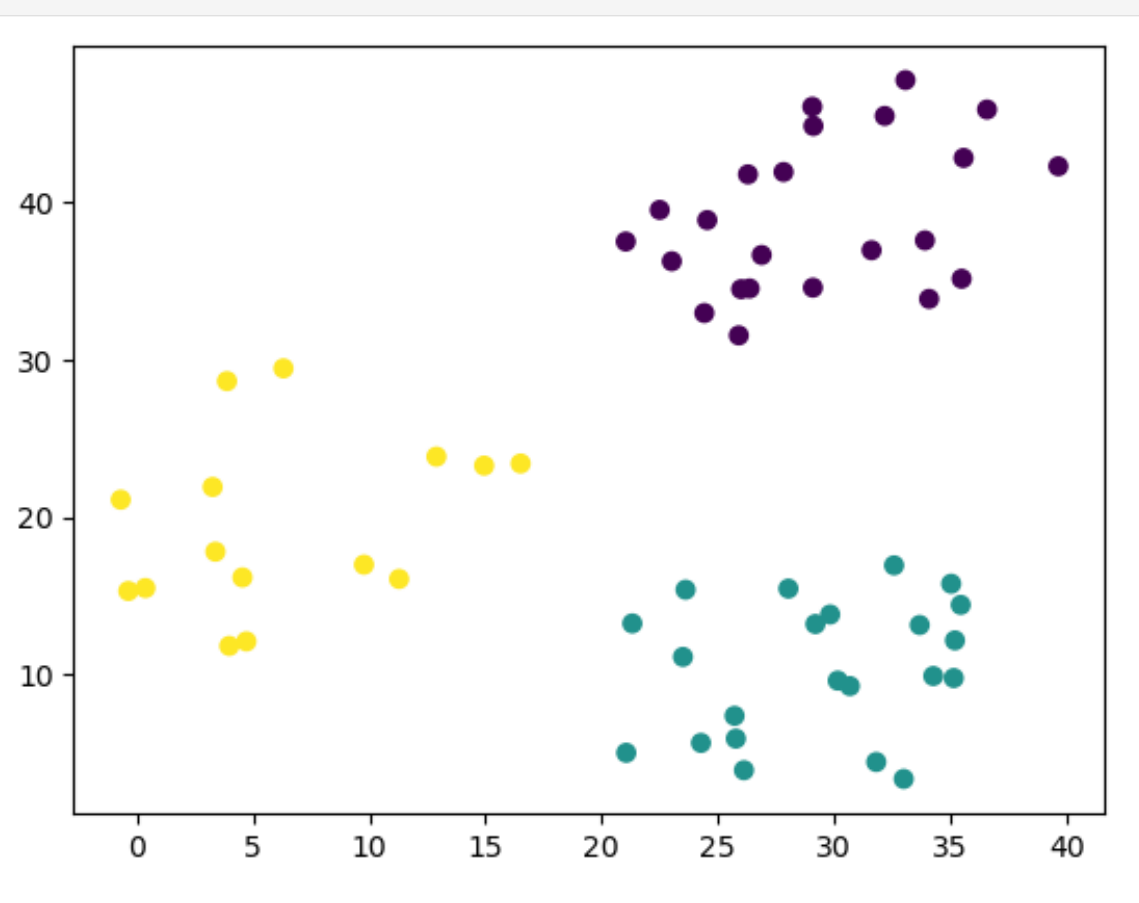

Машинне навчання

Навчання без учителя: задачі кластеризації

Метод DBSCAN

Лабораторна робота 7

Студентка Пороскун Олена. Група ПМ.м-21

5.3.7 Постановка задачі

Провести кластеризацію даних з використанням методу DBSCAN. Етапи розв'язання

1. Імпортувати/згенерувати розмічені/нерозмічені дані
2. У випадку кількості ознак $n > 2$ звести до $n = 2$ з використанням SVD та PCA
3. Зафіксувати кількість сусідів m, та побудувати K-Distance Graph та визначити оптимальне значення щільності ϵ
4. Провести кластеризацію методом DBSCAN при обраних параметрах m та ϵ
5. Візуалізувати отримані результати
6. Порівняти результати з DBSCAN з sklearn
7. Оформити результати у вигляді звіту.

In [1]:

```
import math
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
```

In [2]:

```
from sklearn.preprocessing import normalize
from sklearn.cluster import DBSCAN
from scipy.spatial import distance
from sklearn.neighbors import NearestNeighbors
```

1

In [3]:

```
# генеруємо дані
def make_circle(r, n, noise = 30, seed = 1234):
    np.random.seed(seed)
    return [(math.cos(2*math.pi/n*x)*r+np.random.normal(-noise,noise), math.sin(2*math.pi/n*x)*r+np.random.normal(-noise,noise)) for x in range(1,n+1)]

small_circle = make_circle(100, 300, 10)
medium_circle = make_circle(300, 700, 20)
big_circle = make_circle(500, 1000, 30)

noise = [(np.random.randint(-600,600),np.random.randint(-600,600)) for i in range(300)]
```

In [4]:

```
def arrray_to_df(arr, i):
    df = pd.DataFrame(arr)
    df['cluster'] = str(i)
    return df

data = [arrray_to_df(arr, i) for i, arr in enumerate([small_circle, medium_circle, big_circle, noise])]
data = pd.concat(data)
data.columns = ['x', 'y', 'cluster']
```

In [5]:

```
plt.scatter(data['x'], data['y'], label='data')
plt.xlabel('x')
plt.ylabel('y')
plt.title("Не розмічені дані")
plt.legend(bbox_to_anchor=(1,1), loc="upper left", prop={'size': 12})
```

Out[5]:

```
<matplotlib.legend.Legend at 0x135e08a15b0>
```

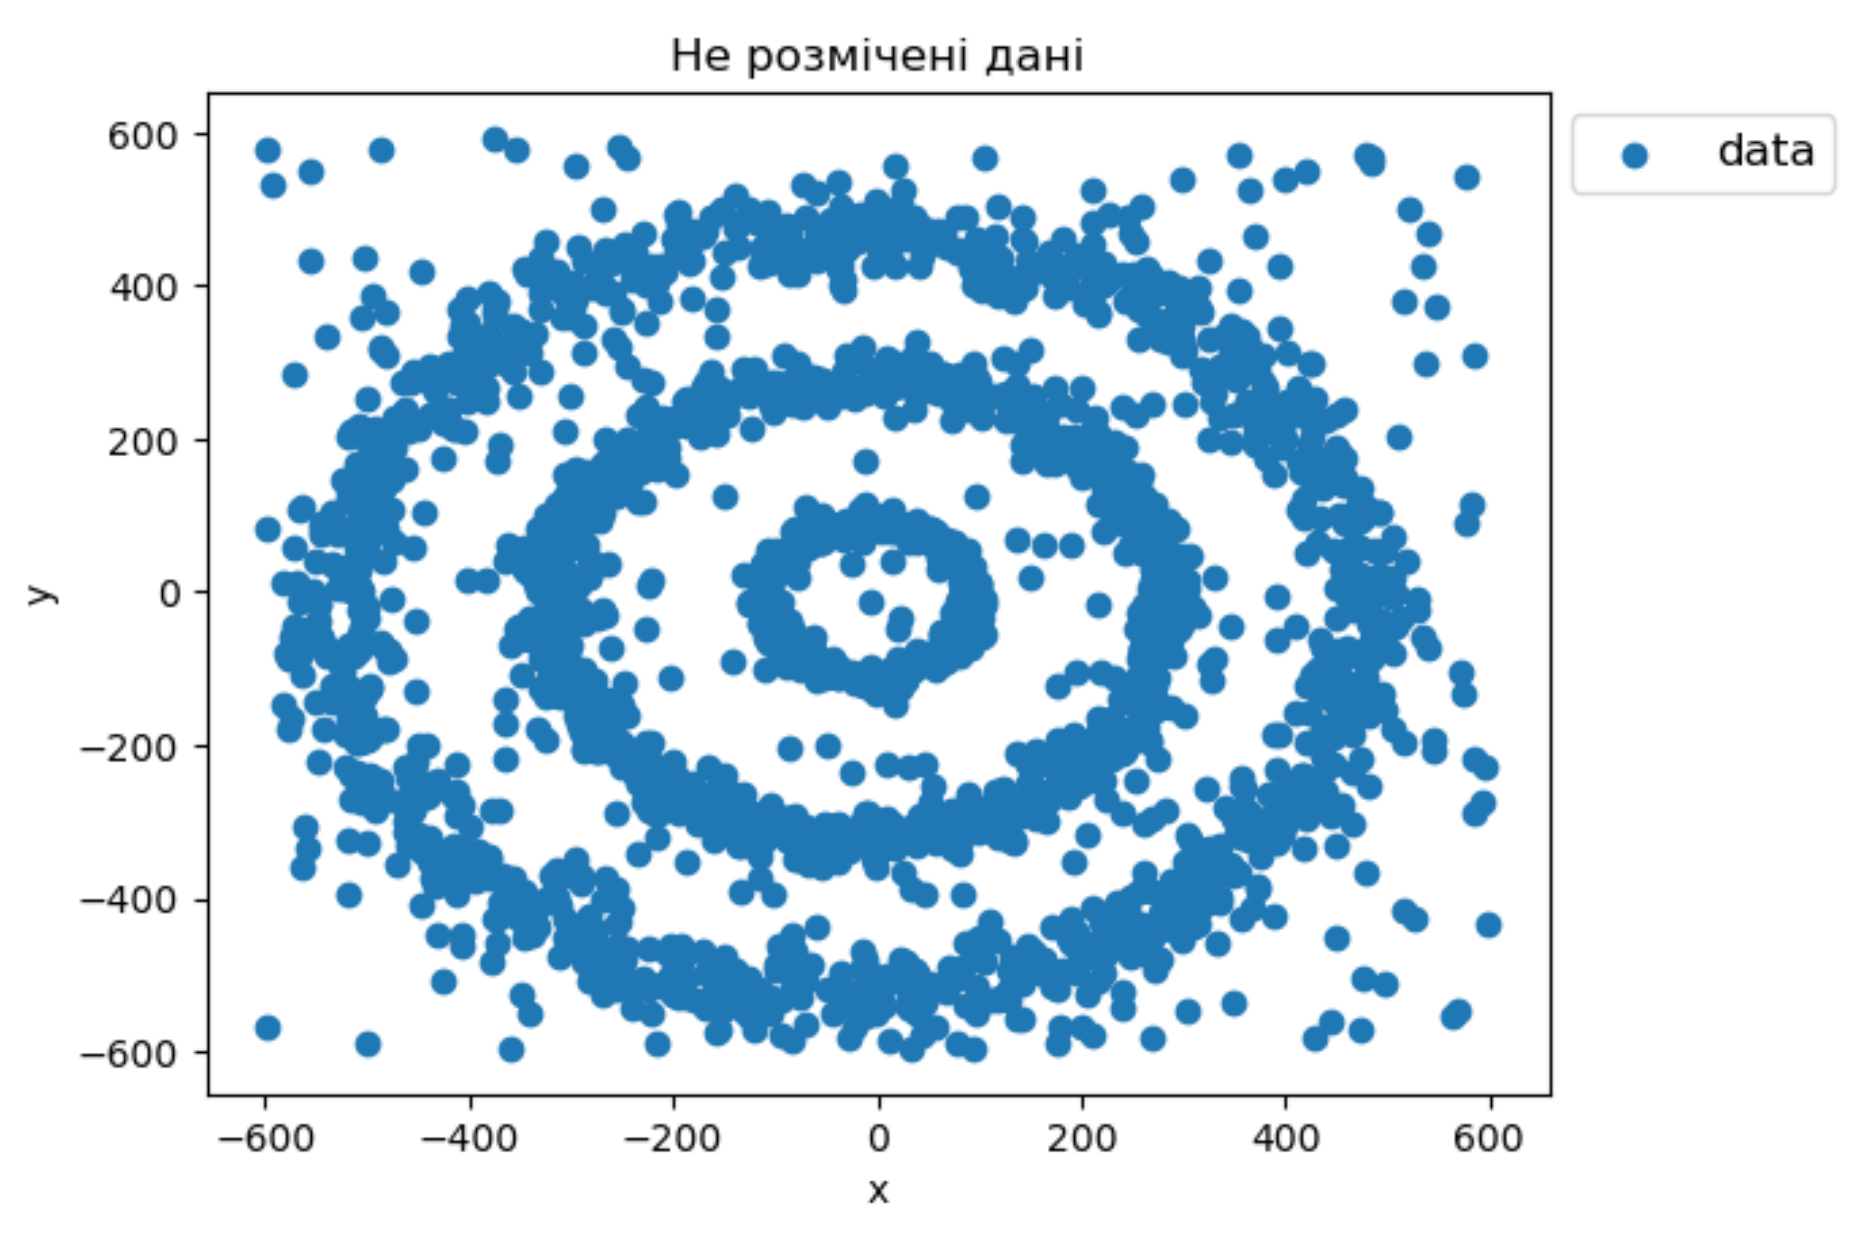

In [6]:

```
plt.rcParams['figure.figsize'] = [8,6]
sns.scatterplot(data = data, x = 'x',y = 'y',hue = 'cluster')
plt.title("Розмічені дані")
plt.legend(bbox_to_anchor=(1,1), loc="upper left", prop={'size': 12})
```

Out[6]:

```
<matplotlib.legend.Legend at 0x135e141f1f0>
```

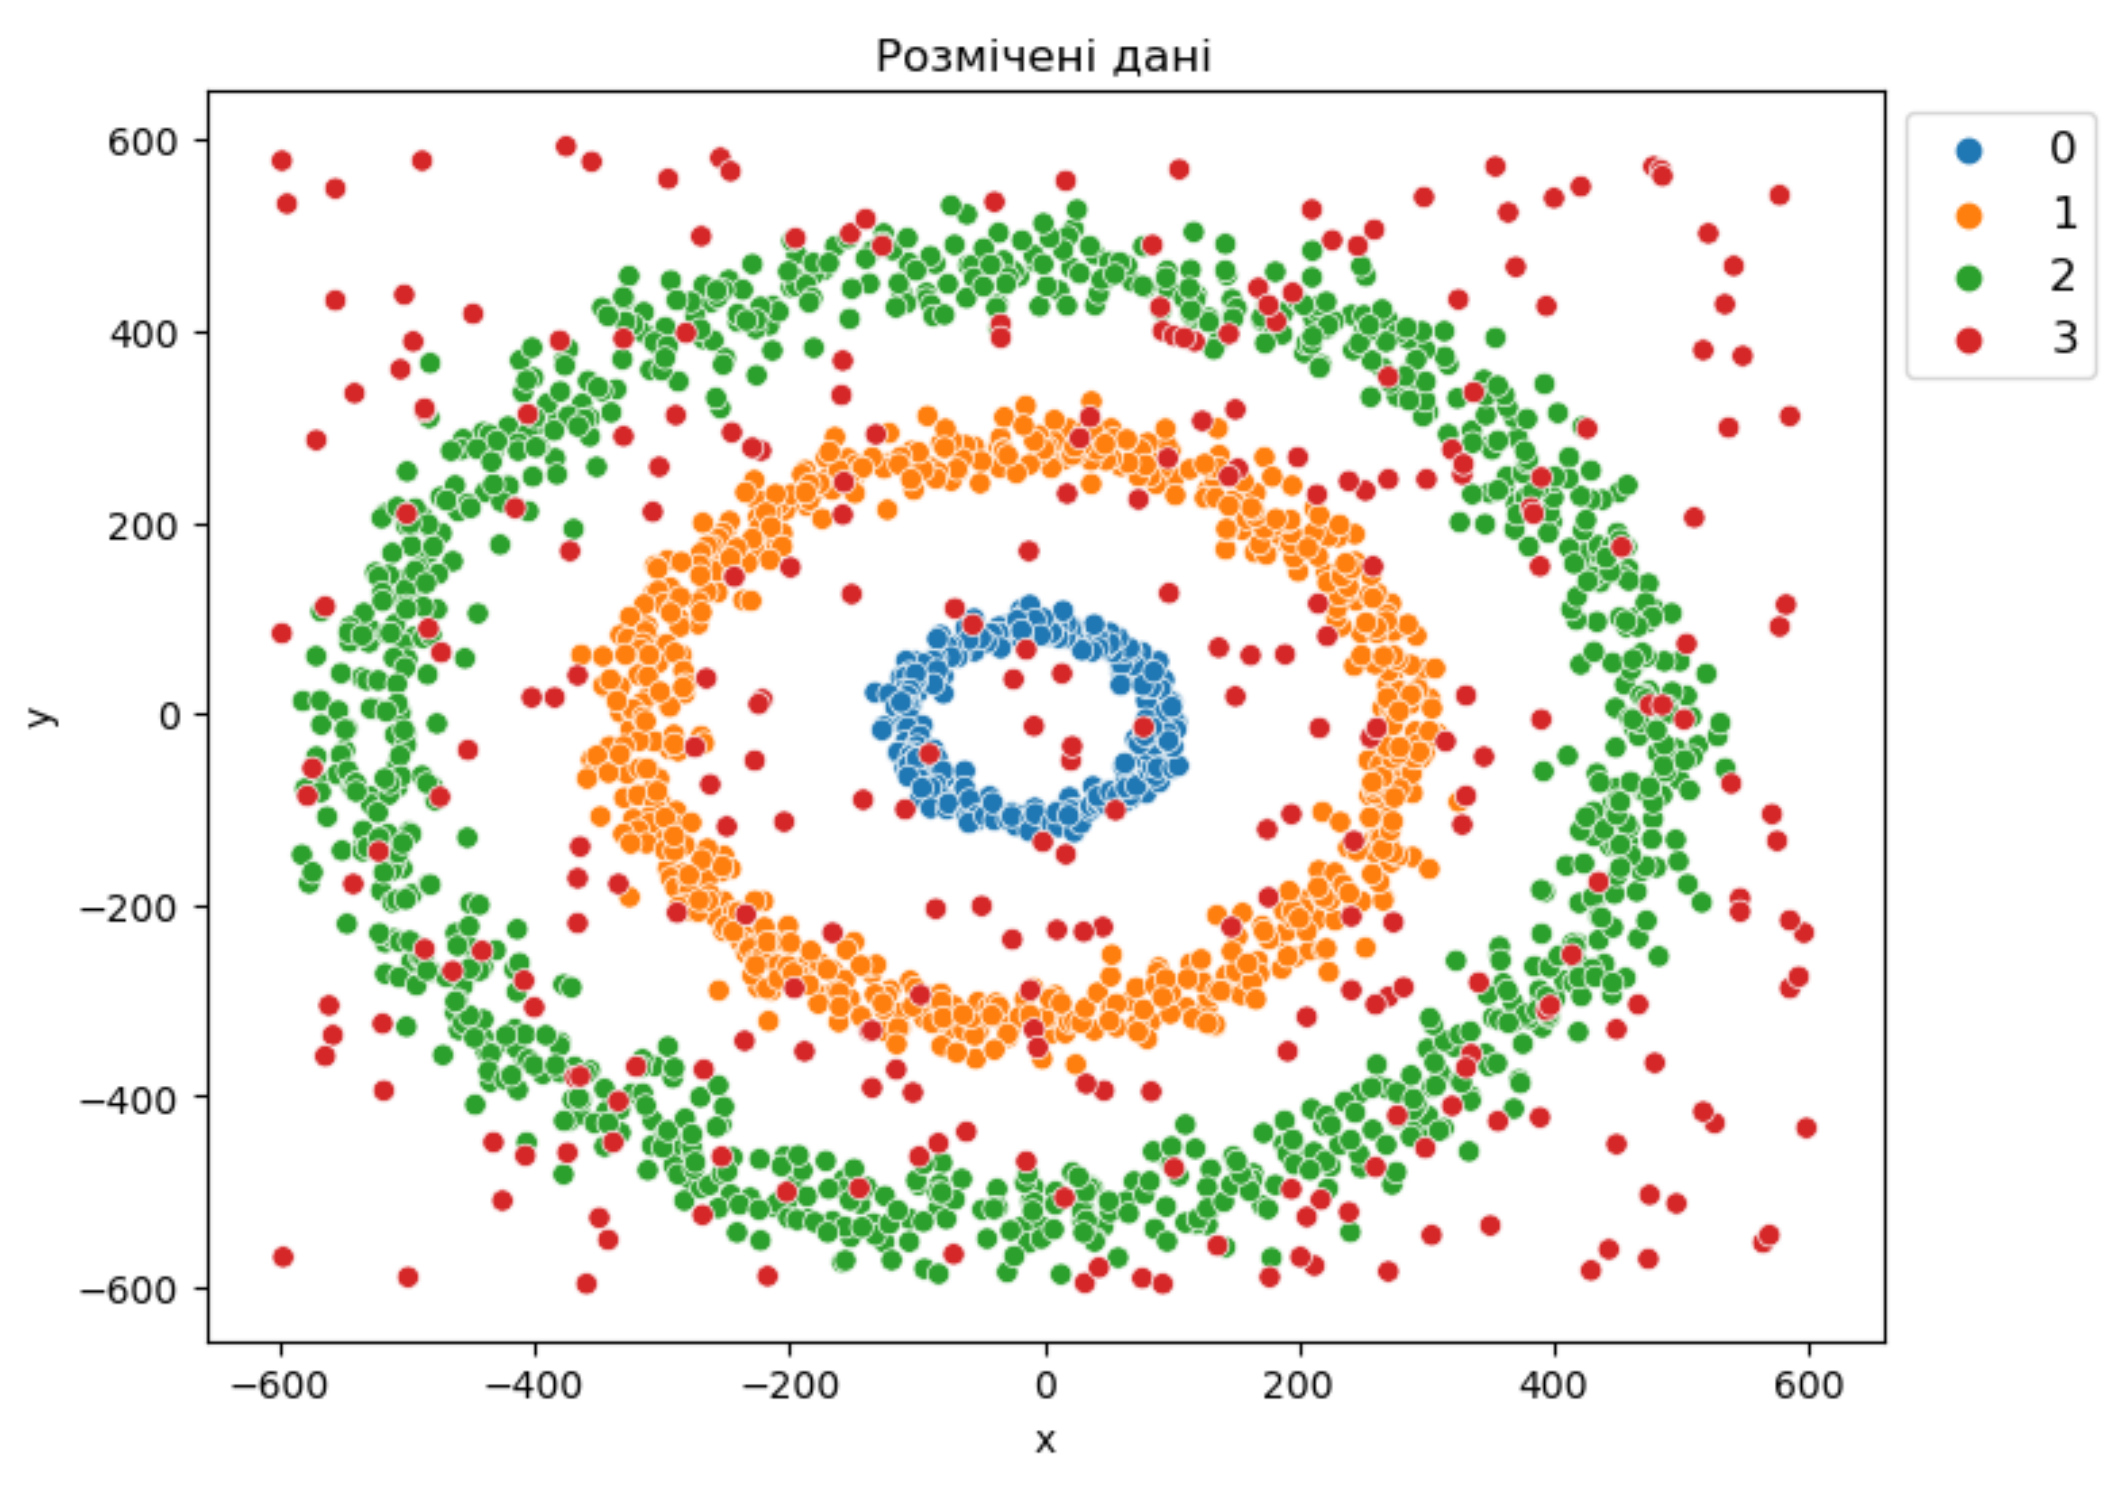

3

In [7]:

```
k = 2
data_nn = data.copy()[['x', 'y']]

nearest_neighbors = NearestNeighbors(n_neighbors=k)
neighbors = nearest_neighbors.fit(data_nn)
distances, indices = neighbors.kneighbors(data_nn)
distances = np.sort(distances, axis=0)

distances = distances[:,1]

i = np.arange(len(distances))

sns.lineplot(x = i, y = distances)
plt.xlabel("Дані сортовані за відстанню")
plt.ylabel("epsilon (distances)")
plt.title('K-Distance Graph')
```

Out[7]:

```
Text(0.5, 1.0, 'K-Distance Graph')
```

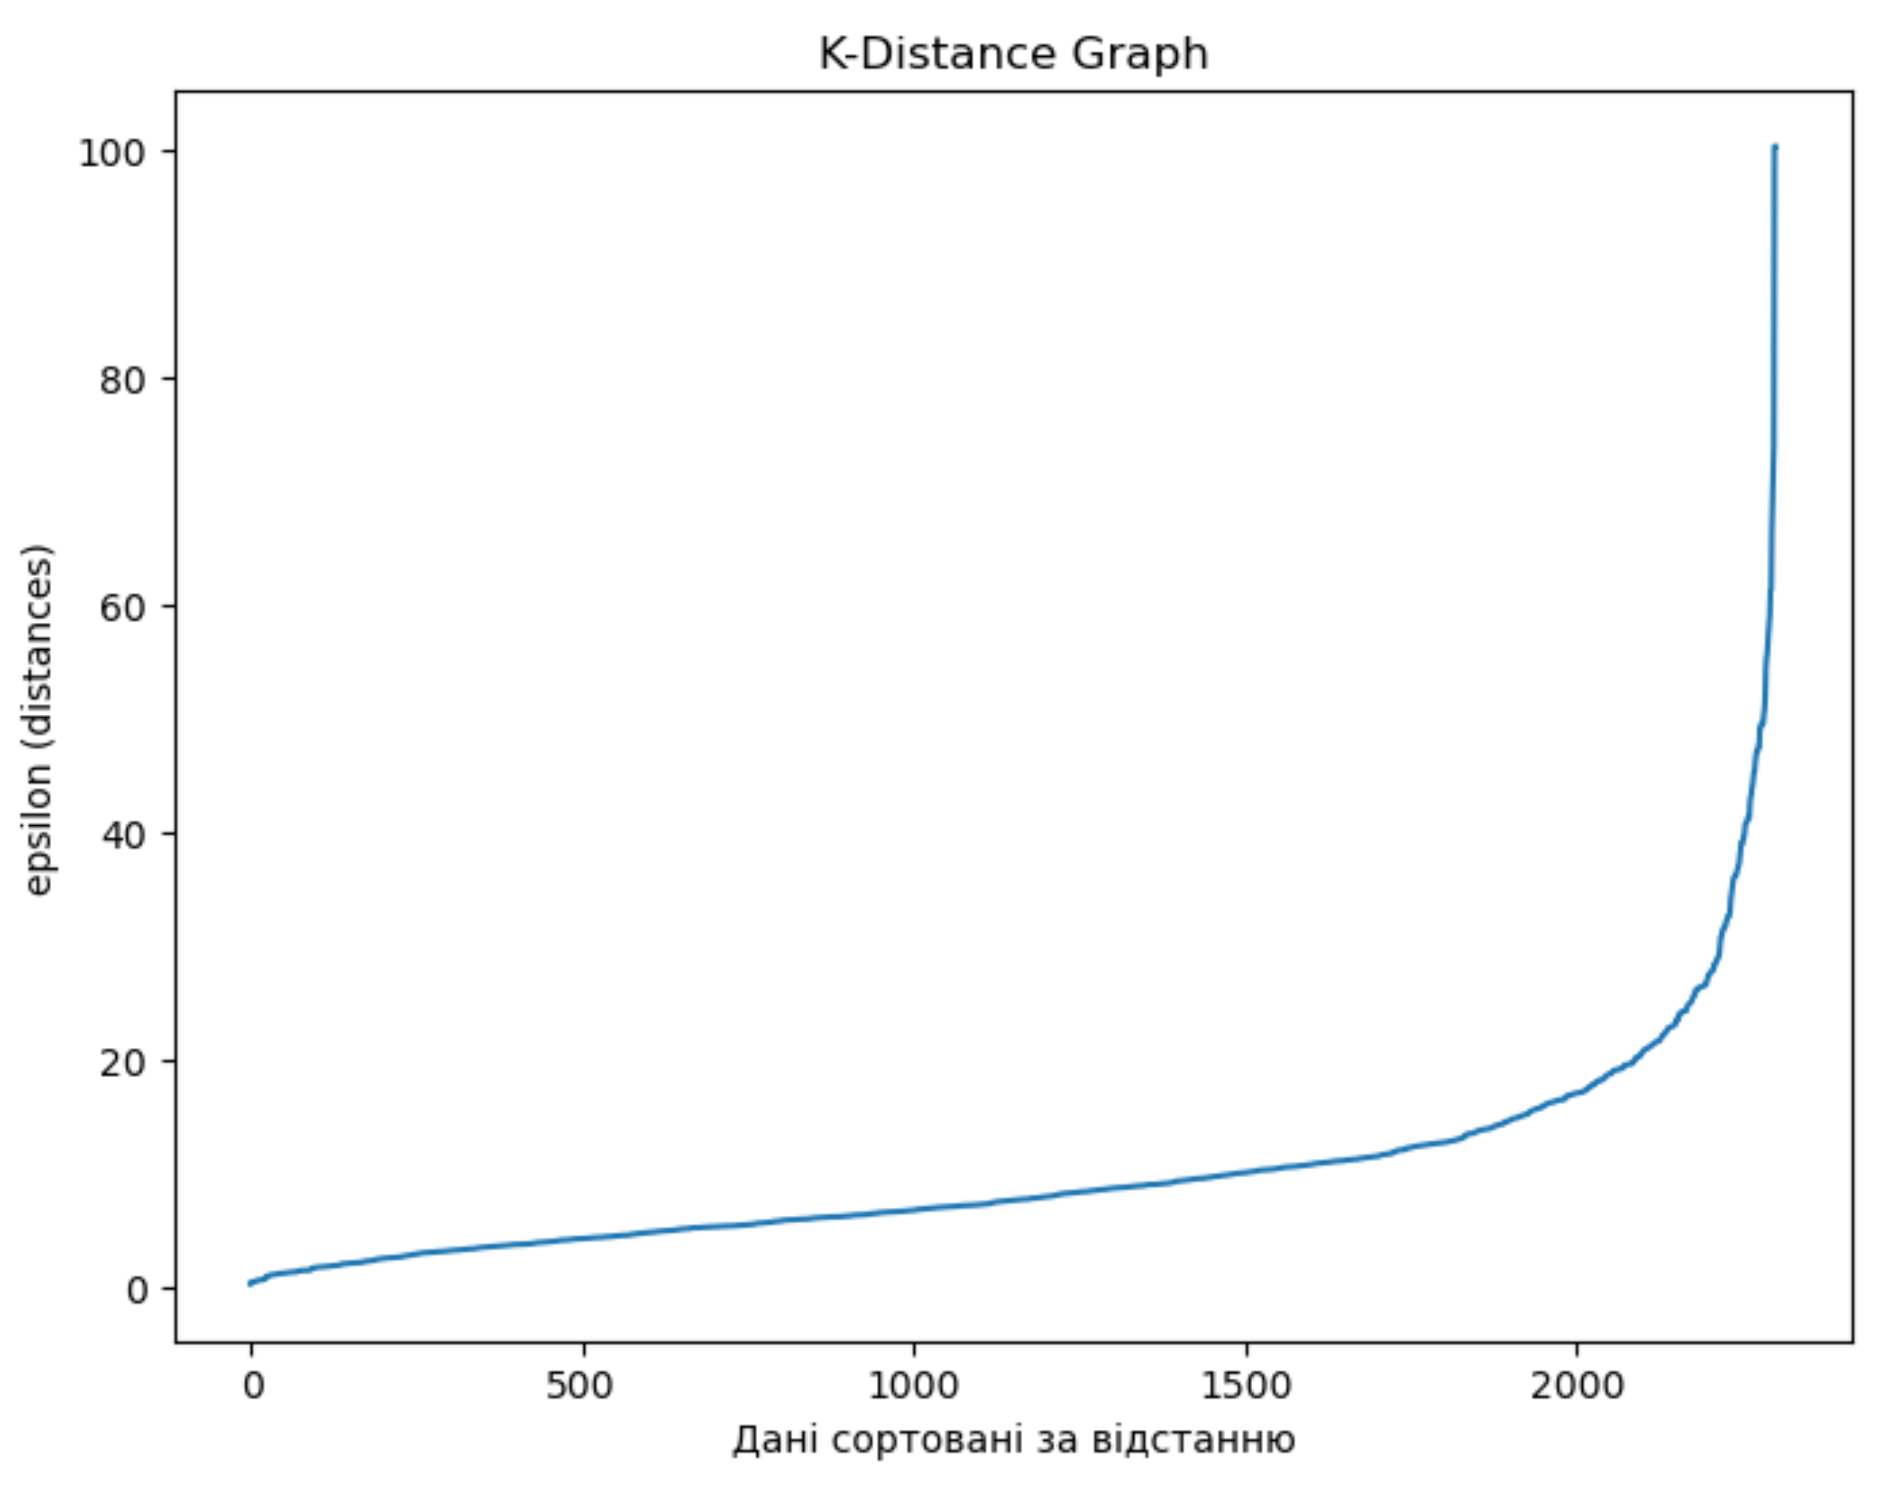

4

In [8]:

```
class dbscan:

    def __init__(self, epsilon = None, min_samples = None, distance = 'euclidean', normalize = False):
        self.epsilon = epsilon
        self.min_samples = min_samples
        self.distance = distance
        self.normalize = normalize

    def find_distance(self, x, type = 'euclidean'):
        """
        Finds distance between numpy arrays.
        """
        return distance.squareform(distance.pdist(x, type))

    def normalization(self, x):
        return (x-np.min(x))/(np.max(x) - np.min(x))

    def find_neighbors(self, x):
        return np.where(x <= self.epsilon)[0]

    def expand_cluster(self, neighbors, x, cluster, labels):

    # Iterate over each neighbor
        for neighbor in neighbors:
      # Check that is not assigned
            if labels[neighbor] == 0:
                # Find neighbors
                neighbor_neighbors = self.find_neighbors(x[neighbor])
                # Check if is core
                if len(neighbor_neighbors) >= self.min_samples:
                    labels[neighbor] = cluster
                    # For each neighbor in neighbors, expand cluster
                    labels = self.expand_cluster(neighbor_neighbors, x, cluster, labels)
        return labels

    def fit(self, x):
        """
        Given a reference point and comparison points and a distance function, returns the index of the neighbors.
        """
        # Do normalization
        if self.normalize:
            x = self.normalization(x)

        # Find distance
        dist_matrix = self.find_distance(x, self.distance)

        # Initialize cluster
        cluster = 1
        n_obs = x.shape[0]
        labels = np.zeros(n_obs)

        for i in range(n_obs):

            # If value not assigned
            if labels[i] == 0:

                # Find neighbors
                neighbors = self.find_neighbors(dist_matrix[i])

                # Check if neighbors > min_samples (self included as neighbor)
                if len(neighbors) > self.min_samples:

                    # If observation is not assigned --> Assign to cluster
                    if labels[i] == 0:
                        labels[i] = cluster

                        # Expand cluster on neighbors
                    labels = self.expand_cluster(neighbors, dist_matrix, cluster, labels)

                    # Go to next cluster
                    cluster = cluster + 1

        return labels
```

In [9]:

```
data['dbscan_custom'] = dbscan(epsilon=32, min_samples=5).fit(data[['x', 'y']].to_numpy())
```

5

In [10]:

```
sns.scatterplot(data = data, x = 'x', y = 'y', hue = 'dbscan_custom')
plt.legend(bbox_to_anchor=(1,1), loc="upper left", prop={'size': 12})
```

Out[10]:

```
<matplotlib.legend.Legend at 0x135e10e8bb0>
```

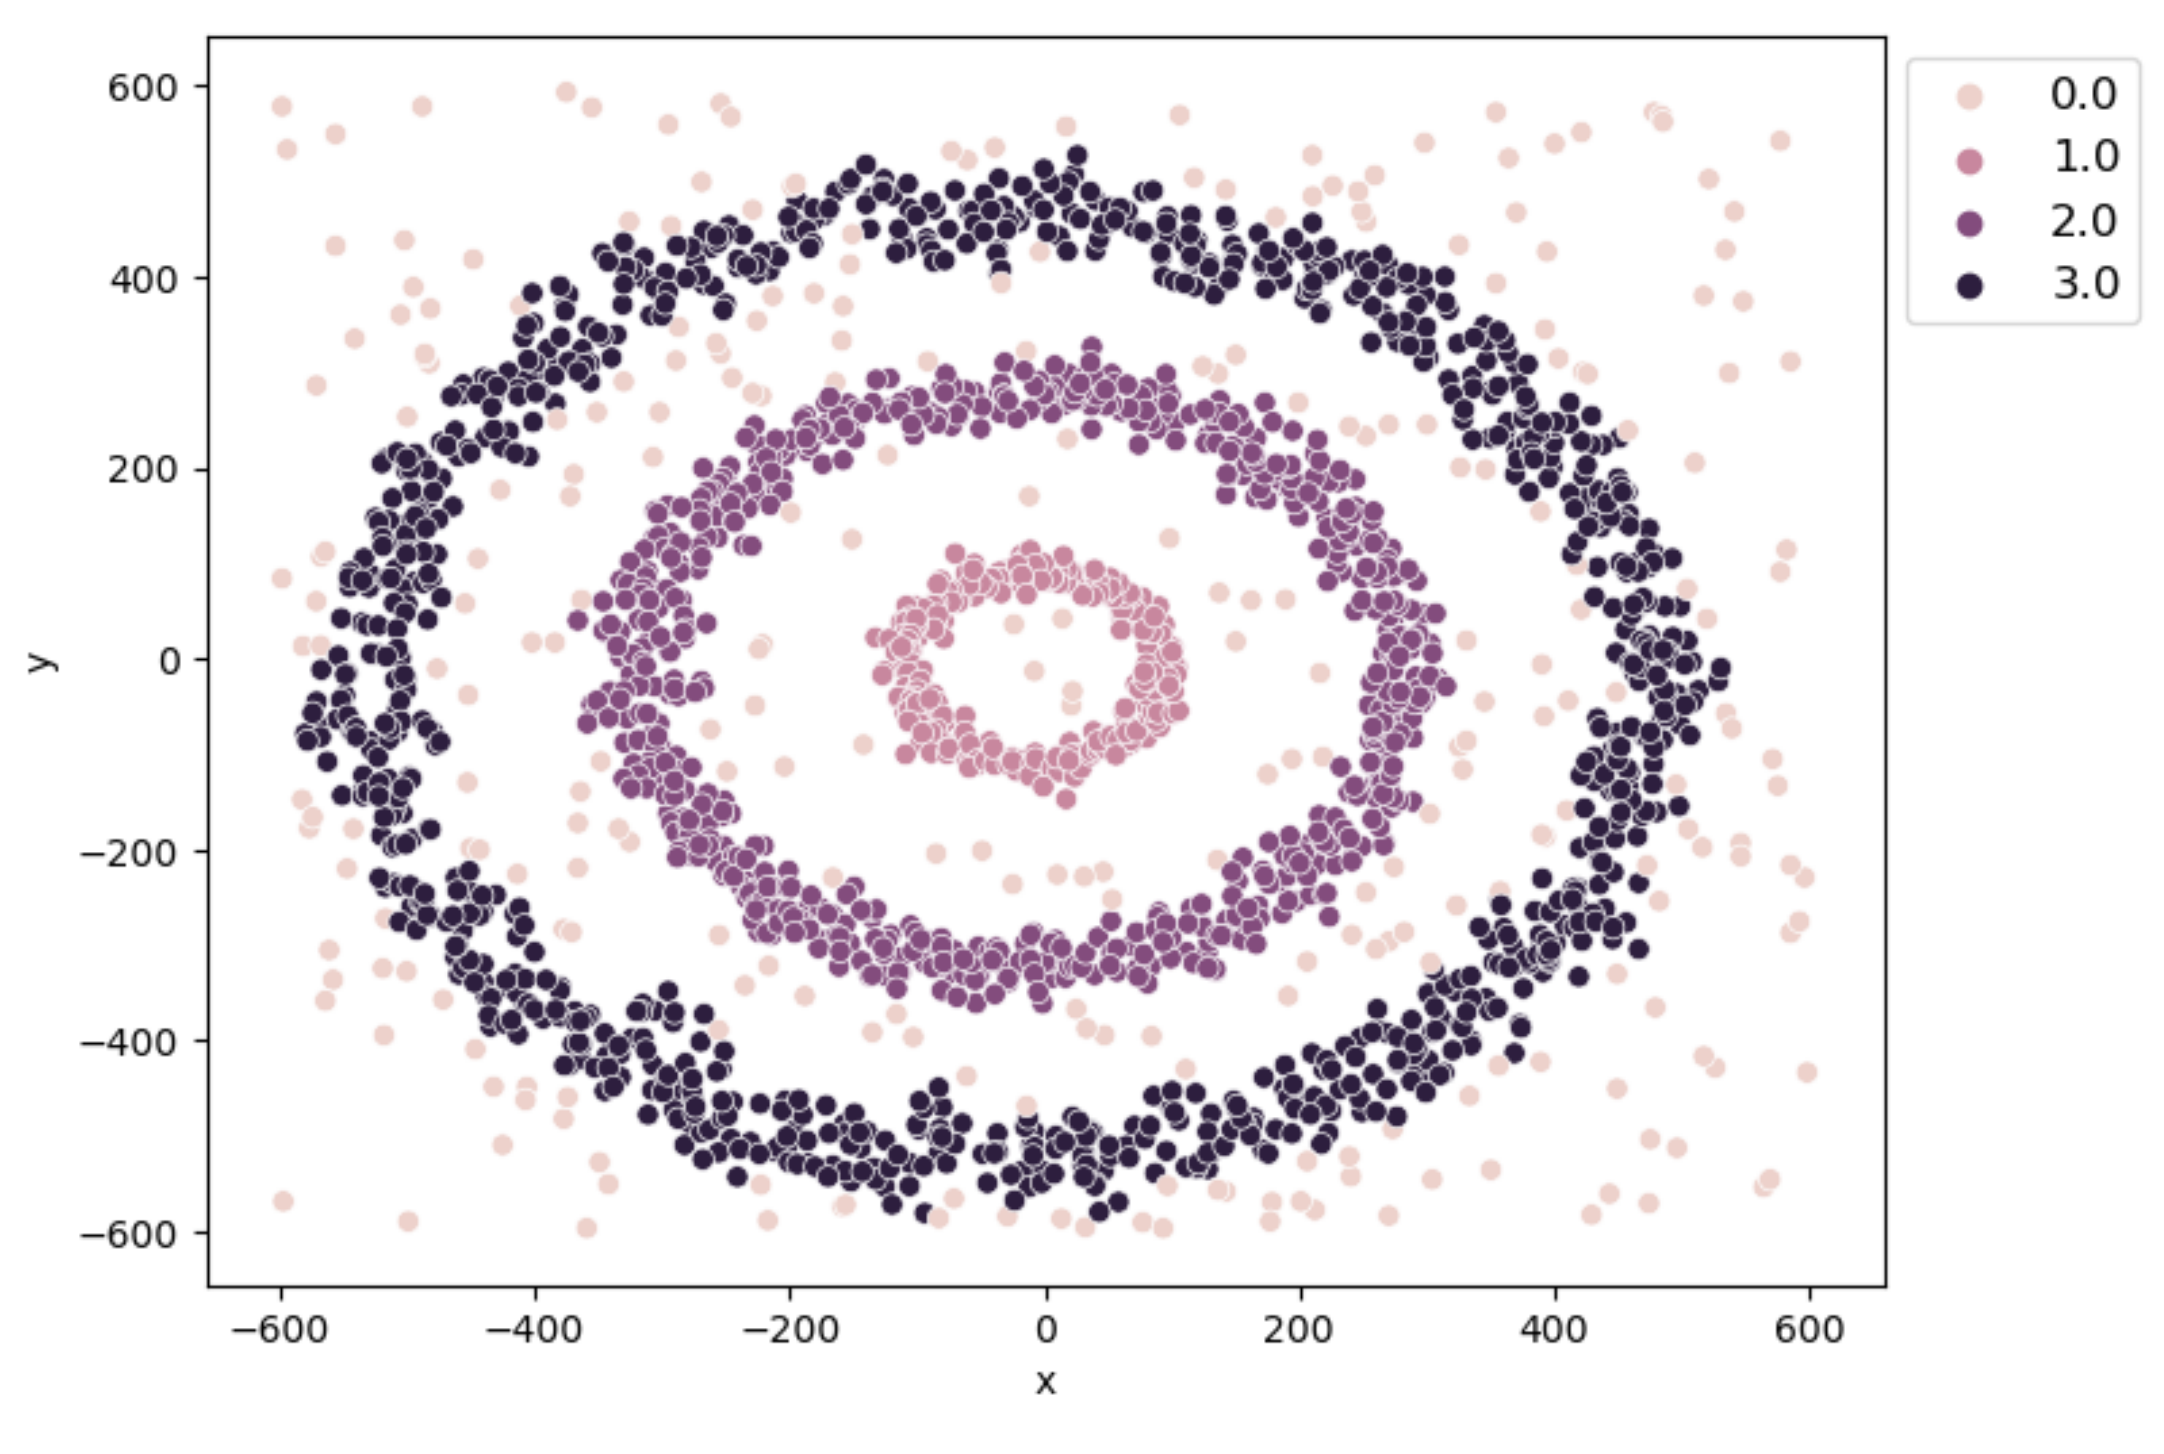

6

In [11]:

```
data2 = data.copy()
data2['dbscan2'] = DBSCAN(eps=32, min_samples=5).fit_predict(data[['x', 'y']])
sns.scatterplot(data = data2, x = 'x', y = 'y', hue = 'dbscan2')
plt.legend(bbox_to_anchor=(1,1), loc="upper left", prop={'size': 12})
```

Out[11]:

```
<matplotlib.legend.Legend at 0x135e1119880>
```

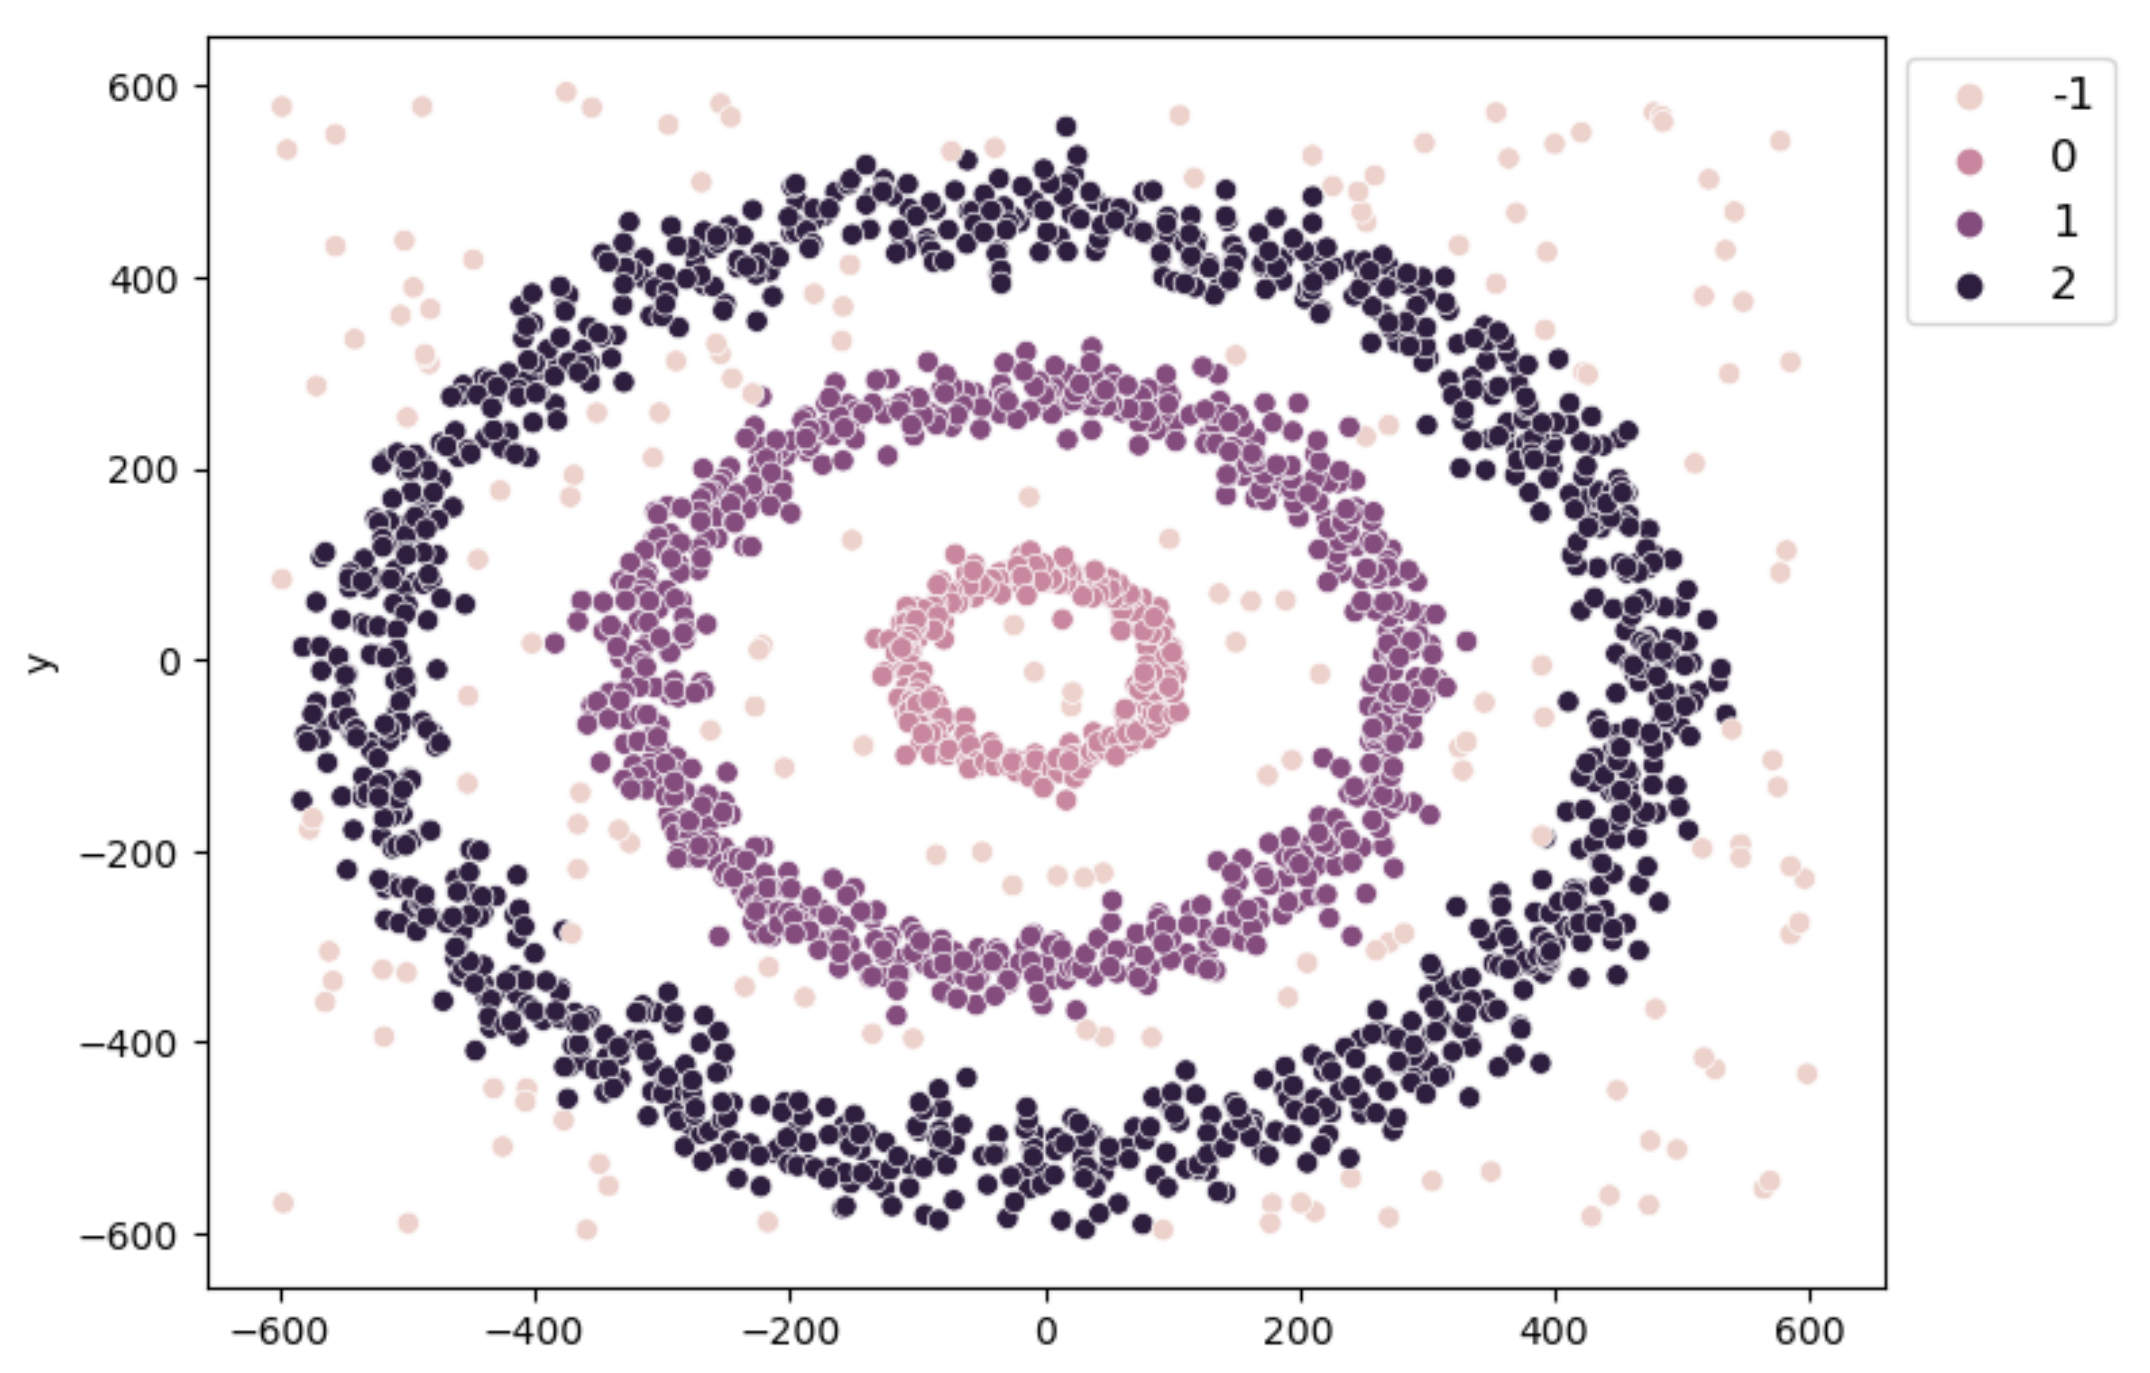

Отже, результати ідентичні.

Машинне навчання

Асоціації та пошук правил: метод Apriori

Лабораторна робота 8

Студентка Пороскун Олена. Група ПМ.м-21

Пошук асоціативних правил з використанням методу Apriori

Імпортувати дані для методу Apriori

1. Фіксуємо значення мінімальної підтримки та мінімальної впевненості
2. Використовуємо вбудований метод apriori з бібліотеки apyori
3. Отримуємо правила асоціації
4. Сортуємо правила за зменшенням впевненості
5. Виводимо правила на екран (файл)
6. Результати оформити у вигляді звіту

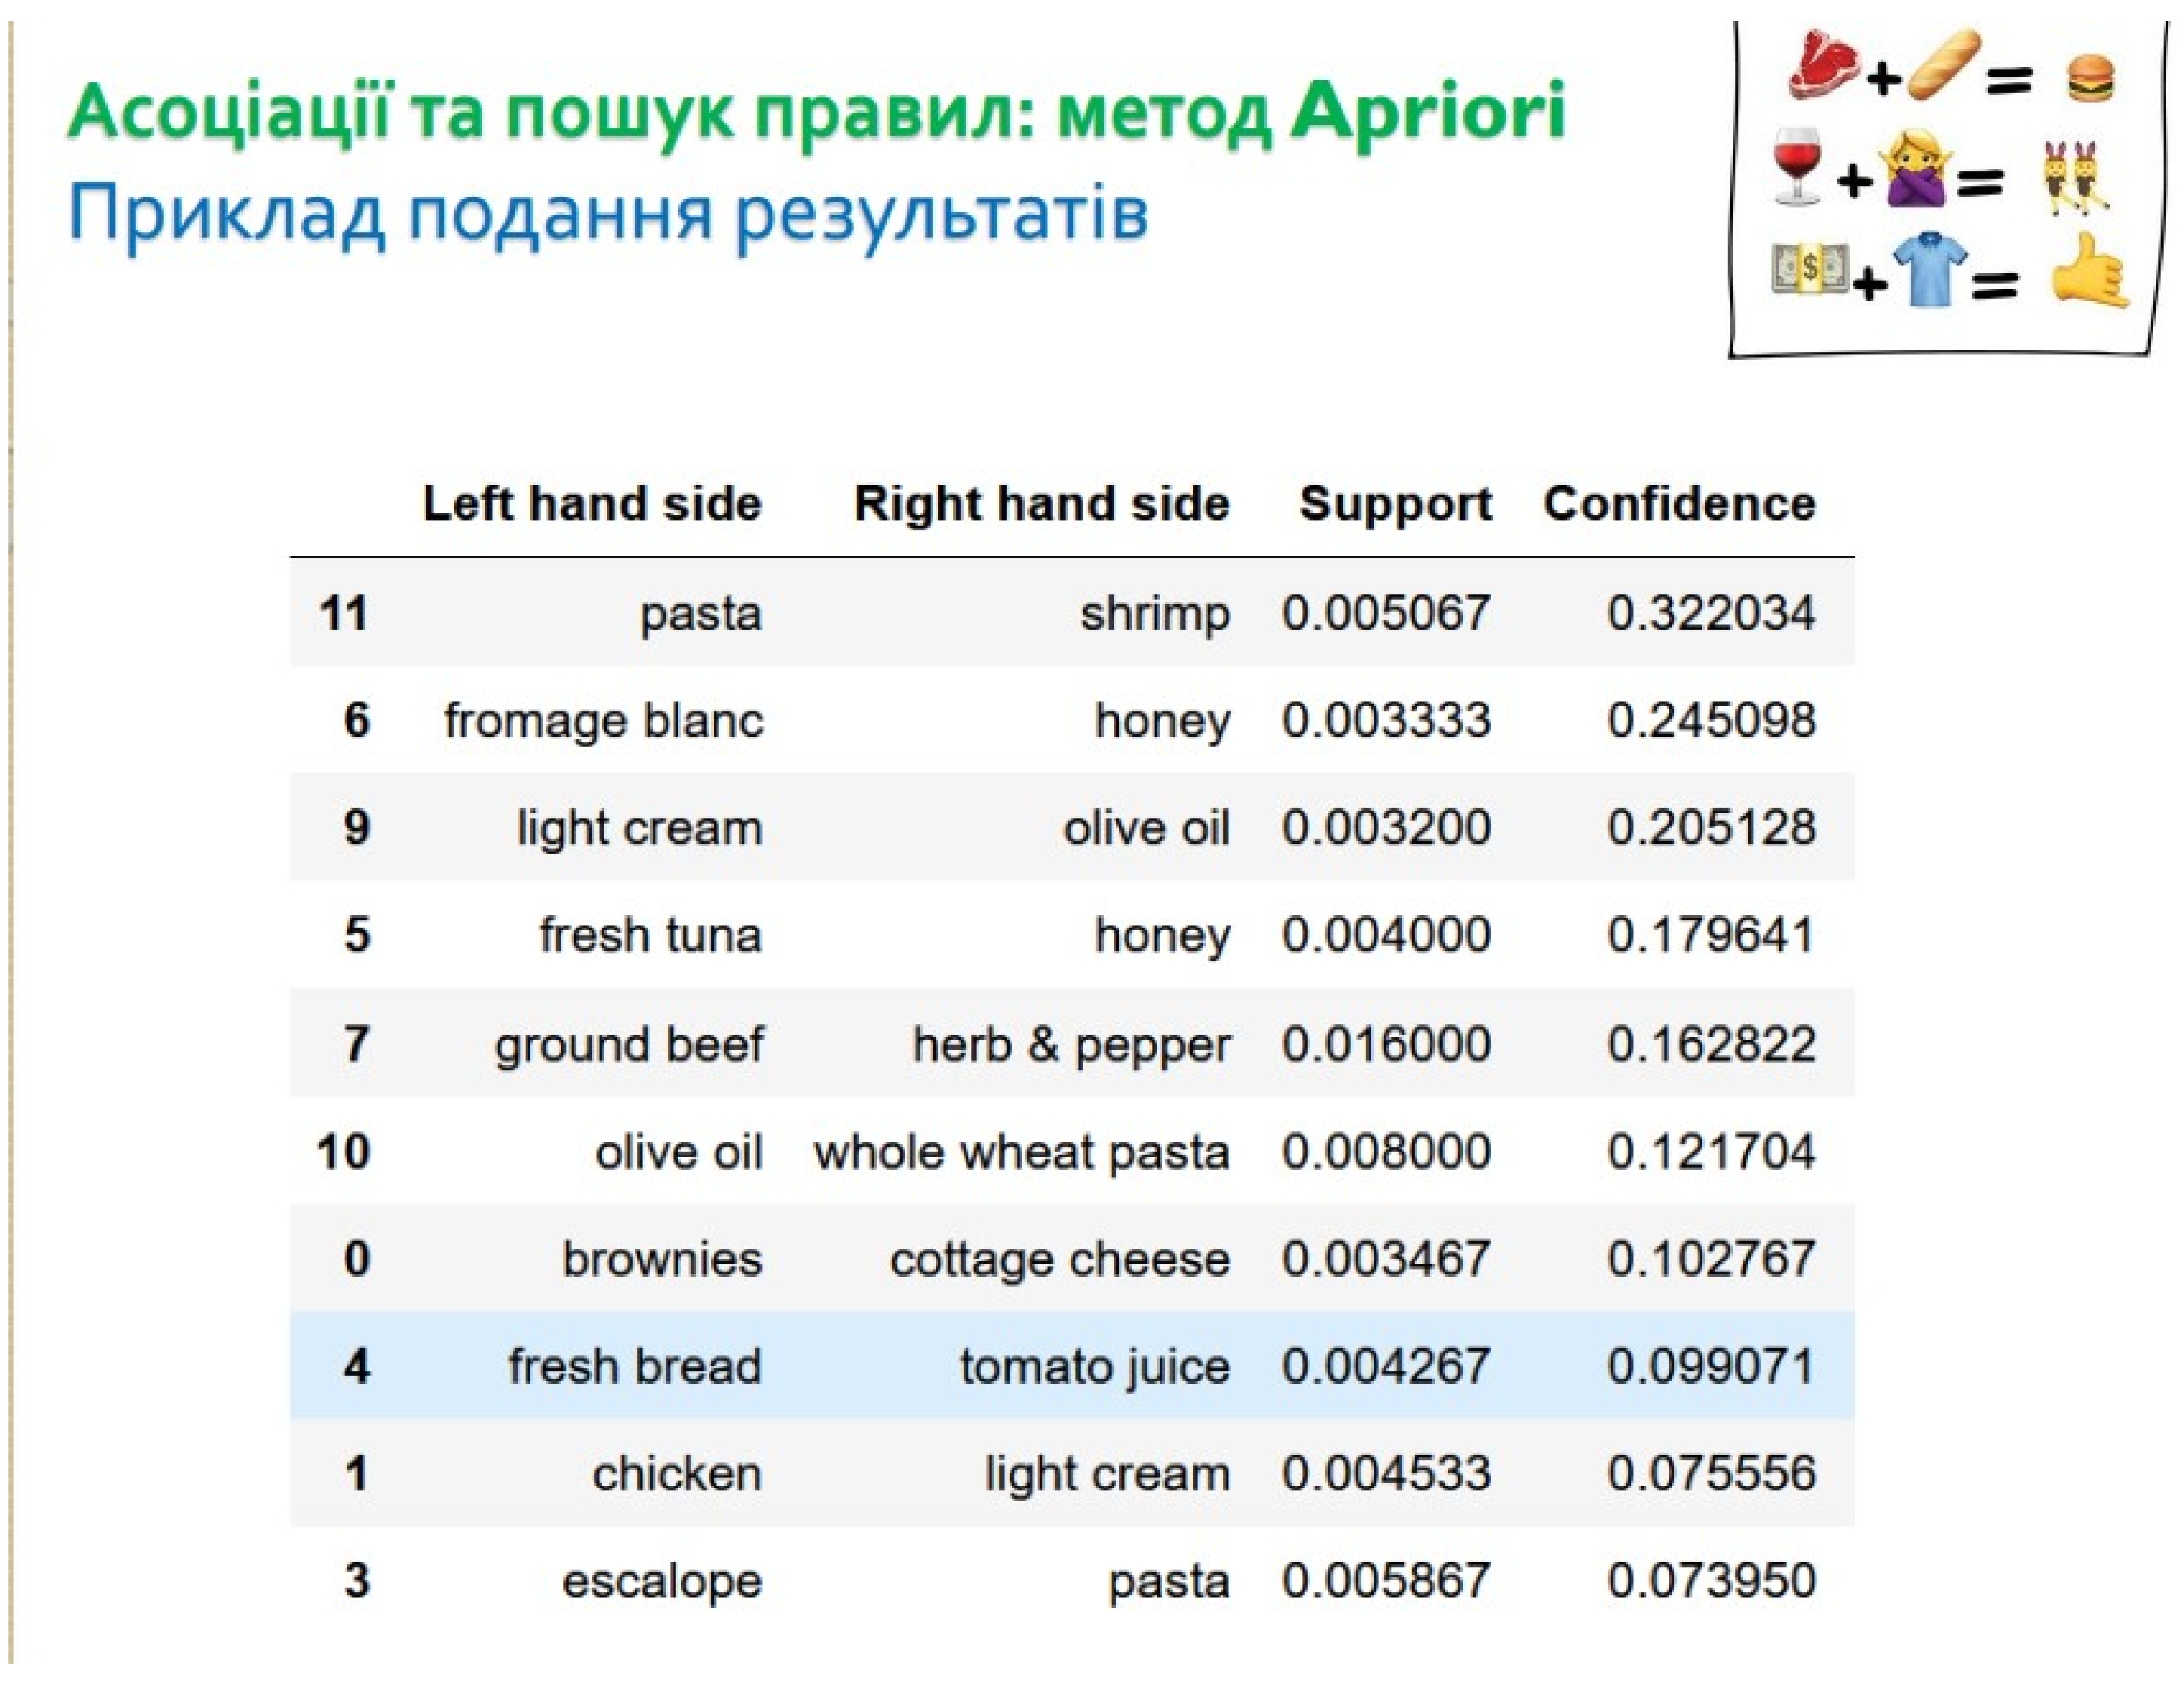

Асоціації та пошук правил: метод Apriori

Приклад подання результатів

	Left hand side	Right hand side	Support	Confidence
11	pasta	shrimp	0.005067	0.322034
6	fromage blanc	honey	0.003333	0.245098
9	light cream	olive oil	0.003200	0.205128
5	fresh tuna	honey	0.004000	0.179641
7	ground beef	herb & pepper	0.016000	0.162822
10	olive oil	whole wheat pasta	0.008000	0.121704
0	brownies	cottage cheese	0.003467	0.102767
4	fresh bread	tomato juice	0.004267	0.099071
1	chicken	light cream	0.004533	0.075556
3	escalope	pasta	0.005867	0.073950

In [1]:

```
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
from apyori import apriori
```

In [2]:

```
!pip install apyori
```

```
Requirement already satisfied: apyori in c:\users\admin\anaconda3\lib\site-packages (1.1.2)
```

In [3]:

```
dataset = pd.read_csv("Market_Basket_Optimisation.csv")
dataset
```

Out[3]:

	shrimp	almonds	avocado	vegetables mix	green grapes	whole weat flour	yams	cottage cheese	energy drink	tomato juice	low fat yogurt	green tea	honey	salad	mineral water	salmon	antioxydant juice	frozen smoothie	spinach	olive oil
0	burgers	meatballs	eggs	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
1	chutney	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2	turkey	avocado	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
3	mineral water	milk	energy bar	whole wheat rice	green tea	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
4	low fat yogurt	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
7495	butter	light mayo	fresh bread	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
7496	burgers	frozen vegetables	eggs	french fries	magazines	green tea	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
7497	chicken	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
7498	escalope	green tea	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
7499	eggs	frozen smoothie	yogurt cake	low fat yogurt	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN

7500 rows × 20 columns

In [4]:

```
len(dataset)
```

Out[4]:

```
7500
```

In [5]:

```
data_new = dataset.drop(range(3500,len(dataset)))
data_new
```

Out[5]:

	shrimp	almonds	avocado	vegetables mix	green grapes	whole weat flour	yams	cottage cheese	energy drink	tomato juice	low fat yogurt	green tea	honey	salad	mineral water	salmon	antioxydant juice	frozen smoothie	spinach	olive oil
0	burgers	meatballs	eggs	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
1	chutney	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2	turkey	avocado	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
3	mineral water	milk	energy bar	whole wheat rice	green tea	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
4	low fat yogurt	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
3495	burgers	salmon	vegetables mix	carrots	green tea	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
3496	tomatoes	rice	oil	green tea	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
3497	herb & pepper	ground beef	salmon	spinach	honey	protein bar	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
3498	chocolate	red wine	tomato sauce	butter	chicken	salmon	french fries	salt	mint	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
3499	cookies	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN

3500 rows × 20 columns

In [6]:

```
transactions = []
for i in range(0, len(data_new)):
    transactions.append([str(data_new.values[i,j]) for j in range(0,20)])
```

In [7]:

```
rules = apriori(transactions = transactions, min_support = 0.003, min_cinfidence = 0.2, \
                min_lift = 3, min_length = 2, max_length = 2)
```

In [8]:

```
results = list(rules)
#results
```

In [9]:

```
with open("file_results.txt", 'w') as f:
    for s in results:
        f.write(str(s) + '\n')

with open("file_results.txt", 'r') as f:
    results_from_file = [line.rstrip('\n') for line in f]

#print(results_from_file)
```

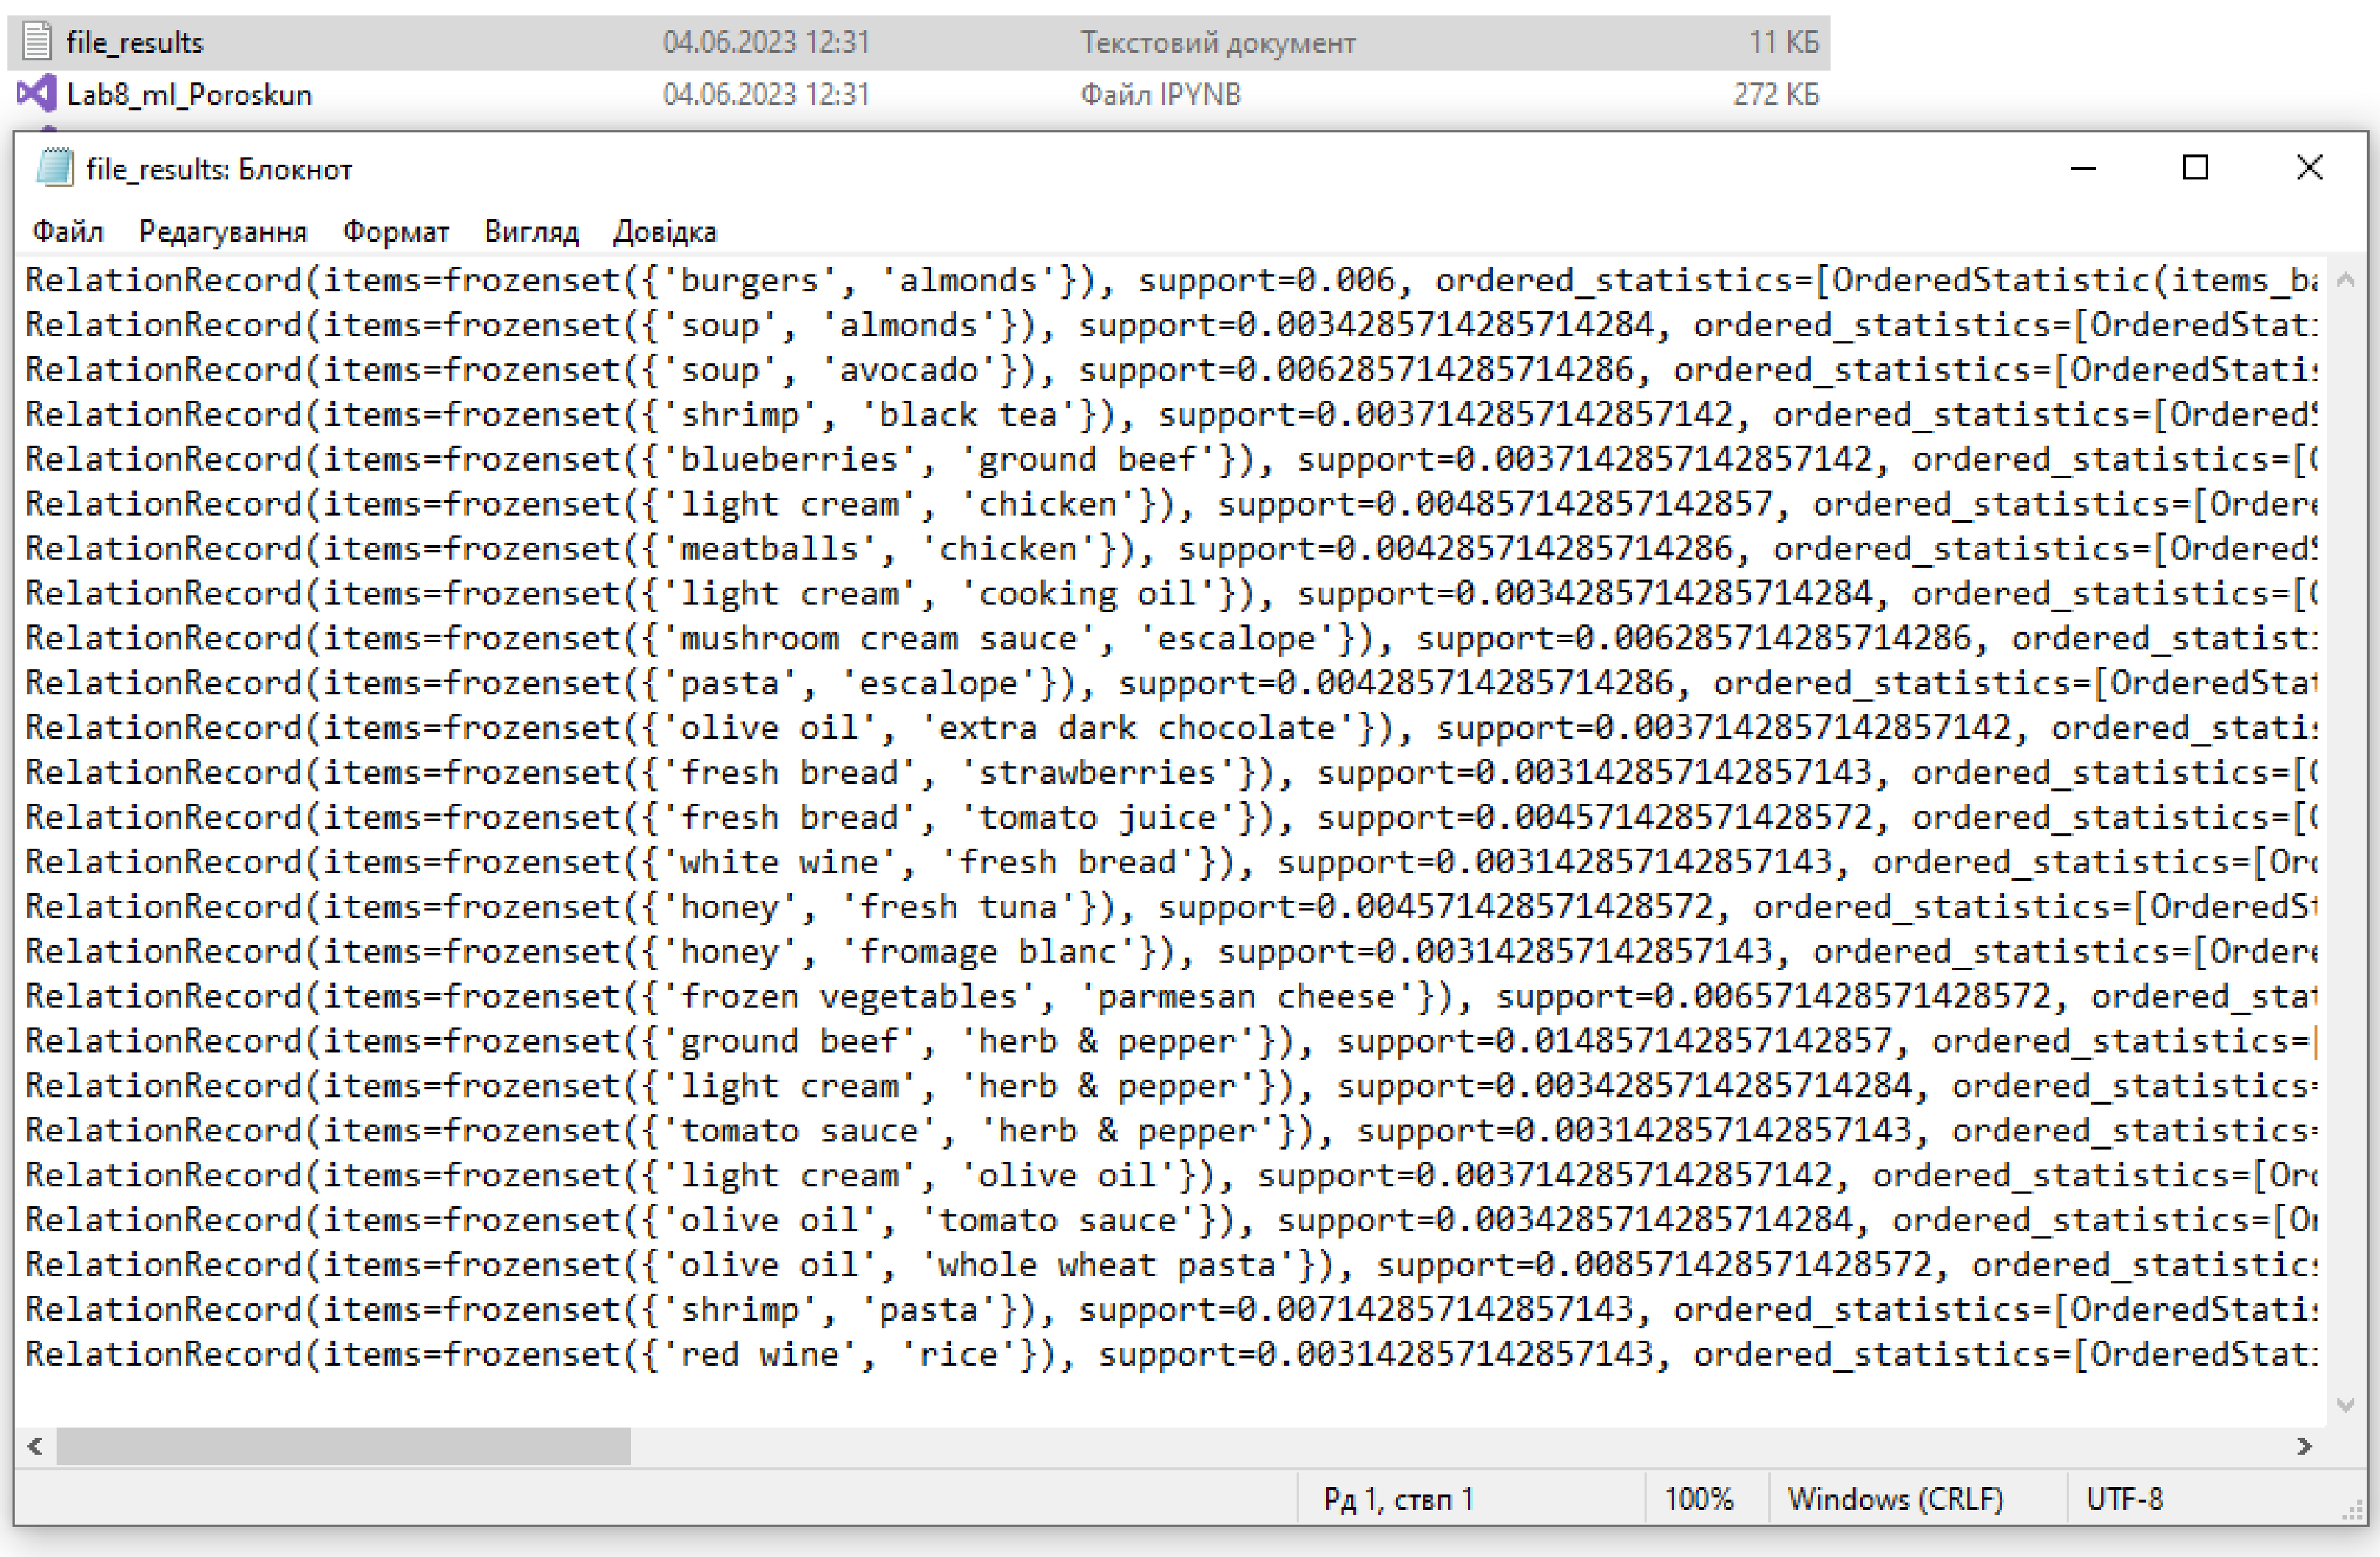

file_results	04.06.2023 12:31	Текстовий документ	11 КБ
Lab8_ml_Poroskun	04.06.2023 12:31	Файл IPYNB	272 КБ

file_results: Блокнот

```
RelationRecord(items=frozenset({'burgers', 'almonds'}), support=0.006, ordered_statistics=[OrderedStatistic(items_b
RelationRecord(items=frozenset({'soup', 'almonds'}), support=0.0034285714285714284, ordered_statistics=[OrderedStat
RelationRecord(items=frozenset({'soup', 'avocado'}), support=0.006285714285714286, ordered_statistics=[OrderedStati
RelationRecord(items=frozenset({'shrimp', 'black tea'}), support=0.0037142857142857142, ordered_statistics=[Ordered
RelationRecord(items=frozenset({'blueberries', 'ground beef'}), support=0.0037142857142857142, ordered_statistics=[
RelationRecord(items=frozenset({'light cream', 'chicken'}), support=0.004857142857142857, ordered_statistics=[Order
RelationRecord(items=frozenset({'meatballs', 'chicken'}), support=0.004285714285714286, ordered_statistics=[Ordered
RelationRecord(items=frozenset({'light cream', 'cooking oil'}), support=0.0034285714285714284, ordered_statistics=[
RelationRecord(items=frozenset({'mushroom cream sauce', 'escalope'}), support=0.006285714285714286, ordered_statist
RelationRecord(items=frozenset({'pasta', 'escalope'}), support=0.004285714285714286, ordered_statistics=[OrderedSta
RelationRecord(items=frozenset({'olive oil', 'extra dark chocolate'}), support=0.0037142857142857142, ordered_stati
RelationRecord(items=frozenset({'fresh bread', 'strawberries'}), support=0.003142857142857143, ordered_statistics=[
RelationRecord(items=frozenset({'fresh bread', 'tomato juice'}), support=0.004571428571428572, ordered_statistics=[
RelationRecord(items=frozenset({'white wine', 'fresh bread'}), support=0.003142857142857143, ordered_statistics=[Or
RelationRecord(items=frozenset({'honey', 'fresh tuna'}), support=0.004571428571428572, ordered_statistics=[OrderedS
RelationRecord(items=frozenset({'honey', 'fromage blanc'}), support=0.003142857142857143, ordered_statistics=[Order
RelationRecord(items=frozenset({'frozen vegetables', 'parmesan cheese'}), support=0.006571428571428572, ordered_sta
RelationRecord(items=frozenset({'ground beef', 'herb & pepper'}), support=0.014857142857142857, ordered_statistics=
RelationRecord(items=frozenset({'light cream', 'herb & pepper'}), support=0.0034285714285714284, ordered_statistics
RelationRecord(items=frozenset({'tomato sauce', 'herb & pepper'}), support=0.003142857142857143, ordered_statistics
RelationRecord(items=frozenset({'light cream', 'olive oil'}), support=0.0037142857142857142, ordered_statistics=[Or
RelationRecord(items=frozenset({'olive oil', 'tomato sauce'}), support=0.0034285714285714284, ordered_statistics=[O
RelationRecord(items=frozenset({'olive oil', 'whole wheat pasta'}), support=0.008571428571428572, ordered_statistic
RelationRecord(items=frozenset({'shrimp', 'pasta'}), support=0.007142857142857143, ordered_statistics=[OrderedStati
RelationRecord(items=frozenset({'red wine', 'rice'}), support=0.003142857142857143, ordered_statistics=[OrderedStat
```

In [10]:

```
def inspect(results):
    lhs         =[tuple(result[2][0][0])[0] for result in results]
    rhs         =[tuple(result[2][0][1])[0] for result in results]
    supports    =[result[1] for result in results]
    confidences =[result[2][0][2] for result in results]
    lifts        =[result[2][0][3] for result in results]
    return list (zip(lhs, rhs, supports, confidences, lifts))
```

In [11]:

```
resultsinDataFrame = pd.DataFrame(inspect(results), \
                                  columns = ["Left hand side", "Right hand side", "Support", "Confidence", "Lift"])
#resultsinDataFrame
```

In [12]:

```
resultsinDataFrame.drop('Lift', axis = 1).nlargest(n = 10, columns = "Confidence")
```

Out[12]:

	Left hand side	Right hand side	Support	Confidence
23	pasta	shrimp	0.007143	0.423729
4	blueberries	ground beef	0.003714	0.371429
0	almonds	burgers	0.006000	0.300000
10	extra dark chocolate	olive oil	0.003714	0.295455
3	black tea	shrimp	0.003714	0.282609
15	fromage blanc	honey	0.003143	0.275000
20	light cream	olive oil	0.003714	0.209677
14	fresh tuna	honey	0.004571	0.192771
2	avocado	soup	0.006286	0.174603
1	almonds	soup	0.003429	0.171429